

Algorytmiczna Analiza Danych

Wszystkie Ćwiczenia

2026-01-30

Adrian Herda
Politechnika Wrocławska

Spis treści

1.	Zadanie 1	6
1.1.	Podpunkt a) wynagrodzenie prezesa a czynniki firmowe	6
1.2.	Podpunkt b) wprowadzenie nowego produktu na rynek	6
1.3.	Podpunkt c) prognozowanie zmian kursu dolara	6
2.	Zadanie 2	6
2.1.	Klasyfikacja	7
2.1.1.	Przykład 1 - rozpoznawanie rodzajów wina	7
2.1.2.	Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami	7
2.2.	Regresja	7
2.2.1.	Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)	7
2.2.2.	Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów	7
2.3.	Analiza klastrow	8
2.3.1.	Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)	8
2.3.2.	Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach	8
3.	Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne	8
3.1.	Parametryczne	9
3.2.	Nieparametryczna	9
3.3.	Zalety i wady	10
4.	Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)	10
4.1.	a) odległość euklidesowa dla każdego punktu	10
4.2.	b) predykcja dla $K = 1$	10
4.3.	c) predykcja dla $K = 3$	10
4.4.	d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa	10
5.	Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych	11
5.1.	a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$	11
5.2.	b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$	11
6.	Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami ...	11
6.1.	Definicje	12
6.2.	Przykłady	12
6.2.1.	Nieobciążony	12

6.2.2.	Obciążony	12
7.	Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza	12
7.1.	Wnioski	13
8.	Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu	14
8.1.	Rozwiązanie	14
8.2.	Równowaga bias-variance	14
9.	Zadanie 9 - Wykresy względem elastyczności modelu	15
9.1.	Wytlumaczenie każdej funkcji	15
10.	Zadanie 10 - Obliczanie wzorów na parametry modelu linowego	15
10.1.	Dane	15
10.2.	Cel	16
10.3.	Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$	17
11.	Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym	17
11.1.	Błąd systematyczny	18
11.2.	Wariancja	18
11.2.1.	Reprezentacja estymatorów za pomocą szumów	18
11.2.2.	Wariancja estymatorów	18
11.3.	Błąd standardowy estymatorów	19
12.	Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny	19
13.	Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale	21
13.1.	Reguła trzech sigm	21
13.2.	Ustandaryzowana zmienna	21
14.	Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami	22
14.1.	Teza	22
14.2.	Dowód	22
15.	Zadanie 15 - Korelacja	24
16.	Zadanie 16 - t-statystyka i p-wartość	25
16.1.	t-statystyka	25
16.2.	p-wartość	25
17.	Zadanie 17 - Odległość Mahalanobisa	25
17.1.	odpowiedź	25
18.	Zadanie 18 - Double descent	25
18.1.	Odpowiedź	26
19.	Zadanie 19	27
19.1.	Odpowiedź	27
19.1.1.	Definicja	27
19.1.2.	Własności	27
20.	Zadanie 20	28
20.1.	Rozwiązanie	28
21.	Zadanie 21	29
21.1.	Rozwiązanie	29
22.	Zadanie 22	30
22.1.	Rozwiązanie	30
22.2.	Czy estymator nieobciążony?	30

23.	Zadanie 23	31
23.1.	a) $p = 1$	31
23.2.	b) $p = 2$	31
23.3.	c) $p = 100$	31
23.4.	d)	31
23.5.	e)	32
23.5.1.	Wzór	32
23.5.2.	Wyniki	32
24.	Zadanie 24 – Ocena modelu w problemie klasyfikacji	33
24.1.	Oznaczenia	33
24.2.	a) Metryki: Accuracy, Precision, Recall oraz F1	33
24.2.1.	Definicje metryk	33
24.2.2.	Przykład	33
24.3.	b) Różnica wersji <i>micro</i> od <i>macro</i>	34
24.4.	c) Potoczne rozumienie a definicja	34
25.	Zadanie 25 – Naiwny Klasyfikator Bayesa	34
25.1.	Definicja	34
25.2.	Dowód wzoru	34
26.	Zadanie 26 – Klasyfikacja Spam vs Nie-spam	35
27.	Zadanie 27 – Regresja Logistyczna	36
27.1.	a) Dlaczego nie regresja liniowa?	36
27.2.	b) Obliczenie szans (Odds)	36
27.3.	c) Dowód równoważności z Log-Odds	36
27.4.	d) Zależność sigma a logit	37
28.	Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych	38
29.	Ćwiczenie 29 – Funkcja Softmax	38
29.1.	Wzór i intuicja	38
29.1.1.	Intuicja	39
29.1.2.	Dlaczego „ciągły argmax”?	39
29.2.	Klasyfikacja wieloetykietowa (Multi-label)	39
30.	Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax	39
30.1.	Macierz Jacobiego	39
30.2.	Analiza znaków pochodnych	40
31.	Ćwiczenie 31 – Gradient Entropii Krzyżowej	40
32.	Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)	41
33.	Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa	42
34.	Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL	42
34.1.	Związek między miarami	43
35.	Ćwiczenie 35 – Entropia różniczkowa	43
35.1.	Definicja	43
35.2.	Ujemna wartość entropii różniczkowej	43
35.3.	Skalowanie zmiennej ($H(aX)$)	44
35.4.	Maksymalna entropia rozkładu normalnego	44
36.	Ćwiczenie 36 – Miary odległości między rozkładami	44
37.	Ćwiczenie 37 – Własności próby bootstrapowej	46
37.1.	Wartość oczekiwana X	46
37.2.	Wariancja X	46
37.3.	Odsetek unikalnych obserwacji i jego wariancja	47

37.3.1.	Średnia	47
37.3.2.	Wariancja	47
37.4.	Prawdopodobieństwo braku obserwacji w k próbkach	47
38.	Ćwiczenie 38 – Konstrukcja drzewa i predyktory kategori- czne	48
38.1.	Konstrukcja drzewa	48
38.2.	Problem z predyktorem kategori- cznym	48
38.3.	Rozwiązanie problemu	48
39.	Ćwiczenie 39 – Miary jakości podziału	48
39.1.	a) Interpretacja indeksu Giniego	48
39.2.	b) Porównanie podziałów	49
39.3.	Obliczenie Indeksu Giniego	49
39.3.1.	Wniosek	50
40.	Zadanie 40 – Współczynnik Giniego	51
40.1.	Intuicja geometryczna (Krzywa Lorenza)	51
40.2.	Pozycja Polski w OECD	51
40.3.	Poziom graniczny napięcie społecznych	51
41.	Zadanie 41 – Algorytm Random Forest	52
41.1.	Pseudokod	52
41.2.	Predykcja	52
42.	Ćwiczenie 42 – Algorytm Boosting (Regresja)	52
42.1.	Pseudokod (na podstawie ISL)	52
42.2.	Wyjaśnienie kluczowych parametrów	52
43.	Zadanie 43 – Obliczenia PCA	53
43.1.	Średnia każdej zmiennej	53
43.2.	Macierz kowariancji	53
43.3.	Wartości własne i wektory własne	53
43.4.	Interpretacja	54
44.	Zadanie 44 – Ortogonalność wektorów własnych	55
45.	Zadanie 45 – Prawda czy Fałsz o PCA	55
46.	Ćwiczenie 46 – Idea algorytmu Apriori	57
46.1.	Właściwość Apriori (Anti-monotonicity)	57
46.2.	Proces generowania kandydatów	57
47.	Ćwiczenie 47 – Oznaczenie węzłów kraty (M, D, C, R)	57
48.	Ćwiczenie 48 – Intuicje: Maksymalne vs Domknięte	59
48.1.	Maksymalny zbiór częsty:	59
48.2.	Domknięty zbiór częsty:	59
49.	Ćwiczenie 49 – Złożoność Algorytmu Apriori	59
50.	Ćwiczenie 50 – Liczba reguł asocjacyjnych	60
51.	Ćwiczenie 51 – Przechodniość reguł	60
52.	Ćwiczenie 52 – Dowód nierówności	61
52.1.	Podpunkt b)	61
52.2.	Podpunkt a)	62
53.	Ćwiczenie 53 – Miary oceny reguł	62
54.	Ćwiczenie 54 – Algorytm K-Means	64
54.1.	Działanie algorytmu	64
54.2.	Złożoność obliczeniowa	64
54.3.	Dlaczego Potrzebne jest wielokrotne uruchomienie	64
54.4.	Pechowy wybór centroidów	65

55.	Ćwiczenie 55 – Dowód na postać centroidu	65
56.	Ćwiczenie 56 – DBSCAN	66
56.1.	Działanie DBSCAN	66
56.2.	Ustalanie parametrów	66
56.3.	Porównanie k-means i DBSCAN	66
56.4.	Co lepsze dla dokumentów (dane wielowymiarowe)?	66
57.	Ćwiczenie 57 — Klasteryzacja hierarchiczna	67
57.1.	Działanie	67
57.1.1.	Single Linkage	67
57.1.2.	Complete Linkage	67
57.2.	Ustalanie liczby klastrow z dendrogramu	68
58.	Ćwiczenie 58 – Wybór metody dla klastrow o nietypowych kształtach	68
58.1.	Poprawne metody:	68
58.2.	Niepoprawne metody:	68

Algorytmiczna Analiza Danych

Ćwiczenia 2

14 października 2025 r.

Adrian Herda

Informatyka Algorytmiczna
Politechnika Wrocławska

1. Zadanie 1

Wyjaśnij, czy dany scenariusz jest związany z problemem klasyfikacji, czy regresji, oraz wskaż, czy bardziej interesuje nas wnioskowanie (ang. inference), czy przewidywanie (ang. prediction). Podaj rozmiar próby n i liczbę predyktorów p

1.1. Podpunkt a) wynagrodzenie prezesa a czynniki firmowe

Typ problemu: problem regresji - wynagrodzenie to zmienna ciągła

Cel: wnioskowanie - chcemy zrozumieć zależności a nie przewidzieć przyszłe zarobki prezesów

Rozmiar próby n : 500 - liczba firm

Liczba predyktorów p : 3 - zysk, liczba pracowników, branża - predyktory do dane które pozwalają na znalezienie korelacji

1.2. Podpunkt b) wprowadzenie nowego produktu na rynek

Typ problemu: problem klasyfikacji - kategoryzujemy produkty na te które odniosły sukces lub porażkę, są dwie klasy

Cel: przewidywanie - chcemy przewidzieć jak produkt poradzi sobie na rynku

Rozmiar próby n : 20 - liczba podobnych produktów

Liczba predyktorów p : 3 - cena, cena bezpośredniej konkurencji, budżet marketingowy

1.3. Podpunkt c) prognozowanie zmian kursu dolara

Typ problemu: problem regresji - procentowe zmiany kursu to wartość liniowa

Cel: przewidywanie - „prognoza” to próba przewidzenia danych w przyszłości

Rozmiar próby n : 52 - liczba tygodni w roku

Liczba predyktorów p : 4 - liczba porównywanych rynków akcji: USA, Wielka Brytania, Niemcy, Japonia

2. Zadanie 2

Praktyczne zastosowania uczenia maszynowego: dla każdego z poniższych punktów zaproponuj dwa niesztafpowe praktyczne zastosowania. Opisz jakie dane są potrzebne w wybranych zastosowaniach, np. jakie cechy (ang. features) mogą zostać użyte jako predyktory, a jakie odpowiedzi, czy potrzebna jest duża liczba obserwacji.

2.1. Klasyfikacja

2.1.1. Przykład 1 - rozpoznawanie rodzajów wina

- Predyktory:
 - gęstość / lepkość
 - zapach
 - kolor
 - smak
- Odpowiedzi
 - rodzaje wina

Potrzebna jest duża ilość obserwacji ze względu na ilość rodzajów wina oraz ze względu na podobieństwo niektórych rodzajów.

2.1.2. Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami

- Predyktory:
 - ton mowy
 - tempo mowy
 - używane wyrażenia
 - głośność
- Odpowiedzi
 - odpowiedzi na pytanie o zadowolenie z obsługi (bardzo pozytywne, pozytywne, neutralne, negatywne, bardzo negatywne)

Potrzebna jest duża ilość danych ponieważ ludzkie emocje są bardzo skomplikowane i często niezrozumiałe nawet dla nas samych. Nawet do setek tysięcy

2.2. Regresja

2.2.1. Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)

- Predyktory:
 - kolor włosów
 - zmarszczki
 - proporcje oczu do głowy (szczególnie u dzieci)
 - kolor skóry
 - przebarwienia
- Odpowiedzi:
 - wiek

Potrzebne może być nawet do dziesiątek tysięcy obserwacji może być potrzebne gdyż fizjologia ludzka jest skomplikowana

2.2.2. Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów

- Predyktory:
 - skład chemiczny
 - gęstość
 - porowatość

- temperatura
- wilgotność
- rodzaj środowiska (gleba, woda, kompost).
- Odpowiedź:
 - czas rozkładu

Potrzebne będą setki eksperymentów laboratoryjnych i terenowych.

2.3. Analiza klastrow

2.3.1. Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)

- Predyktory:
 - tempo
 - tonacja
 - analiza tekstu - używane słowa i wyrażenia
 - głośność
 - użyte instrumenty
 - użyte narzędzia modyfikowania dźwięku
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: muzyka melancholijna, wesoła, skoczna, buntownicza

Setki tysięcy lub nawet miliony utworów będą potrzebne by znaleźć widocznie wyróżniające się klastry.

2.3.2. Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach

- Predyktory:
 - średnia wartość zakupów
 - częstotliwość zakupów
 - najczęściej kupowane i przeglądane oferty
 - ocena satysfakcji klienta
 - lokalizacja klienta (może być nie dokładna, np. region - ciepły czy zimny)
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: klient zainteresowany ciuchami zimowymi / letnimi, wędkarz, sportowiec, kolekcjoner butów, stały klient, klient jednorazowy

Setki tysięcy klientów będą potrzebne by znaleźć wyróżniające się klastry.

3. Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne

Opisz różnice między parametrycznym a nieparametrycznym podejściem do uczenia statystycznego. Jakie są wady i zalety podejścia parametrycznego w porównaniu do podejścia nieparametrycznego?

3.1. Parametryczne

Zakłada pewien rozkład danych, za pomocą skończonej (nie ogromnej) ilości parametrów. Umożliwia stosunkowo łatwą analizę modelu ale sprawia że jest ona tylko przybliżeniem. To podejście jest też mniej elastyczne i jest podatne na błędy związane z biasem.

3.2. Nieparametryczna

Nie wymaga założeń co do rozkładu danych . Model uczy się bardziej elastycznie dopasowując się do obserwacji. Dzięki temu otrzymujemy mniejszy bias ale możliwym jest zbyt dopasować model do danych (ang. overfitting). Podejście to wymaga dużej liczby obserwacji i przez to jest bardziej kosztowne niż podejście parametryczne.

3.3. Zalety i wady

	Uczenie parametryczne	Uczenie nieparametryczne
Zalety	• mały wariancja • łatwość analizy i interpretacji modelu • niski koszt obliczeń	• mały bias • duża elastyczność i dopasowanie do danych • Nie wymaga założeń o danych
Wady	• duży bias • mała elastyczność • słaba moc predykcyjna • wymaga założeń o danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń

4. Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)

4.1. a) odległość euklidesowa dla każdego punktu

1. $\sqrt{0^2 + 3^2 + 0^2} = \sqrt{9} = 3$,
2. $\sqrt{2^2 + 0^2 + 0^2} = \sqrt{4} = 2$,
3. $\sqrt{0^2 + 1^2 + 3^2} = \sqrt{10}$,
4. $\sqrt{0^2 + 1^2 + 2^2} = \sqrt{5}$,
5. $\sqrt{(-1)^2 + 0^2 + 1^2} = \sqrt{2}$,
6. $\sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}$

4.2. b) predykcja dla $K = 1$

Bierzemy najbliższego sąsiada którym jest obserwacja 5 i bierzemy jego odpowiedź → **Green**

4.3. c) predykcja dla $K = 3$

Bierzemy 3 najbliższych sąsiadów którymi są obserwacje 5 → Green, 6 → Red oraz 2 → Red i bierzemy najpopularniejszą odpowiedź wśród tych obserwacji → **Red**

4.4. d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa

Jeśli granica decyzyjna Bayesa jest silnie nieliniowa (czyli prawdziwa granica między klasami jest bardzo złożona), to potrzebujemy bardziej elastycznego modelu, aby tę złożoność uchwycić. Małe wartości K dają klasyfikatorowi KNN większą elastyczność (niższy bias, wyższa wariancja) i pozwalają na odwzorowanie skomplikowanych, lokalnych zależności. Dlatego przy silnie nieliniowej granicy Bayesa zwykle lepiej sprawdzają się małe wartości K . (Przy przeciwnym założeniu — gładkiej granicy — większe K redukuje wariancję i może dać lepsze wyniki).

5. Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych

$$\text{Cov}(X, Y) = 0 \quad (5.1)$$

5.1. a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$

Proof.

$$\begin{aligned} \mathbb{E}(X + Y) &= \sum_x \sum_y (x + y) \Pr(X = x, Y = y) \\ &= \sum_x \sum_y x \cdot \Pr(X = x, Y = y) + \sum_x \sum_y y \cdot \Pr(X = x, Y = y) \\ &= \sum_x x \cdot \left(\sum_y \Pr(X = x, Y = y) \right) + \sum_y y \cdot \left(\sum_x \Pr(X = x, Y = y) \right) \quad (5.2) \\ &= \sum_x x \cdot \Pr(X = x) + \sum_y y \cdot \Pr(Y = y) \\ &= \mathbb{E}(X) + \mathbb{E}(Y) \end{aligned}$$

■

5.2. b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Proof.

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mathbb{E}(X))^2] \wedge (1) \\ &\Downarrow \end{aligned} \quad (5.3)$$

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X + Y - \mathbb{E}(X + Y))^2] \\ &= \mathbb{E}[((X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y)))^2] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2 + (Y - \mathbb{E}(Y))^2 + 2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2] + \mathbb{E}[(Y - \mathbb{E}(Y))^2] + \mathbb{E}[2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \quad (5.4) \\ &= \text{Var}(X) + \text{Var}(Y) + \underbrace{2 \cdot \text{Cov}(X, Y)}_0 \\ &= \text{Var}(X) + \text{Var}(Y) \end{aligned}$$

■

6. Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami

Przypomnij, co to jest estymator oraz co to jest obciążenie (ang. bias) i wariancja estymatora. Podaj przykłady estymatorów obciążonych i nieobciążonych

6.1. Definicje

Estymator - To funkcja mająca za zadanie przybliżyć (wyestymować) wybrany parametr.

$$\theta \approx \hat{\theta}(X_1, X_2, \dots, X_n) \quad (6.5)$$

Bias estymatora - Jest wartość opisująca tendencję estymatora do zawyżania lub zaniżania wartości estymowanej

$$\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta \quad (6.6)$$

- Estymator nazywamy obciążonym gdy $\text{Bias}(\hat{\theta}) \neq 0$
- Estymator nazywamy nieobciążonym gdy $\text{Bias}(\hat{\theta}) = 0 \Rightarrow \mathbb{E}(\hat{\theta}) = \theta$

Wariancja estymatora - służy ocenianiu jak daleko, zazwyczaj, będzie estymator od estymowanej wartości

$$\text{Var}(\hat{\theta}) = \mathbb{E}\left(\left(\mathbb{E}(\hat{\theta}) - \hat{\theta}\right)^2\right) \quad (6.7)$$

MSE - Mean Square Error (ang. Błąd średniokwadratowy) tak samo jak wariancja

$$\text{MSE}(\hat{\theta}) = \mathbb{E}\left(\left(\hat{\theta}(X) - \theta\right)^2\right) \quad (6.8)$$

6.2. Przykłady

6.2.1. Nieobciążony

Typ estymatora	Przykład	Obciążenie
Średnia z próby	$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$	$\mathbb{E}(\hat{\mu}) = \mu \Rightarrow \text{Bias}(\hat{\mu}) = 0$
Wariancja z $n-1$	$\hat{\sigma}_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_{n-1}^2) = \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_{n-1}^2) = 0$

6.2.2. Obciążony

Typ estymatora	Przykład	Obciążenie
Wariancja z n	$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_n^2) = \frac{n-1}{n} \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_n^2) = -\frac{\sigma^2}{n}$
$X \sim \text{Exp}(\lambda)$	MLE $\hat{\lambda} = \frac{1}{\bar{X}}$	$\mathbb{E}(\hat{\lambda}) = \frac{n}{n-1} \Rightarrow \text{Bias}(\hat{\lambda}) = \frac{1}{n-1} \lambda$

7. Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza

Szukamy odpowiedniego modelu dla problemu związanego z uczeniem nadzorowanym. Dla każdego z punktów od (a) do (d), wskaż, czy ogólnie oczekivalibyśmy, że mało „elastyczny” model będzie lepszy czy gorsza od bardziej „elastycznego”. Uzasadnij swoją odpowiedź.

- Rozmiar próby n jest bardzo duży, a liczba predyktorów (and. predictor) p jest mała.
- Liczba predyktorów p jest bardzo duża, a liczba obserwacji n jest mała.
- Zależność między predyktorami a odpowiedzią (and. response) wykazuje wyraźnie nieliniowy charakter.
- Wariancja błędów, tj. $\sigma^2 = \text{Var}(\varepsilon)$, jest bardzo wysoka.

Sformułuj wnioski dotyczące tego, jakie są zalety i wady bardziej elastycznego modelu, w porównaniu z mniej elastycznym? W jakich okolicznościach bardziej elastyczny model może być preferowany? Kiedy preferowany może być mniej elastyczny model?

Przypadek	Elastyczność modelu	Uzasadnienie
a) n - duże, p - małe	Bardziej elastyczny	Elastyczny model może wykorzystać dużą liczbę obserwacji aby dopasować się i dzięki temu obniża bias
b) n - małe p - duże	Mniej elastyczny	Duża liczba predyktorów grozi overfittingiem, należy najpierw dokonać redukcji wymiaru tak aby p było mniejsze od n a następnie wykorzystać mniej elastyczny model aby uzyskać model zwiększyć wydajność na małej ilości danych
c) silna nieliniowość danych	Bardziej elastyczny	Elastyczny model lepiej dopasuje się do danych i lepiej przedstawi nieliniowość, nie uśredniając jej tak jak zrobiłby to model mniej elastyczny
d) Wysoka wariancja szumu	Mniej elastyczny	Mniej elastyczny model uśredni dane i zniweluje w ten sposób wysoką wariancję szumu

7.1. Wnioski

	Model mniej elastyczny	Model bardziej elastyczny
Zalety	• stabilny, z małą wariancją • łatwiejszy do interpretacji • bardziej odporny na szum • sprawdza się lepiej dla małych n względem p	• niski bias • świetny dla dużych n • uchwyci złożone zależności
Wady	• duży bias • słaby przy dużej nieliniowości danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń • kiepski dla małych n • ryzyko overfittingu

Algorytmiczna Analiza Danych

Ćwiczenia 3

17 października 2025 r.

Adrian Herda
Politechnika Wrocławska

8. Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu

$$MSE = \mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \quad (8.9)$$

8.1. Rozwiązanie

1. $\mathbb{E}[\varepsilon] = 0 \Rightarrow \mathbb{E}[\varepsilon]^2 = 0 \Rightarrow \sigma_\varepsilon^2 = \mathbb{E}[\varepsilon^2]$
2. Szum jest niezależny z żadną inną zmienną

Proof.

$$\begin{aligned} \mathbb{E}[(y_0 - \hat{f}(x_0))^2] &= \mathbb{E}[(f(x_0) + \varepsilon - \hat{f}(x_0))^2] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \underbrace{\mathbb{E}[\varepsilon^2]}_{\sigma_\varepsilon^2} + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \sigma_\varepsilon^2 + \underbrace{2(f(x_0) - \mathbb{E}[\hat{f}(x_0)])\mathbb{E}[\varepsilon]}_0 \\ &= \mathbb{E}[f(x_0)^2 + \hat{f}(x_0)^2 - 2f(x_0)\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 + \mathbb{E}[\hat{f}(x_0)^2] - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \underbrace{\mathbb{E}[\hat{f}(x_0)]^2 - \mathbb{E}[\hat{f}(x_0)]^2}_0 + \mathbb{E}[\hat{f}(x_0)^2] + \sigma_\varepsilon^2 \\ &= (f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2 + (\mathbb{E}[\hat{f}(x_0)^2] - \mathbb{E}[\hat{f}(x_0)]^2) + \sigma_\varepsilon^2 \\ &= \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \end{aligned} \quad (8.10)$$


■

8.2. Równowaga bias-variance

W miarę jak model staje się bardziej elastyczny, jego zdolność do uchwycenia złożoności danych rośnie, co prowadzi do zmniejszenia błędu bias. Jednakże, większa elastyczność może również prowadzić do większej wariancji, ponieważ model może zacząć „przeuczać” się na dane treningowe. W rezultacie, istnieje kompromis między bias a wariancją, który należy uwzględnić podczas projektowania modeli.

Optymalny wybór złożoności/regularizacji minimalizuje sumę $\text{Bias}^2 + \text{Var}$.
Składnik ε jest nieredukowalny.

9. Zadanie 9 - Wykresy względem elastyczności modelu



9.1. Wytlumaczenie każdej funkcji

Niebieski - W miarę jak modele stają się bardziej elastyczne i złożone, błąd treningowy maleje, ale z coraz mniejszym zyskiem.

Czerwony - Często obserwujemy kształt litery U w błędzie na zbiorze walidacyjnym. Jest to kombinacja błędu Bias (obserwowanego przy najmniej elastycznym modelu), błędu Variance (wynikającego z przeuczenia najbardziej elastycznych modeli) oraz składnika błędu nieusuwalnego.

Niebieski - Składnik błędu Bias, im bardziej elastyczny model tym lepiej się dopasowuje tym mniejszy jest Bias.

Brązowy - Składnik błędu Variance. Im bardziej elastyczny model tym większe różnice w wynikach na zbiorze treningowym i walidacyjnym.

Czarny - Składnik błędu nieusuwalnego. Niezmienna wartość szumu.

10. Zadanie 10 - Obliczanie wzorów na parametry modelu linowego

10.1. Dane

- n obserwacji: $\{(x_1, y_1), \dots, (x_n, y_n)\}$,
- model linowy: $y_i = \beta_0 + \beta_1 x_i + e_i$

10.2. Cel

Szacujemy β_0, β_1 poprzez minimalizację błędu średniokwadratowego:

$$\text{MSE}(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \quad (10.11)$$

Udowodnij że:

1. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
2. $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

Proof. Różniczkujemy i przyrównujemy do zera:

$$\frac{\partial}{\partial \hat{\beta}_0} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.12)$$

$$\frac{\partial}{\partial \hat{\beta}_1} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.13)$$

Z równania (10.12) mamy:

$$\begin{aligned} \sum_{i=1}^n y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i &= 0 \\ n\hat{\beta}_0 &= \sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned} \quad (10.14)$$

Podstawiając do równania (10.13) mamy:

$$\begin{aligned}
0 &= \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \cdot n\bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\bar{y}\bar{x} - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2\bar{x}x_i + \sum_{i=1}^n \bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n \bar{y}x_i + \sum_{i=1}^n \bar{y}\bar{x} - \sum_{i=1}^n \bar{x}y_i \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) &= \sum_{i=1}^n (x_i y_i - \bar{y}x_i) + (\bar{y}\bar{x} - \bar{x}y_i) \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - \bar{x}^2) &= \sum_{i=1}^n x_i(y_i - \bar{y}) - \bar{x}(y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}
\end{aligned} \tag{10.15}$$

■

10.3. Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$

Proof. Podstawiając $x = \bar{x}$ do równania (10.12) prostej:

$$\begin{aligned}
y &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \\
&= (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} \\
&= \bar{y}
\end{aligned} \tag{10.16}$$

■

11. Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym

$$y_i = \beta_0 + \beta_1 x_i + e_i \tag{11.17}$$

Estymaotry jak w modelu z zadania w sekcji 10.

Oraz niech: $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$

11.1. Błąd systematyczny

$$E[\hat{\beta}_0] = \beta_0 \Rightarrow \text{Bias}(\hat{\beta}_0) = 0 \quad (11.18)$$

$$E[\hat{\beta}_1] = \beta_1 \Rightarrow \text{Bias}(\hat{\beta}_1) = 0 \quad (11.19)$$

11.2. Wariancja

Zmienne e_i dla $i \in \{1, \dots, n\}$ są niezależne

11.2.1. Reprezentacja estymatorów za pomocą szumów

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.20)$$

$$\hat{\beta}_0 = \beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.21)$$

11.2.2. Wariancja estymatorów

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \text{Var}\left(\frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \frac{1}{(S_{xx})^2} \text{Var}\left(\sum_{i=1}^n (x_i - \bar{x})e_i\right) \\ &= \frac{1}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) \\ &= \frac{\sigma^2}{S_{xx}} \end{aligned} \quad (11.22)$$

$$\begin{aligned}
\text{Var}(\hat{\beta}_0) &= \text{Var}\left(\beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i\right) + \text{Var}\left(\bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) - 2 \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n e_i, \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(e_i) + \frac{\bar{x}^2}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) - 2 \frac{\bar{x}}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \text{Var}(e_i) \quad (11.23) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \cdot 0 \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} \\
&= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)
\end{aligned}$$

11.3. Błąd standardowy estymatorów

$$\text{SE}(\hat{\beta}_0) = \sqrt{\text{Var}(\hat{\beta}_0)} = \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} = \sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \quad (11.24)$$

$$\text{SE}(\hat{\beta}_1) = \sqrt{\text{Var}(\hat{\beta}_1)} = \sqrt{\frac{\sigma^2}{S_{xx}}} = \frac{\sigma}{\sqrt{S_{xx}}} \quad (11.25)$$

12. Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny

1. $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$
2. $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$
3. $Z = X + Y$

Udowodnij że $Z \sim \mathcal{N}(\mu_Z, \sigma_Z^2)$

Proof. Funkcje charakterystyczne zmiennych losowych:

$$\varphi_X(t) = \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right), \quad \varphi_Y(t) = \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \quad (12.26)$$

Zmienna losowa Z jest sumą niezależnych zmiennych losowych X i Y, więc jej funkcja charakterystyczna jest iloczynem funkcji charakterystycznych X i Y:

$$\begin{aligned}\varphi_Z(t) &= \varphi_X(t) \cdot \varphi_Y(t) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right) \cdot \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2} + i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i(\mu_X + \mu_Y)t - (\sigma_X^2 + \sigma_Y^2) \frac{t^2}{2}\right) \\&= \exp\left(i\mu_Z t - \sigma_Z^2 \frac{t^2}{2}\right)\end{aligned}\tag{12.27}$$

■

Algorytmiczna Analiza Danych

Ćwiczenia 4

24 października 2025 r.

Adrian Herda
Politechnika Wrocławska

13. Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale

Jako że $e_i \sim \mathcal{N}(0, \sigma^2)$ oraz są niezależne, to zgodnie z własnościami rozkładu normalnego, estymator $\hat{\beta}_1$ również ma rozkład normalny z wartością oczekiwaną równą β_1 oraz wariancją $\text{Var}(\hat{\beta}_1)$.

13.1. Reguła trzech sigm

Reguła trzech sigm mówi, że w rozkładzie normalnym ok. 99.7% masy leży w przedziale $\mathbb{E}[X] \pm 3\sigma_X$ dla każdej zmiennej losowej $X \sim \mathcal{N}(\mathbb{E}[X], \sigma_X)$. Dla $\mathbb{E}[X] \pm 2\sigma_X$ mamy ok. 95%.

To tylko krótkie heurystyczne odwołanie do „regułki 68 – 95 – 99.7” dla rozkładu normalnego ($1\sigma \approx 68\%$, $2\sigma \approx 95\%$, $3\sigma \approx 99.7\%$).

13.2. Ustandaryzowana zmienna

Niech

$$Z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim \mathcal{N}(0, 1) \quad (13.28)$$

Wtedy:

$$\Pr(|\hat{\beta}_1 - \beta_1| \leq 2\sqrt{\text{Var}(\hat{\beta}_1)}) = \Pr(|Z| \leq 2) \quad (13.29)$$

Ze wzoru na gęstość prawdopodobieństwa w standardowym rozkładzie normalnym mamy:

$$\begin{aligned} \Pr(|Z| \leq 2) &= \int_{-2}^2 \varphi(x) dx \\ &= \Phi(2) - \Phi(-2) \\ &= \Phi(2) - (1 - \Phi(2)) \\ &= 2\Phi(2) - 1 \\ &= 0.9545 \end{aligned} \quad (13.30)$$

14. Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami

14.1. Teza

Estymatory:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} \in \mathbb{R}^{k+1} \quad (14.31)$$

Wzór:

$$\hat{\beta} = (X^T X)^{-1} X^T \vec{y} \quad (14.32)$$

gdzie X to macierz danych a $\vec{y}$ to wektor odpowiedzi.

14.2. Dowód

$$y = f(x) + \varepsilon \quad (14.33)$$

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k \quad (14.34)$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (14.35)$$

$$\vec{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad (14.36)$$

$$\vec{y} = X\beta + \varepsilon$$

$\Downarrow$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \beta_0 + \beta_1 x_{11} + \dots + \beta_k x_{1k} + \varepsilon_1 \\ \beta_0 + \beta_1 x_{21} + \dots + \beta_k x_{2k} + \varepsilon_2 \\ \vdots \\ \beta_0 + \beta_1 x_{n1} + \dots + \beta_k x_{nk} + \varepsilon_n \end{pmatrix} \quad (14.37)$$

$$\varepsilon = \vec{y} - \hat{y} \wedge \text{RSS} = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon^T \varepsilon \quad (14.38)$$

$\Downarrow$

$$\text{RSS} = (\vec{y} - \hat{y})^T (\vec{y} - \hat{y})$$

$$\begin{aligned} J(\hat{\beta}) &= (\vec{y} - X\hat{\beta})^T (\vec{y} - X\hat{\beta}) \\ &= (\vec{y}^T - \hat{\beta}^T X^T) (\vec{y} - X\hat{\beta}) \\ &= \vec{y}^T \vec{y} - \vec{y}^T X\hat{\beta} - \hat{\beta}^T X^T \vec{y} + X^T \hat{\beta}^T X\hat{\beta} \\ &= \vec{y}^T \vec{y} - 2\vec{y}^T X\hat{\beta} + \hat{\beta}^T X^T X\hat{\beta} \end{aligned} \quad (14.39)$$

Chcemy najmniejszą wartość RSS. Liczymy pochodną cząstkową po $\hat{\beta}$ i przyrównujemy do zera:

$$\begin{aligned}\frac{\partial J}{\partial \hat{\beta}} &= 2X^T X \hat{\beta} - 2X^T \vec{y} = 0 \\ X^T X \hat{\beta} &= X^T \vec{y} \\ \hat{\beta} &= (X^T X)^{-1} X^T \vec{y}\end{aligned}\tag{14.40}$$

Algorytmiczna Analiza Danych

Ćwiczenia 5

7 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

15. Zadanie 15 - Korelacja

$$\begin{aligned}
 \text{TSS} &= \sum_{i=1}^n (Y_i - \bar{Y}_i)^2 = S_{yy} \\
 &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y}_i)^2 \\
 &= \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{RSS}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}_{\text{ESS}} - 2 \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}_i)}_{\text{Własność ortogonalności reszt} \rightarrow 0} \\
 &= \text{RSS} + \text{ESS}
 \end{aligned} \tag{15.41}$$

$$\begin{aligned}
 \hat{\beta}_0 &= \bar{Y}_i - \hat{\beta}_1 \bar{X} \\
 \hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\
 &= (\bar{Y}_i - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 X_i \\
 &= \bar{Y}_i + \hat{\beta}_1 (X_i - \bar{X}) \\
 \hat{Y}_i - \bar{Y}_i &= \hat{\beta}_1 (X_i - \bar{X})
 \end{aligned} \tag{15.42}$$

$$\text{ESS} = \hat{\beta}_1^2 S_{yy}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$\begin{aligned}
 R^2 &= 1 - \frac{\text{RSS}}{\text{TSS}} \\
 &= \frac{\text{RSS} + \text{ESS} - \text{RSS}}{\text{TSS}} \\
 &= \frac{\text{ESS}}{\text{TSS}} \\
 &= \left(\frac{S_{xy}}{S_{xx}} \right)^2 \frac{S_{xx}}{S_{yy}} \\
 &= \frac{S_{xy}^2}{S_{xx} S_{yy}} \\
 &= \text{Corr}(X, Y)^2
 \end{aligned} \tag{15.43}$$

■

16. Zadanie 16 - t-statystyka i p-wartość

Wyjaśnij czym jest t-statystyka i w jaki sposób możemy jej użyć w kontekście regresji liniowej. Czym jest p-wartość?

16.1. t-statystyka

t-statystyka to miara używana w statystyce do oceny istotności współczynników regresji w modelu regresji liniowej. Określa, jak wiele standardowych błędów odchyła się estymowany współczynnik od wartości zerowej (hipoteza zerowa). Wzór na t-statystykę dla współczynnika regresji $\hat{\beta}_j$ jest następujący:

$$t_j = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \quad (16.44)$$

gdzie $\text{SE}(\hat{\beta}_j)$ to standardowy błąd estymatora współczynnika regresji $\hat{\beta}_j$.

16.2. p-wartość

p-wartość to prawdopodobieństwo uzyskania wyników co najmniej tak ekstremalnych jak obserwowane, zakładając, że hipoteza zerowa jest prawdziwa. W kontekście regresji liniowej, p-wartość jest używana do oceny istotności statystycznej współczynników regresji. Niska p-wartość (zazwyczaj poniżej 0.05) sugeruje odrzucenie hipotezy zerowej, co oznacza, że istnieje statystycznie istotny związek między zmienną niezależną a zmienną zależną.

17. Zadanie 17 - Odległość Mahalanobisa

Wyjaśnij czym jest odległość Mahalanobisa i jaki jest jej związek z leverage statistic.

17.1. odpowiedź

Odległość Mahalanobisa to miara odległości między punktem a rozkładem prawdopodobieństwa. W przeciwieństwie do standardowej odległości euklidesowej, odległość Mahalanobisa uwzględnia korelacje między zmiennymi i skalę danych. Jest definiowana jako:

$$D_{M(x)} = \sqrt{(x - \mu)^T S^{-1} (x - \mu)} \quad (17.45)$$

gdzie μ to wektor średnich zmiennych, a S to macierz kowariancji.

Odległość Mahalanobisa jest szczególnie użyteczna w kontekście analizy regresji, ponieważ pozwala na identyfikację obserwacji, które są nietypowe lub odstające w kontekście całego zbioru danych. Wartości odległości Mahalanobisa mogą być używane do obliczania statystyki leverage, która mierzy wpływ danej obserwacji na dopasowanie modelu regresji. Obserwacje o wysokiej odległości Mahalanobisa mogą mieć duży wpływ na estymację współczynników regresji i mogą być potencjalnymi punktami odstającymi.

18. Zadanie 18 - Double descent

Na podstawie materiału wideo i rozdziału 10.8 w książce ISL opisz zjawisko double descent

18.1. Odpowiedź

- W fazie podparametryzowanej („under-parameterized”) - model nie ma wystarczającej mocy, by dobrze dopasować dane $\rightarrow$ testowy błąd jest stosunkowo wysoki, ale spada wraz ze wzrostem złożoności.
- Następnie w okolicy punktu, kiedy liczba parametrów $\approx$ liczba próbek (lub model może dokładnie dopasować dane) - następuje wzrost błędu testowego (szczyt) z powodu dużej wariancji, niestabilności.
- Potem, w nadparametryzowanej („over-parameterized”) fazie - mimo że model może „przeuczyć” dane, okazuje się, że zwiększanie złożoności dalej prowadzi do spadku błędu testowego. Model bardzo duży generalizuje lepiej niż średni.

Algorytmiczna Analiza Danych

Ćwiczenia 6

14 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

19. Zadanie 19

Przypomnij, czym jest estymator największej wiarygodności. Przedstaw i wyjaśnij własności takiego estymatora (w szczególności asymptotyczną nieobciążoność i efektywność).

19.1. Odpowiedź

19.1.1. Definicja

Założmy, że mamy próbę losową $X_1, \dots, X_n$ pochodzącą z rozkładu o funkcji gęstości (lub masie prawdopodobieństwa) $f(x; \theta)$, gdzie θ to nieznaną parametr populacji (np. średnia, wariancja, parametr Bernoulliego itd.).

Funkcja wiarygodności (likelihood function) określa prawdopodobieństwo zaobserwowania danej próby przy danym parametrze θ :

$$L(\theta) = f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta) \quad (19.46)$$

albo w postaci logarytmicznej (częściej stosowanej dla wygody obliczeń):

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta) \quad (19.47)$$

Estymator największej wiarygodności (ENW) to wartość $\hat{\theta}$, która maksymalizuje funkcję wiarygodności:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} L(\theta) \quad (19.48)$$

lub równoważnie:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} \ell(\theta) \quad (19.49)$$

19.1.2. Własności

Spójność - Gdy liczba obserwacji $n \rightarrow \infty$ to estymator największej wiarygodności zbliża się do prawdziwej wartości parametru θ

$$\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta \quad (19.50)$$

Efektywność - Przy pewnych warunkach estymator największej wiarygodności zbliża się, w dystrybucji, do rozkładu normalnego:

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \sim \mathcal{N}(0, \mathcal{I}^{-1}) \quad (19.51)$$

gdzie

$$\mathcal{J}_{jk} = \mathbb{E} \left[-\frac{\partial^2 f_{\theta_0}(X_t)}{\partial \theta_j \partial \theta_k} \right] \quad (19.52)$$

to macierz informacji Fishera.

20. Zadanie 20

Założmy, że mamy n obserwacji $x_1, \dots, x_n$ pochodzących z rozkładu normalnego zmiennej losowej $X \sim \mathcal{N}(\mu, \sigma^2)$. Wyprowadź estymator największej wiarygodności dla parametru μ

20.1. Rozwiązanie

$$f(x_i; \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (20.53)$$

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(x_i; \mu) \\ \ell(\mu) &= \sum_{i=1}^n \ln f(x_i; \mu) \\ &= \sum_{i=1}^n \ln \left((2\pi\sigma^2)^{-\frac{1}{2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right) \\ &= \sum_{i=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (20.54)$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\mu} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\mu} &= \frac{d}{d\mu} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right) \\
&= -\frac{1}{2\sigma^2} \frac{d}{d\mu} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n \frac{d}{d\mu} (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n (-2x_i + 2\mu) \\
&= -\frac{1}{\sigma^2} \sum_{i=1}^n (-x_i + \mu) \\
&= \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) \\
&= \sum_{i=1}^n (\mu - x_i) \\
&= n\mu - \sum_{i=1}^n x_i \\
n\mu &= \sum_{i=1}^n x_i \\
\hat{\mu}_{\text{MLE}} &= \frac{1}{n} \sum_{i=1}^n x_i
\end{aligned} \tag{20.55}$$

21. Zadanie 21

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu wykładniczego z nieznanym parametrem λ . Wyprowadź estymator największej wiarygodności dla parametru λ . Wskaż intuicyjnie, dlaczego ten estymator ma sens.

21.1. Rozwiązanie

$$f(x; \lambda) = \lambda e^{-\lambda x} \tag{21.56}$$

$$\begin{aligned}
L(\lambda) &= \prod_{i=1}^n f(x_i; \lambda) \\
&= \lambda^n \exp(-\lambda n x_i) \\
&= \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right) \\
\ell(\lambda) &= n \ln \lambda - \lambda \sum_{i=1}^n x_i
\end{aligned} \tag{21.57}$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\lambda} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
0 &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
\frac{n}{\lambda} &= \sum_{i=1}^n x_i \\
\hat{\lambda}_{\text{MLE}} &= \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}
\end{aligned} \tag{21.58}$$

22. Zadanie 22

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu jednostajnego na przedziale $[0, \theta]$, gdzie θ jest nieznanym parametrem. Wyprowadź estymator największej wiarygodności dla parametru θ . Wskaż intuicyjnie, dlaczego ten estymator ma sens. Czy ten estymator jest nieobciążony?

22.1. Rozwiązanie

$$f(x; \theta) = \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x) \tag{22.59}$$

$$\begin{aligned}
L(\theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) \\
&= \theta^{-n} \mathbf{1}_{\{\forall_i, x_i \leq \theta\}} \\
&= \theta^{-n} \mathbf{1}_{\{\max_i x_i \leq \theta\}} \\
&= \begin{cases} 0, & \max_i x_i > \theta \\ \theta^{-n}, & \max_i x_i \leq \theta, \text{ funkcja malejąca} \end{cases}
\end{aligned} \tag{22.60}$$

Chcąc osiągnąć największe możliwe $L(\theta)$ musimy zminimalizować θ tak aby nadal $\forall_i x_i \leq \theta \Rightarrow \max_i x_i \leq \theta$. Więc największa wartość $L(\theta)$ jest osiągnięta dla:

$$\hat{\theta}_{\text{MLE}} = \max_i x_i = x_{(n)} \tag{22.61}$$

22.2. Czy estymator nieobciążony?

Nie, estymator jest obciążony.

Proof. Rozkład $x_{(n)}$ (maksimum) dla $x \in [0, \theta]$:

$$F_{x_{(n)}}(x) = P(x_{(n)} < x) = \left(\frac{x}{\theta}\right)^n \tag{22.62}$$

$$\begin{aligned}
\mathbb{E}[\hat{\theta}_{\text{MLE}}] &= \mathbb{E}[x_{(n)}] = \int_0^\theta x dF_{x_{(n)}}(x) \\
&= \int_0^\theta x \cdot n \frac{x^{n-1}}{\theta^n} dx \\
&= \frac{n}{\theta^n} \int_0^\theta x^n dx \\
&= \frac{n}{\theta^n} \left(\frac{x^{n+1}}{n+1} \right) \Big|_0^\theta \\
&= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \\
&= \frac{n}{n+1} \theta \neq \theta
\end{aligned} \tag{22.63}$$

$$\begin{aligned}
\text{Bias}(\hat{\theta}_{\text{MLE}}) &= \mathbb{E}[\hat{\theta}_{\text{MLE}}] - \theta \\
&= \frac{n}{n+1} \theta - \theta \\
&= -\frac{1}{n+1} \theta
\end{aligned} \tag{22.64}$$

■

23. Zadanie 23

23.1. a) $p = 1$

Ułamek próby który użyjemy $\frac{0.10}{1} = 0.1$

23.2. b) $p = 2$

Teraz chcemy wykorzystać kwadrat o długości $X_1 = 0.1$ oraz szerokości $X_2 = 0.1$

Ułamek próby który użyjemy: $\frac{0.1 \cdot 0.1}{1} = 0.01$

23.3. c) $p = 100$

Teraz chcemy wykorzystać hiperkostkę o długości boku 0.1

Ułamek próby który użyjemy: $\frac{0.1^{100}}{1} = 10^{-100} \approx 0$

23.4. d)

Im większe p tym mniej punktów leży w odległości 0.1 od testowego, więc metody oparte na lokalności się trochę psują, mając mało danych do porządnego przewidywania. Rośnie wariancja a żeby ją kontrolować musimy zwiększać K lub zwiększać okno szukania co psuje założenie lokalności.

23.5. e)**23.5.1. Wzór**

Niech w to długość krawędzi hiperkostki wewnętrznej, zawierającej $\approx 10\%$ obserwacji treningowych

$$\begin{aligned} 0.1 &= w^p \\ w &= \sqrt[p]{0.1} \end{aligned} \tag{23.65}$$

23.5.2. Wyniki

p	w
1	0.1
2	$\sqrt{0.1} \approx 0.31$
100	$\sqrt[100]{0.1} \approx 0.977$

Prawie cała objętość hiperkostki leży w jej brzegach. Nie da się być lokalnym i mieć wystarczająco dużo sąsiadów $\rightarrow$ Klątwa wielowymiarowości

Algorytmiczna Analiza Danych

Ćwiczenia 7

21 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

24. Zadanie 24 – Ocena modelu w problemie klasyfikacji

24.1. Oznaczenia

Stosujemy następujące oznaczenia w macierzy pomyłek:

- **TP (True Positive)** - Prawdziwie pozytywne.
- **TN (True Negative)** - Prawdziwie negatywne.
- **FP (False Positive)** - Fałszywie pozytywne (błąd I rodzaju).
- **FN (False Negative)** - Fałszywie negatywne (błąd II rodzaju).

24.2. a) Metryki: Accuracy, Precision, Recall oraz F1

24.2.1. Definicje metryk

1. **Accuracy (Dokładność)** - Określa, jak często model ma rację.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (24.66)$$

2. **Precision (Precyzja)** - Określa wiarygodność pozytywnej predykcji (ile z przewidzianych „jedynek” to faktycznie „jedynek”).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (24.67)$$

3. **Recall (Czułość)** - Określa zdolność modelu do wykrywania klasy pozytywnej (ile faktycznych „jedynek” udało się znaleźć).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (24.68)$$

4. **F1-Score** - Średnia harmoniczna precyzji i czułości. Jest lepszą miarą niż Accuracy przy niebalansowanych danych.

$$F1 = 2 \cdot \left(\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \right) \quad (24.69)$$

24.2.2. Przykład

Testujemy wykrywacz choroby (10 chorych, 90 zdrowych). Model wykrył 8 chorych, ale też błędnie wskazał 10 zdrowych jako chorych.

- $\text{Accuracy} = \frac{8+80}{100} = 0.88$
- $\text{Precision} = \frac{8}{8+10} \approx 0.44$

- $\text{Recall} = \frac{8}{8+2} = 0.80$

24.3. b) Różnica wersji *micro* od *macro*

- **Macro Average** - Liczymy metrykę (np. F1) dla każdej klasy osobno, a potem wyciągamy z nich średnią. Traktuje każdą klasę równoważnie (dobre do wykrywania błędów w rzadkich klasach).
- **Micro Average** - Sumujemy wszystkie TP, FP, FN globalnie i liczymy metrykę raz. W klasyfikacji wieloklasowej (single-label) Micro-F1 jest równoważne Accuracy. Faworyzuje klasy większościowe.

Przykład: Klasa A (100 próbek, model idealny), Klasa B (10 próbek, model tragiczny).

- **Micro** będzie wysokie (zdominowane przez A).
- **Macro** będzie niskie (uwidoczni błąd na B).

24.4. c) Potoczne rozumienie a definicja

- **Accuracy** - Potocznie „jakość”. W *ML* może być mylące - model przewidujący zawsze brak rzadkiego zdarzenia (np. wygrana w lotto) ma 99.9% accuracy, a jest bezużyteczny.
- **Precision** - Potocznie kojarzy się z „dokładnością pomiaru”. W *ML* to „brak fałszywych alarmów”.

25. Zadanie 25 – Naiwny Klasyfikator Bayesa

25.1. Definicja

Naiwny klasyfikator Bayesa - model probabilistyczny oparty na twierdzeniu Bayesa, który zakłada **warunkową niezależność** cech (x_i) od siebie przy znanej klasie (C_k).

Warto go stosować, gdy mamy mało danych (szybka zbieżność), bardzo wysoki wymiar danych (np. tekst) lub potrzebujemy szybkiego modelu bazowego.

25.2. Dowód wzoru

Theorem 25.1.

$$\Pr(C_k \mid x_1, \dots, x_n) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.70)$$

Proof. Wychodzimy z twierdzenia Bayesa:

$$\Pr(C_k \mid x) = \frac{\Pr(x \mid C_k) \Pr(C_k)}{\Pr(x)} \quad (25.71)$$

Gdzie $x = (x_1, \dots, x_n)$. W liczniku mamy prawdopodobieństwo łączne $\Pr(x_1, \dots, x_n \mid C_k)$. Stosujemy „naiwne” założenie o niezależności cech:

$$\Pr(x_1, \dots, x_n \mid C_k) \approx \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.72)$$

Podstawiając do licznika:

$$\Pr(C_k | x) = \frac{\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k)}{\Pr(x)} \quad (25.73)$$

$$\Pr(C_k | x) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \quad (25.74)$$

Mianownik $\Pr(x)$ jest sumą po wszystkich klasach (z prawa całkowitego prawdopodobieństwa):

$$\Pr(x) = \sum_k \Pr(x | C_k) \Pr(C_k) = \sum_k \left(\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \right) \quad (25.75)$$

■

26. Zadanie 26 – Klasyfikacja Spam vs Nie-spam

Dane:

- $N = 1000$ e-maili.
- Klasa C_1 (Spam): 100 e-maili (wszystkie $x_1 = 1, x_2 = 1$).
- Klasa C_2 (Nie-spam): 900 e-maili (450: $x_1 = 1, x_2 = 0$ oraz 450: $x_1 = 0, x_2 = 1$).

Szukamy predykcji dla nowego e-maila $x = (x_1 = 1, x_2 = 1)$.

1. Prawdopodobieństwa a priori (Priors):

$$\Pr(C_1) = \frac{100}{1000} = 0.1 \quad (26.76)$$

$$\Pr(C_2) = \frac{900}{1000} = 0.9 \quad (26.77)$$

2. Prawdopodobieństwa warunkowe (Likelihoods):

- Dla C_1 (Spam):
 - $\Pr(x_1 = 1 | C_1) = \frac{100}{100} = 1$
 - $\Pr(x_2 = 1 | C_1) = \frac{100}{100} = 1$
- Dla C_2 (Nie-spam):
 - $\Pr(x_1 = 1 | C_2) = \frac{450}{900} = 0.5$
 - $\Pr(x_2 = 1 | C_2) = \frac{450}{900} = 0.5$

3. Obliczenia dla nowego e-maila (licznik wzoru Bayesa):

- Dla Spam:

$$L(C_1) = \Pr(C_1) \cdot \Pr(x_1 = 1 | C_1) \cdot \Pr(x_2 = 1 | C_1) = 0.1 \cdot 1 \cdot 1 = 0.1 \quad (26.78)$$

- Dla Nie-spam:

$$L(C_2) = \Pr(C_2) \cdot \Pr(x_1 = 1 | C_2) \cdot \Pr(x_2 = 1 | C_2) = 0.9 \cdot 0.5 \cdot 0.5 = 0.225 \quad (26.79)$$

4. Normalizacja i wynik:

$$\text{Evidence } \Pr(x) = 1 \cdot 1 \cdot 0.1 + 0.5 \cdot 0.5 \cdot 0.9 = 0.1 + 0.225 = 0.325.$$

$$\Pr(C_1 | x) = \frac{0.1}{0.325} \approx 0.308 \quad (26.80)$$

$$\Pr(C_2 | x) = \frac{0.225}{0.325} \approx 0.692 \quad (26.81)$$

Odp: Prawdopodobieństwo, że to Spam wynosi ok. 30.8%, a że Nie-spam ok. 69.2%.

27. Zadanie 27 – Regresja Logistyczna

27.1. a) Dlaczego nie regresja liniowa?

- Predykcje mogą wykraczać poza przedział $[0, 1]$.
- Zależność rzadko jest liniowa (często przyjmuje kształt litery S).
- Niespełnione założenie o stałej wariancji reszt (heteroskedastyczność).

27.2. b) Obliczenie szans (Odds)

Dane: $p = 0.75$.

$$\text{Odds} = \frac{p}{1-p} = \frac{0.75}{1-0.75} = \frac{0.75}{0.25} = 3 \quad (27.82)$$

Szanse wynoszą 3 do 1.

27.3. c) Dowód równoważności z Log-Odds

Model:

$$\Pr(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (27.83)$$

Oznaczmy $z = \beta_0 + \beta_1 X$. Wtedy $p = \frac{e^z}{1+e^z}$.

1. Obliczamy $1 - p$:

$$1 - p = 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z - e^z}{1 + e^z} = \frac{1}{1 + e^z} \quad (27.84)$$

2. Dzielimy p przez $1 - p$:

$$\frac{p}{1-p} = \frac{\frac{e^z}{1+e^z}}{\frac{1}{1+e^z}} = \left(\frac{e^z}{1+e^z} \right) \cdot \left(\frac{1+e^z}{1} \right) = e^z \quad (27.85)$$

3. Logarytmujemy obustronnie:

$$\ln\left(\frac{p}{1-p}\right) = \ln(e^z) = z \quad (27.86)$$

Podstawiając z :

$$\ln\left(\frac{\Pr(X)}{1 - \Pr(X)}\right) = \beta_0 + \beta_1 X \quad (27.87)$$

27.4. d) Zależność sigma a logit

Funkcja logistyczna $\sigma(x)$ i funkcja logit $l(p)$ są **funkcjami odwrotnymi**.

$$\sigma(x) = \frac{e^x}{1 + e^x} \quad (\text{odwzorowuje } \mathbb{R} \rightarrow (0, 1)) \quad (27.88)$$

$$l(p) = \ln\left(\frac{p}{1-p}\right) \quad (\text{odwzorowuje } (0, 1) \rightarrow \mathbb{R}) \quad (27.89)$$

Zachodzi:

$$l(\sigma(x)) = x \quad (27.90)$$

oraz

$$\sigma(l(p)) = p \quad (27.91)$$

.

Algorytmiczna Analiza Danych

Ćwiczenia 8

28 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

28. Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych

Aby uzyskać model dla K klas, wykorzystując $K - 1$ modeli binarnej regresji logistycznej, stosujemy podejście oparte na **klasie referencyjnej** (bazowej). Załóżmy, że klasa K jest naszą klasą bazową.

Budujemy $K - 1$ klasyfikatorów binarnych, gdzie k -ty model (dla $k = 1, \dots, K - 1$) uczy się przewidywać logarytm szansy (log-odds) bycia w klasie k względem klasy K :

$$\ln\left(\frac{\Pr(Y = k)}{\Pr(Y = K)}\right) = \beta_k^T x \quad (28.92)$$

Gdzie β_k to wektor wag dla klasy k . Przekształcając to równanie, otrzymujemy:

$$P(Y = k) = P(Y = K) \cdot e^{\beta_k^T x} \quad (28.93)$$

Ponieważ suma prawdopodobieństw wszystkich klas musi wynosić 1 ($\sum_{j=1}^K \Pr(Y = j) = 1$), możemy wyznaczyć $\Pr(Y = K)$:

$$\begin{aligned} \Pr(Y = K) + \sum_{k=1}^{K-1} \Pr(Y = K) \cdot e^{\beta_k^T x} &= 1 \\ \Pr(Y = K) \left(1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}\right) &= 1 \\ \Pr(Y = K) &= \frac{1}{1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}} \end{aligned} \quad (28.94)$$

Dla dowolnego $k < K$ prawdopodobieństwo wynosi zatem:

$$\Pr(Y = k) = \frac{e^{\beta_k^T x}}{1 + \sum_{j=1}^{K-1} e^{\beta_j^T x}} \quad (28.95)$$

Jest to równoważne funkcji Softmax, gdzie dla klasy referencyjnej przyjmujemy wektor wag $\beta_K = 0$ (wektor zerowy).

29. Ćwiczenie 29 – Funkcja Softmax

29.1. Wzór i intuicja

Wzór funkcji Softmax dla j -tego elementu wektora z :

$$p_j(z) = \frac{e^{z_j}}{\sum_{k=1}^n e^{z_k}} \quad (29.96)$$

29.1.1. Intuicja

Funkcja ta realizuje dwa cele:

1. **Exponentiation** (e^x) - Przekształca logity (które mogą być ujemne) na wartości dodatnie oraz wzmacnia różnice między wartościami (duże wartości stają się znacznie większe od małych).
2. **Normalizacja** - Dzielenie przez sumę sprawia, że wszystkie wartości sumują się do 1, tworząc poprawny rozkład prawdopodobieństwa.

29.1.2. Dlaczego „ciągły argmax”?

Zwykła funkcja `argmax` zwraca indeks największej wartości (np. wektor one-hot). Jest ona jednak nieciągła i nieróżniczkowalna. Softmax jest jej gładkim przybliżeniem. Jeśli wprowadzimy parametr temperatury T ($\frac{z_j}{T}$) i $T \rightarrow 0$, rozkład softmax dąży do rozkładu punktowego (1 dla maksimum, 0 dla reszty), zachowując jednak różniczkowalność, co jest kluczowe dla uczenia sieci metodą spadku gradientu.

29.2. Klasyfikacja wieloetykietowa (Multi-label)

Gdy obserwacja może należeć do kilku klas jednocześnie, Softmax nie jest odpowiedni, ponieważ wymusza sumowanie się prawdopodobieństw do 1 (konkurencja między klasami).

Rozwiązanie: Stosuje się funkcję **Sigmoid** ($\sigma(z) = \frac{1}{1+e^{-z}}$) niezależnie dla każdego wyjścia (dla każdej klasy). Traktujemy to jako n niezależnych problemów klasyfikacji binarnej („czy należy do klasy A?”, „czy należy do klasy B?” itd.). Funkcją kosztu jest wtedy suma binarnych entropii krzyżowych.

30. Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax

Mamy wektor $p(z)$ o składowych $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$.

30.1. Macierz Jacobiego

Macierz Jacobiego J ma wymiary $n \times n$, a jej element na pozycji (j, k) to pochodna cząstkowa j -tego wyjścia po k -tym wejściu:

$$J_{jk} = \frac{\partial p_j}{\partial z_k} \quad (30.97)$$

Wzór ogólny (z wykorzystaniem delty Kroneckera δ_{jk}):

$$\frac{\partial p_j}{\partial z_k} = p_j(\delta_{jk} - p_k) \quad (30.98)$$

Co w rozwinięciu daje:

- Na przekątnej ($j = k$): $p_j(1 - p_j)$
- Poza przekątną ($j \neq k$): $-p_j p_k$

30.2. Analiza znaków pochodnych

- **Gdy $j = k$:** $\frac{\partial p_j}{\partial z_k} = p_j(1 - p_j)$. Ponieważ p_j jest prawdopodobieństwem z funkcji Softmax (dla skończonych z), to $0 < p_j < 1$. Zatem iloczyn dwóch liczb dodatnich jest **dodatni**.
- **Gdy $j \neq k$:** $\frac{\partial p_j}{\partial z_k} = -p_j p_k$. Ponieważ $p_j > 0$ i $p_k > 0$, to ich iloczyn ze znakiem minus jest **ujemny**.

Konsekwencje: Zwiększenie wartości logitu z_k (sygnału dla klasy k) powoduje wzrost prawdopodobieństwa tej klasy (p_k), ale jednocześnie **obniżenie** prawdopodobieństw wszystkich pozostałych klas (p_j). Potwierdza to konkurencyjną naturę Softmaxu - klasy „walczą” o zasoby (sumę równą 1).

31. Ćwiczenie 31 – Gradient Entropii Krzyżowej

Chcemy policzyć $\frac{\partial L}{\partial z_i}$, gdzie $L = -\sum_k y_k \log(p_{k(z)})$.

Korzystając z reguły łańcuchowej (dla wielu zmiennych):

$$\frac{\partial L}{\partial z_i} = \sum_{k=1}^n \frac{\partial L}{\partial p_k} \cdot \frac{\partial p_k}{\partial z_i} \quad (31.99)$$

1. Pochodna L po p_k :

$$\frac{\partial}{\partial p_k} \left(-\sum_j y_j \log(p_j) \right) = -\frac{y_k}{p_k} \quad (31.100)$$

2. Pochodna Softmaxu (z Ćwiczenia 30):

$$\frac{\partial p_k}{\partial z_i} = p_k(\delta_{ki} - p_i) \quad (31.101)$$

Podstawiając:

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= \sum_k \left(-\frac{y_k}{p_k} \right) \cdot p_k(\delta_{ki} - p_i) \\ &= -\sum_k y_k(\delta_{ki} - p_i) \\ &= -\left(y_i(1 - p_i) + \sum_{k \neq i} y_k(-p_i) \right) \\ &= -\left(y_i - y_i p_i - \sum_{k \neq i} y_k p_i \right) \\ &= -\left(y_i - p_i \underbrace{\sum_k y_k}_{=1} \right) \\ &= p_i - y_i \end{aligned} \quad (31.102)$$

Wynik:

$$\frac{\partial L}{\partial z_i} = p_i - y_i \quad (31.103)$$

Wykorzystanie: Wzór $p_i - y_i$ reprezentuje **błąd predykcji** (różnicę między przewidywanym prawdopodobieństwem a rzeczywistą etykietą). Jest to sygnał błędu przekazywany wstecz (backpropagation) do aktualizacji wag modelu.

- Jeśli $y_i = 1$, a model dał $p_i = 0.8$, gradient wynosi -0.2 (dążymy do zwiększenia z_i).
- Jego prostota obliczeniowa sprawia, że połączenie Softmax + Cross-Entropy jest standardem w sieciach neuronowych.

32. Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)

Wykres pudełkowy służy do wizualizacji rozkładu cechy statystycznej i składa się z następujących elementów:

1. Pudełko (Box):

- Dolna krawędź pudełka wyznacza *pierwszy kwartył* ($Q1$) (25. centyl).
- Górna krawędź wyznacza *trzeci kwartył* ($Q3$) (75. centyl).
- Wysokość pudełka to *rozstęp międzykwartyłowy* ($IQR = Q3 - Q1$), w którym znajduje się 50% środkowych obserwacji.

2. Linia wewnątrz pudełka:

- Oznacza *medianę* ($Q2$), czyli wartość środkową. Jej położenie wskazuje na skośność rozkładu (np. jeśli jest bliżej dołu, rozkład może być prawoskośny).

3. Wąsy (Whiskers):

- Linie wychodzące z pudełka w górę i w dół.
- Zazwyczaj sięgają do ostatniego punktu danych mieszczącego się w przedziale $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$.

4. Punkty poza wąsami (Outliers):

- Obserwacje odstające, które wykraczają poza zasięg wąsów. Są zaznaczane jako pojedyncze kropki lub gwiazdki.

Algorytmiczna Analiza Danych

Ćwiczenia 9

5 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

33. Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa

W problemie klasyfikacji wieloklasowej (gdzie mamy K klas), zmienną celu dla i -tej obserwacji możemy zapisać jako wektor one-hot $\mathbf{y}^{(i)} = [y_1^{(i)}, \dots, y_K^{(i)}]$, gdzie $y_k^{(i)} = 1$ jeśli obserwacja należy do klasy k , a 0 w przeciwnym razie. Model przewiduje prawdopodobieństwa $\hat{y}_k^{(i)}$ (np. za pomocą funkcji Softmax).

Funkcja wiarygodności (Likelihood) dla N niezależnych obserwacji ma postać:

$$L(\theta) = \prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \quad (33.104)$$

Aby ułatwić optymalizację, stosujemy logarytm naturalny wiarygodności (Log-Likelihood):

$$\ln L(\theta) = \ln \left(\prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \right) = \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.105)$$

Maksymalizacja funkcji wiarygodności jest równoważna minimalizacji jej odwrotności ze znakiem minus (negative log-likelihood):

$$\text{NLL} = - \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.106)$$

Powyższy wzór to nic innego jak suma **entropii krzyżowych** pomiędzy rozkładem rzeczywistym y a przewidywanym $\hat{y}$. Zatem maksymalizacja wiarygodności w klasyfikacji wieloklasowej jest tożsama z minimalizacją entropii krzyżowej.

34. Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL

Niech P będzie prawdziwym rozkładem prawdopodobieństwa, a Q rozkładem aproksymującym (modelowanym). Zdefiniujmy miary dla zmiennych dyskretnych:

1. **Entropia Shannona ($H(P)$)** - Miara niepewności lub ilości informacji zawartej w rozkładzie P .

$$H(P) = - \sum_x P(x) \log P(x) \quad (34.107)$$

2. **Entropia krzyżowa ($H(P, Q)$)** - Średnia liczba bitów potrzebna do zakodowania zdarzeń z rozkładu P przy użyciu kodowania optymalnego dla rozkładu Q .

$$H(P, Q) = - \sum_x P(x) \log Q(x) \quad (34.108)$$

3. **Dywergencja Kullbacka-Leiblera ($D_{\text{KL}(P \parallel Q)}$)** - Miara „odległości” (straty informacji) przy zastąpieniu prawdziwego rozkładu P rozkładem Q .

$$D_{\text{KL}(P \parallel Q)} = \sum_x P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (34.109)$$

34.1. Związek między miarami

Rozpisując wzór na dywergencję KL:

$$\begin{aligned} D_{\text{KL}(P \parallel Q)} &= \sum_x P(x) (\log P(x) - \log Q(x)) \\ &= \sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned} \quad (34.110)$$

Stąd otrzymujemy kluczową zależność:

$$H(P, Q) = H(P) + D_{\text{KL}(P \parallel Q)} \quad (34.111)$$

Interpretacja: Entropia krzyżowa to entropia własna danych plus „kara” (dywergencja KL) za niedopasowanie modelu Q do rzeczywistości P .

35. Ćwiczenie 35 – Entropia różniczkowa

35.1. Definicja

Dla zmiennej losowej ciągłej X o gęstości prawdopodobieństwa $f(x)$, entropia różniczkowa wynosi:

$$h(X) = - \int_{-\infty}^{\infty} f(x) \log f(x) dx \quad (35.112)$$

35.2. Ujemna wartość entropii różniczkowej

W przeciwieństwie do przypadku dyskretnego, $h(X)$ może być ujemna, ponieważ $f(x)$ może przyjmować wartości > 1 . **Przykład:** Rozkład jednostajny na przedziale $[0, a]$, gdzie $a < 1$ (np. $a = 0.5$).

$$f(x) = \begin{cases} \frac{1}{a} & \text{dla } x \in [0, a] \\ 0 & \text{w p.p.} \end{cases} \quad (35.113)$$

$$h(X) = - \int_0^a \frac{1}{a} \log \left(\frac{1}{a} \right) dx = -\frac{1}{a} \log \left(\frac{1}{a} \right) \cdot a = -\log \left(\frac{1}{a} \right) = \log(a) \quad (35.114)$$

Dla $a = 0.5$, $h(X) = \log(0.5) < 0$.

35.3. Skalowanie zmiennej ($H(aX)$)

Niech $Y = aX$ dla $a > 0$. Gęstość prawdopodobieństwa Y to $f_{Y(y)} = \frac{1}{a}f_{X(\frac{y}{a})}$.

$$\begin{aligned} h(Y) &= - \int f_{Y(y)} \log f_{Y(y)} dy \\ &= - \int \frac{1}{a} f_{X(\frac{y}{a})} \log \left(\frac{1}{a} f_{X(\frac{y}{a})} \right) dy \end{aligned} \quad (35.115)$$

Podstawiając $x = \frac{y}{a}$ (więc $dy = a dx$):

$$\begin{aligned} &= - \int \frac{1}{a} f_{X(x)} (\log f_{X(x)} - \log a) a dx \\ &= - \int f_{X(x)} \log f_{X(x)} dx + \log a \int f_{X(x)} dx \\ &= h(X) + \log a \end{aligned} \quad (35.116)$$

35.4. Maksymalna entropia rozkładu normalnego

Wiemy, że $D_{\text{KL}}(f \parallel g) \geq 0$ (Nierówność Gibbsa). Niech $f(x)$ będzie dowolnym rozkładem o średniej μ i wariancji σ^2 , a $g(x)$ będzie rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

$$D_{\text{KL}}(f \parallel g) = \int f(x) \log \left(\frac{f(x)}{g(x)} \right) dx = -h(f) - \int f(x) \log g(x) dx \geq 0 \quad (35.117)$$

Stąd: $h(f) \leq - \int f(x) \log g(x) dx$.

Obliczmy prawą stronę dla $g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$:

$$\begin{aligned} &- \int f(x) \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2} \right] dx \\ &= \frac{1}{2} \log(2\pi\sigma^2) \int f(x) dx + \frac{1}{2\sigma^2} \int f(x)(x-\mu)^2 dx \end{aligned} \quad (35.118)$$

Ponieważ f ma wariancję σ^2 , całka $\int f(x)(x-\mu)^2 dx = \sigma^2$. Oraz $\int f(x) dx = 1$.

$$= \frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2} = \frac{1}{2} \log(2\pi e\sigma^2) \quad (35.119)$$

Wartość ta jest dokładnie entropią rozkładu normalnego $h(g)$. Zatem $h(f) \leq h(g)$, co dowodzi, że rozkład normalny ma największą entropię przy ustalonej wariancji.

36. Ćwiczenie 36 – Miary odległości między rozkładami

Oto zestawienie popularnych miar dla rozkładów P i Q (gęstości $p(x)$ i $q(x)$):

Miara	Opis i Własności
-------	------------------

Dywergencja Kullbacka-Leiblera (KL) $D_{\text{KL}(P \parallel Q)} = \int p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$	• Intuicja: Strata informacji przy aproksymacji P przez Q. • Własności: Nieujemna (≥ 0), równa 0 wtw gdy $P = Q$. • Uwaga: Nie jest metryką (nie jest symetryczna: $D_{\text{KL}(P \parallel Q)} \neq D_{\text{KL}(Q \parallel P)}$ i nie spełnia nierówności trójkąta).
Odległość Hellingera $H^2(P, Q) = \frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx$	• Intuicja: Euklidesowa odległość między pierwiastkami z gęstości. • Własności: Jest to metryka. Przyjmuje wartości w zakresie $[0, 1]$. Jest symetryczna. • Przydatna w teorii estymacji i statystyce asymptotycznej.
Total Variation Distance (TV) $TV(P, Q) = \sup_A P(A) - Q(A) $ $= \frac{1}{2} \int p(x) - q(x) dx$	• Intuicja: Największa możliwa różnica w prawdopodobieństwie przypisanym temu samemu zdarzeniu przez dwa rozkłady. • Własności: Jest metryką (L_1 norm). Ograniczona $0 \leq TV \leq 1$. • Bardzo restrykcyjna miara zbieżności.
Odległość Wassersteina (Earth Mover's) $W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\ x - y\]$	• Intuicja: Minimalny „koszt” (masa $\times$ droga) przesunięcia masy prawdopodobieństwa z rozkładu P, by uformować Q. • Własności: Jest metryką. Działa świetnie nawet gdy rozkłady mają rozłączne nośniki (gdzie KL byłoby nieskończone). Kluczowa w GAN-ach (WGAN).

Algorytmiczna Analiza Danych

Ćwiczenia 10

12 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

37. Ćwiczenie 37– Własności próby bootstrapowej

Niech X oznacza liczbę unikalnych obserwacji w próbie bootstrapowej rozmiaru n .

37.1. Wartość oczekiwana X

Zdefiniujmy zmienną indykatorową I_j dla j -tej obserwacji z oryginalnej próby (gdzie $j = 1, \dots, n$):

$$I_j = \begin{cases} 1 & \text{jeśli obserwacja } j \text{ znalazła się w próbie bootstrapowej} \\ 0 & \text{w przeciwnym wypadku} \end{cases} \quad (37.120)$$

Liczba unikalnych obserwacji to suma indykatorów: $X = \sum_{j=1}^n I_j$.

Prawdopodobieństwo, że konkretna obserwacja j **nie** zostanie wylosowana w pojedynczym losowaniu wynosi $(1 - \frac{1}{n})$. Ponieważ próba bootstrapowa polega na n -krotnym losowaniu ze zwracaniem, prawdopodobieństwo, że obserwacja j nie znajdzie się w całej próbie wynosi:

$$P(I_j = 0) = \left(1 - \frac{1}{n}\right)^n \quad (37.121)$$

Zatem prawdopodobieństwo, że obserwacja j znajdzie się w próbie (jest unikalna) to:

$$\mathbb{E}[I_j] = P(I_j = 1) = 1 - \left(1 - \frac{1}{n}\right)^n \quad (37.122)$$

Korzystając z liniowości wartości oczekiwanej:

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^n I_j\right] = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \quad (37.123)$$

Dla dużych n , korzystając z granicy $\lim_{n \rightarrow \infty} \left(1 - \frac{a}{n}\right)^n = e^{-a}$:

$$\mathbb{E}[X] \approx n(1 - e^{-1}) \approx 0.632n \quad (37.124)$$

37.2. Wariancja X

Wariancję sumy zmiennych zależnych wyrażamy wzorem:

$$\text{Var}(X) = \sum_{j=1}^n \text{Var}(I_j) + \sum_{j \neq k} \text{Cov}(I_j, I_k) \quad (37.125)$$

Wariancja pojedynczego indykatora:

$$\begin{aligned}
\text{Var}(I_j) &= \mathbb{E}[I_j^2] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] (1 - \mathbb{E}[I_j]) \\
&= \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \left(1 - \frac{1}{n}\right)^n
\end{aligned} \tag{37.126}$$

Kowariancja:

$$\text{Cov}(I_j, I_k) = E[I_j I_k] - E[I_j] E[I_k] \tag{37.127}$$

$$\begin{aligned}
E[I_j I_k] &= 1 \cdot P(j \in S \wedge k \in S) + 0 \cdot P(j \in S \wedge k \notin S) \\
&= P(j \in S \wedge k \in S)
\end{aligned} \tag{37.128}$$

to prawdopodobieństwo, że **zarówno** j jak i k są w próbie. Łatwiej policzyć to przez dopełnienie:

$$P(j \in S \wedge k \in S) = 1 - P(j \notin S \vee k \notin S) \tag{37.129}$$

$$= 1 - [P(j \notin S) + P(k \notin S) - P(j \notin S \wedge k \notin S)] \tag{37.130}$$

Gdzie $P(j \notin S \wedge k \notin S) = \left(1 - \frac{2}{n}\right)^n$.

Po podstawieniu i uproszczeniu dla dużych n , otrzymujemy przybliżenie:

$$\text{Var}(X) \approx n[e^{-1}(1 - e^{-1}) - n(e^{-1} - e^{-2})] \tag{37.131}$$

W praktyce dla dużych n wariancja ta dąży do:

$$\text{Var}(X) \approx n \cdot e^{-1}(1 - e^{-1}) \approx n \cdot 0.233 \tag{37.132}$$

37.3. Odsetek unikalnych obserwacji i jego wariancja

Niech $\hat{p}$ będzie odsetkiem unikalnych obserwacji: $\hat{p} = \frac{X}{n}$.

37.3.1. Średnia

$$E[\hat{p}] = E\left[\frac{X}{n}\right] = \frac{1}{n} E[X] = 1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - e^{-1} \approx 0.632 \tag{37.133}$$

37.3.2. Wariancja

$$\text{Var}(\hat{p}) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) \tag{37.134}$$

Dla dużych n , wariancja odsetka maleje rzędu $\frac{1}{n}$.

37.4. Prawdopodobieństwo braku obserwacji w k próbkach

Prawdopodobieństwo, że dana obserwacja nie znajdzie się w jednej próbie bootstrapowej wynosi $\left(1 - \frac{1}{n}\right)^n \approx e^{-1}$. Ponieważ próbki są generowane niezależnie, prawdopodobieństwo, że obserwacja nie znajdzie się w żadnej z k próbek wynosi:

$$P(\text{brak w } k \text{ próbkach}) = \left[\left(1 - \frac{1}{n} \right)^n \right]^k \approx (e^{-1})^k = e^{-k} \quad (37.135)$$

38. Ćwiczenie 38 – Konstrukcja drzewa i predyktory kategoryczne

38.1. Konstrukcja drzewa

Drzewa decyzyjne konstruowane są zazwyczaj za pomocą algorytmu zachłannego (np. CART, C4.5). Proces polega na rekurencyjnym podziale przestrzeni cech na prostokątne regiony. W każdym kroku wybierana jest zmienna oraz punkt podziału, które najlepiej rozdzielają dane względem zmiennej celu (minimalizując np. RSS dla regresji lub wskaźnik Giniego/entropię dla klasyfikacji).

38.2. Problem z predyktorem kategorycznym

Dla predyktora kategorycznego z q możliwymi nieuporządkowanymi wartościami, podział polega na przydzieleniu pewnego podzbioru wartości do lewego węzła, a reszty do prawego.

Liczba możliwych podziałów: Aby podzielić zbiór q wartości na dwie niepuste grupy, rozważamy wszystkie możliwe podzbiory. Zbiór q -elementowy ma 2^q podzbiorów.

1. Odejmujemy zbiór pusty i zbiór pełny (podział musi być na dwie grupy): $2^q - 2$.
2. Ponieważ podział $\{A, B\}$ vs $\{C\}$ jest tożsamy z $\{C\}$ vs $\{A, B\}$, wynik dzielimy przez 2.

Liczba podziałów wynosi:

$$\frac{2^q - 2}{2} = 2^{q-1} - 1 \quad (38.136)$$

Problem: Liczba ta rośnie wykładniczo wraz z q . Przeszukiwanie wszystkich podziałów jest obliczeniowo bardzo kosztowne dla dużego q . Dodatkowo, zmienne o dużej liczbie kategorii są faworyzowane przez algorytm doboru zmiennych (tzw. bias doboru).

38.3. Rozwiązanie problemu

Dla binarnej klasyfikacji (0/1) lub regresji istnieje efektywne rozwiązanie (Fisher, 1958):

1. Oblicz średnią wartość zmiennej celu dla każdej kategorii predyktora.
2. Uporządkuj kategorie według tych średnich rosnąco.
3. Potraktuj zmienną kategoryczną jak zmienną ciągłą (uporządkowaną) i sprawdzaj podziały tylko wzdłuż tego porządku.

Redukuje to liczbę sprawdzanych podziałów z $2^{q-1} - 1$ do $q - 1$.

39. Ćwiczenie 39 – Miary jakości podziału

39.1. a) Interpretacja indeksu Giniego

Indeks Giniego dla węzła m zdefiniowany jest jako:

$$G = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2 \quad (39.137)$$

gdzie p_{mk} to frakcja obserwacji klasy k w węźle m .

Interpretacja: Indeks Giniego można interpretować jako miarę „nieczystości” węzła. Reprezentuje on oczekiwany poziom błędu, jeśli klasyfikowalibyśmy losowo obserwację z węzła, losując jej etykietę zgodnie z rozkładem klas w tym węźle. Im mniejszy indeks Giniego, tym bardziej „czysty” węzeł (zdominowany przez jedną klasę).

39.2. b) Porównanie podziałów

Mamy problem dwuklasowy (klasy A i B). W korzeniu mamy (400, 400). Całkowita liczba obserwacji $N = 800$.

- **Analiza Podziału 1:**

Tworzy węzły: $N_1(300, 100)$ oraz $N_2(100, 300)$.

- ▶ N_1 (400 obs): Dominująca klasa A. Błędne: 100 (klasa B).
- ▶ N_2 (400 obs): Dominująca klasa B. Błędne: 100 (klasa A).
- ▶ Całkowita liczba błędów: $100 + 100 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

- **Analiza Podziału 2:**

Tworzy węzły: $N_3(200, 400)$ oraz $N_4(200, 0)$.

- ▶ N_3 (600 obs): Dominująca klasa B. Błędne: 200 (klasa A).
- ▶ N_4 (200 obs): Dominująca klasa A. Błędne: 0 (czysty węzeł).
- ▶ Całkowita liczba błędów: $200 + 0 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

Oba podziały mają ten sam Misclassification Rate (0.25).

39.3. Obliczenie Indeksu Giniego

Wzór dla dwóch klas: $2p(1 - p)$.

- **Dla Podziału 1:**

- ▶ Węzeł N_1 ($p = 0.75$): $G_1 = 1 - (0.75^2 + 0.25^2) = 1 - (0.5625 + 0.0625) = 375$.
- ▶ Węzeł N_2 ($p = 0.25$): $G_2 = 1 - (0.25^2 + 0.75^2) = 375$.
- ▶ Średni ważony Gini:

$$G_{\text{split 1}} = \frac{400}{800} \cdot 0.375 + \frac{400}{800} \cdot 0.375 = 375 \quad (39.138)$$

- **Dla Podziału 2:**

- ▶ Węzeł N_3 (200, 400), $p_A = \frac{1}{3}$, $p_B = \frac{2}{3}$:

$$G_3 = 1 - \left(\left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right) = 1 - \left(\frac{1}{9} + \frac{4}{9} \right) = \frac{4}{9} \approx 0.444 \quad (39.139)$$

- ▶ Węzeł N_4 (200, 0), $p_A = 1$:

$$G_4 = 1 - (1^2 + 0^2) = 0 \quad (39.140)$$

(węzeł czysty)

- Średni ważony Gini (wagi: $\frac{600}{800} = \frac{3}{4}$ i $\frac{200}{800} = \frac{1}{4}$):

$$G_{\text{split } 2} = \frac{3}{4} \cdot \frac{4}{9} + \frac{1}{4} \cdot 0 = \frac{3}{9} = \frac{1}{3} \approx 0.333 \quad (39.141)$$

39.3.1. Wniosek

$$G_{\text{split } 2}(0.333) < G_{\text{split } 1}(0.375) \quad (39.142)$$

Indeks Giniego jest niższy dla drugiego podziału, co oznacza, że preferuje on podział, który wydziela czysty węzeł („pure node”), nawet jeśli globalny błąd klasyfikacji jest taki sam.

Algorytmiczna Analiza Danych

Ćwiczenia 11

19 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

40. Zadanie 40 – Współczynnik Giniego

Współczynnik Giniego - to statystyczna miara koncentracji (nierówności) rozkładu dochodów lub bogactwa w danym społeczeństwie. Przyjmuje wartości od 0 do 1 (lub od 0% do 100%).

- **0 (Idealna równość)** - Każdy obywatel ma dokładnie taki sam dochód.
- **1 (Idealna nierówność)** - Jedna osoba posiada cały dochód kraju, a reszta nie posiada nic.

40.1. Intuicja geometryczna (Krzywa Lorenza)

Współczynnik Giniego oblicza się na podstawie wykresu, gdzie na osi X mamy skumulowany odsetek populacji, a na osi Y skumulowany odsetek dochodu.

1. **Linia 45 stopni** - To linia idealnej równości.
2. **Krzywa Lorenza** - Rzeczywisty rozkład dochodów w populacji.
3. **Obliczanie** - Jeśli oznaczymy pole między linią 45 stopni a Krzywą Lorenza jako A , a pole pod Krzywą Lorenza jako B , współczynnik Giniego (G) wyraża się wzorem:

$$G = \frac{A}{A + B} \quad (40.143)$$

40.2. Pozycja Polski w OECD

Polska na tle krajów OECD prezentuje się jako kraj o **średnio-niskich** nierównościach, szczególnie po uwzględnieniu transferów społecznych:

- **Przed transferami i podatkami:** Współczynnik Giniego w Polsce jest relatywnie wysoki (podobnie jak w większości krajów rozwiniętych), co wynika z rynkowego zróżnicowania płac.
- **Po transferach i podatkach:** Polska odnotowuje jeden z większych spadków współczynnika w OECD. Obecnie wartość ta oscyluje wokół **0.27 – 0.28**, co plasuje Polskę poniżej średniej OECD (czyli jesteśmy krajem o mniejszych nierównościach niż np. USA, Wielka Brytania czy kraje bałtyckie).

40.3. Poziom graniczny napięcie społecznych

W literaturze ekonomicznej i socjologicznej (m.in. ONZ) przyjmuje się często, że wartości współczynnika Giniego powyżej **0.40** stanowią „czerwoną linię”. Przekroczenie tego poziomu sugeruje głębokie nierówności, które mogą prowadzić do destabilizacji politycznej, protestów i wzrostu przestępczości.

41. Zadanie 41 – Algorytm Random Forest

Random Forest to metoda zespołowa (ensemble learning) oparta na budowie wielu drzew decyzyjnych i agregacji ich wyników.

41.1. Pseudokod

- Dla $b = 1$ do B (liczba drzew):
 - Wylosuj próbkę bootstrapową Z^* z danych treningowych (losowanie ze zwracaniem).
 - Wyhoduj drzewo T_b na podstawie próbki Z^* :
 - Powtarzaj, aż osiągniesz minimalny rozmiar liścia:
 - Wybierz losowo m zmiennych spośród wszystkich p predyktorów.
 - Wybierz najlepszą zmienną i punkt podziału spośród m zmiennych.
 - Podziel węzeł na dwa węzły potomne.
- Zwróć zespół drzew $\{T_b\}_1^B$.

41.2. Predykcja

- Klasyfikacja** - Głosowanie większościowe (Majority Vote) - klasa najczęściej wskazywana przez drzewa.
- Regresja** - Średnia arytmetyczna z przewidywań wszystkich B drzew.

42. Ćwiczenie 42 – Algorytm Boosting (Regresja)

W przeciwieństwie do Random Forest, Boosting buduje drzewa sekwencyjnie. Każde kolejne drzewo uczy się na błędach (resztach) swoich poprzedników.

42.1. Pseudokod (na podstawie ISL)

- Ustaw $\hat{f}(x) = 0$ oraz reszty $r_i = y_i$ dla wszystkich obserwacji w zbiorze treningowym.
- Dla $b = 1, 2, \dots, B$:
 - Dopasuj drzewo $\hat{f}^b$ z d podziałami (liczba liści = $d + 1$) do danych treningowych (X, r) .
 - Zaktualizuj model główny, dodając nową wersję drzewa z parametrem uczenia (shrinkage) λ :

$$\hat{f}(x) \leftarrow \hat{f}(x) + \lambda \hat{f}^b(x) \quad (42.144)$$

- Zaktualizuj reszty:

$$r_i \leftarrow r_i - \lambda \hat{f}^b(x_i) \quad (42.145)$$

- Zwróć model końcowy: $\hat{f}(x) = \sum_{b=1}^B \lambda \hat{f}^b(x)$.

42.2. Wyjaśnienie kluczowych parametrów

- B (Liczba drzew)** - Zbyt duża może prowadzić do overfittingu (inaczej niż w RF).
- λ (Shrinkage)** - Mała wartość (np. 0.01) spowalnia naukę, wymagając więcej drzew, ale zazwyczaj poprawia generalizację.
- d (Liczba podziałów)** - Kontroluje złożoność każdego drzewa (często wystarczają bardzo proste drzewa, tzw. stumps, gdzie $d = 1$).

Algorytmiczna Analiza Danych

Ćwiczenia 12

9 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

43. Zadanie 43 – Obliczenia PCA

Dane są punkty: $(2, 3), (3, 4), (4, 5), (5, 6), (6, 7)$. Liczba obserwacji $n = 5$.

43.1. Średnia każdej zmiennej

Obliczamy średnie arytmetyczne dla X i Y :

$$\bar{X} = \frac{2 + 3 + 4 + 5 + 6}{5} = \frac{20}{5} = 4 \quad (43.146)$$

$$\bar{Y} = \frac{3 + 4 + 5 + 6 + 7}{5} = \frac{25}{5} = 5 \quad (43.147)$$

43.2. Macierz kowariancji

Najpierw centrujemy dane (odejmujemy średnie od każdej obserwacji):

$$X_c = [-2, -1, 0, 1, 2] \quad (43.148)$$

$$Y_c = [-2, -1, 0, 1, 2] \quad (43.149)$$

Wzór na kowariancję dla próbki (dzielenie przez $n - 1$):

$$\text{Cov}(A, B) = \frac{\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})}{n - 1} \quad (43.150)$$

Obliczamy wariancje i kowariancję (gdzie $n - 1 = 4$):

$$s_X^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{4} = \frac{4 + 1 + 0 + 1 + 4}{4} = \frac{10}{4} = 2.5$$

$$s_Y^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{4} = \frac{10}{4} = 2.5 \quad (43.151)$$

$$\text{Cov}(X, Y) = \frac{(-2)(-2) + (-1)(-1) + 0 + 1(1) + 2(2)}{4} = \frac{4 + 1 + 0 + 1 + 4}{4} = 2.5$$

Macierz kowariancji C :

$$C = \begin{pmatrix} 2.5 & 2.5 \\ 2.5 & 2.5 \end{pmatrix} \quad (43.152)$$

43.3. Wartości własne i wektory własne

Rozwiązujemy równanie charakterystyczne $\det(C - \lambda I) = 0$:

$$\begin{aligned}
\det \begin{pmatrix} 2.5 - \lambda & 2.5 \\ 2.5 & 2.5 - \lambda \end{pmatrix} &= 0 \\
(2.5 - \lambda)^2 - 2.5^2 &= 0 \\
(2.5 - \lambda - 2.5)(2.5 - \lambda + 2.5) &= 0 \\
-\lambda(5 - \lambda) &= 0
\end{aligned} \tag{43.153}$$

Wartości własne to:

$$\lambda_1 = 5, \quad \lambda_2 = 0 \tag{43.154}$$

Wyznaczamy wektory własne:

Dla $\lambda_1 = 5$:

$$\begin{aligned}
\begin{pmatrix} 2.5 - 5 & 2.5 \\ 2.5 & 2.5 - 5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\
\begin{pmatrix} -2.5 & 2.5 \\ 2.5 & -2.5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix}
\end{aligned} \tag{43.155}$$

Równanie: $-2.5x + 2.5y = 0 \rightarrow x = y$. Znormalizowany wektor własny:

$$v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \vee v_1 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \tag{43.156}$$

Dla $\lambda_2 = 0$:

$$\begin{pmatrix} 2.5 & 2.5 \\ 2.5 & 2.5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow x = -y \tag{43.157}$$

Znormalizowany wektor własny:

$$v_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \vee v_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \tag{43.158}$$

43.4. Interpretacja

Wybór głównych składowych: Całkowita wariancja wynosi $\lambda_1 + \lambda_2 = 5 + 0 = 5$. **Pierwsza składowa ($PC1$, związana z λ_1) wyjaśnia $\frac{5}{5} = 100\%$ wariancji.** Druga składowa ($PC2$, związana z λ_2) wyjaśnia 0% wariancji.

Decyzja: Należy wybrać tylko **pierwszą główną składową**. **Uzasadnienie:** Wszystkie punkty leżą idealnie na prostej ($y = x + 1$). Redukcja do jednego wymiaru nie powoduje żadnej utraty informacji. Druga składowa jest zbędna (szum wynosi zero).

Analiza przypadku odstającego: punkt (6, 7) zamieniony na (6, 107)

Zastąpienie punktu (6, 7) punktem (6, 107) drastycznie zmienia sytuację:

1. **Średnia** - Średnia Y znacznie wzrosła.
2. **Wariancja** - Wariancja zmiennej Y stanie się ogromna w porównaniu do wariancji X .
3. **Kierunek** - Główna składowa ($PC1$) obróci się i będzie prawie równoległa do osi Y (ponieważ tam jest teraz największa zmienność).

4. **Wynik** - PCA jest bardzo wrażliwe na wartości odstające (outliers), ponieważ opiera się na kowariancji/wariancji (kwadratach odchylenia). Ten jeden punkt zdominuje wynik analizy.

44. Zadanie 44 – Ortogonalność wektorów własnych

Theorem 44.2. Pokaż, że wektory własne symetrycznej macierzy kowariancji C odpowiadające różnym wartościom własnym $\lambda_i \neq \lambda_j$ są ortogonalne.

Proof. Niech v_i oraz v_j będą wektorami własnymi macierzy C odpowiadającymi odpowiednio wartościom własnym λ_i oraz λ_j . Z definicji mamy:

$$Cv_i = \lambda_i v_i \quad \text{oraz} \quad Cv_j = \lambda_j v_j \quad (44.159)$$

Rozważmy wyrażenie $v_i^T Cv_j$. Ponieważ $Cv_j = \lambda_j v_j$, mamy:

$$v_i^T Cv_j = v_i^T (\lambda_j v_j) = \lambda_j v_i^T v_j \quad (44.160)$$

Z drugiej strony, transponując skalar (który jest równy swojej transpozycji) i korzystając z faktu, że macierz kowariancji jest symetryczna ($C = C^T$):

$$v_i^T Cv_j = (v_i^T Cv_j)^T = v_j^T C^T v_i = v_j^T Cv_i \quad (44.161)$$

Podstawiając $Cv_i = \lambda_i v_i$:

$$v_j^T (\lambda_i v_i) = \lambda_i v_j^T v_i = \lambda_i v_i^T v_j \quad (44.162)$$

Mamy zatem równość:

$$\lambda_j v_i^T v_j = \lambda_i v_i^T v_j \quad (44.163)$$

Przekształcając:

$$(\lambda_i - \lambda_j) v_i^T v_j = 0 \quad (44.164)$$

Ponieważ z założenia $\lambda_i \neq \lambda_j$, to różnica $(\lambda_i - \lambda_j) \neq 0$. Aby równanie było prawdziwe, musi zachodzić:

$$v_i^T v_j = 0 \quad (44.165)$$

Oznacza to, że wektory v_i i v_j są ortogonalne.

■

45. Zadanie 45 – Prawda czy Fałsz o PCA

Zakładamy, że wartości własne są unikalne.

1. **Dodanie jedynki na końcu każdego punktu próbki nie zmienia wyników przeprowadzenia PCA (z wyjątkiem dodatkowej składowej z wartością własną 0).**

Odpowiedź: PRAWDA. PCA operuje na macierzy kowariancji (dane scentrowane). Dodanie stałej wartości (np. 1) jako nowej cechy oznacza, że wariancja tej cechy wynosi

0. Po scentrowaniu otrzymamy kolumnę zer. Nie wpłynie to na relacje wariancji między oryginalnymi cechami, a jedynie doda wymiar o zerowej wariancji (wartość własna 0).
2. **Sekwencyjna redukcja wymiarowości ($d \rightarrow j \rightarrow k$) daje ten sam wynik co bezpośrednia redukcja ($d \rightarrow k$).**

Odpowiedź: PRAWDA. PCA sortuje składowe według wariancji. Wybranie najlepszych j składowych, a następnie wybranie z nich najlepszych k składowych, jest tożsame z wybraniem od razu k najlepszych składowych z pierwotnego zbioru (ponieważ zbiór k najlepszych zawiera się w zbiorze j najlepszych dla $k < j$).

3. **Obrót punktów przed PCA nie zmienia kierunków głównych składowych.**

Odpowiedź: FAŁSZ. Jeśli obrócimy dane wejściowe, struktura kowariancji się zmienia. Główne składowe (wektory własne) obracają się wraz z danymi. Chociaż **względna** geometria chmury punktów jest taka sama, to wektory własne (które są wyrażone w układzie współrzędnych cech) zmieniają swoje współrzędne.

4. **Obrót punktów przed PCA nie zmienia największej wartości własnej.**

Odpowiedź: PRAWDA. Wartości własne reprezentują wariancję (rozrzut) danych wzdłuż głównych osi. Obrót chmury punktów w przestrzeni nie zmienia „kształtu” tej chmury ani wielkości jej rozrzutu, jedynie jej orientację względem osi. Zatem wielkość maksymalnej wariancji (λ_1) pozostaje taka sama.

Algorytmiczna Analiza Danych

Ćwiczenia 13

16 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

46. Ćwiczenie 46 – Idea algorytmu Apriori

Algorytm Apriori - klasyczny algorytm służący do znajdowania częstych zbiorów elementów (frequent itemsets) w transakcyjnych bazach danych.

46.1. Właściwość Apriori (Anti-monotonicity)

Kluczowa dla działania algorytmu jest zasada:

Jeśli zbiór elementów jest częsty, to każdy jego podzbiór musi być częsty. I odwrotnie: jeśli zbiór jest rzadki, to każdy jego nadzbiór również jest rzadki.

Dzięki tej właściwości możemy drastycznie ograniczyć przestrzeń poszukiwań (tzw. *pruning*). Jeśli zbiór A, B jest rzadki, nie musimy sprawdzać A, B, C, ponieważ on również musi być rzadki.

46.2. Proces generowania kandydatów

Algorytm działa iteracyjnie (poziomami $k = 1, 2, \dots$):

1. **Łączenie (Join)** - Kandydaci o rozmiarze k (C_k) są generowani poprzez łączenie częstych zbiorów o rozmiarze $k - 1$ (L_{k-1}). Łączymy dwa zbiory $X, Y \in L_{k-1}$ tylko wtedy, gdy ich pierwsze $k - 2$ elementy są identyczne (zakładając porządek leksykograficzny).
2. **Przycinanie (Prune)** - Dla każdego wygenerowanego kandydata sprawdzamy, czy **wszystkie** jego podzbiory o rozmiarze $k - 1$ znajdują się w L_{k-1} . Jeśli którykolwiek podzbiór nie jest częsty, kandydat jest usuwany zgodnie z właściwością Apriori.

47. Ćwiczenie 47 – Oznaczenie węzłów kraty (M, D, C, R)

Dane:

- Liczba transakcji (N): 10
- Próg wsparcia: 30% $\rightarrow$ 3 transakcje.

Analiza licznosci zbiorów (Support count):

Zbiór	Liczność	Status
{a}	5	D
{b}	7	D
{c}	5	D

Zbiór	Liczność	Status
{d}	9	D
{e}	6	C
{ab}	3	M
{ac}	2	R
{ad}	4	C
{ae}	4	C
{bc}	3	M
{bd}	6	D
{be}	4	C
{cd}	4	M
{ce}	2	R
{de}	6	D
{abc}	1	R
{abd}	2	R
{abe}	2	R
{acd}	1	R
{ace}	1	R
{ade}	4	M
{bcd}	2	R
{bce}	1	R
{bde}	4	M
{cde}	2	R
{abcd}	0	R
{abce}	0	R
{abde}	2	R
{acde}	1	R
{bcde}	1	R
{abcde}	0	R

Oznaczenia:

- **M (Maksymalny)** - Częsty, brak częstych nadzbiorów.
- **D (Domknięty)** - Częsty, brak nadzbiorów o *tym samym* wsparciu (Maksymalne też są domknięte, ale tutaj rozróżniamy je dla precyzji, przypisując M do tych na granicy „częstości”).
- **C** - Częsty, nie M i nie D.
- **R (Rzadki)** - Poniżej progu.

Wynikowa klasyfikacja węzłów:

- **M:** ab, bc, cd, ade, bde
- **D:** a, b, c, d, bd, de
- **C:** e, ad, ae, be
- **R:** ac, ce oraz wszystkie zbiory 3-elementowe inne niż ade, bde i wszystkie 4-elementowe.

48. Ćwiczenie 48 – Intuicje: Maksymalne vs Domknięte

48.1. Maksymalny zbiór częsty:

- **Intuicja:** Jest to „granica” zbiorów częstych. Najdłuższe możliwe kombinacje, które są jeszcze częste.
- **Cel:** Kompaktowa reprezentacja wszystkich częstych zbiorów. Jeśli znamy zbiory maksymalne, wiemy, że każdy ich podzbiór też jest częsty.
- **Wada:** Tracimy informację o dokładnej liczności podzbiorów (kompresja stratna).

48.2. Domknięty zbiór częsty:

- **Intuicja:** Zbiór, który „maksymalizuje” przedmioty dla danej grupy transakcji. Dodanie czegokolwiek do tego zbioru spowodowałoby spadek wsparcia (występowanie w mniejszej liczbie transakcji).
- **Cel:** Pozwala na odtworzenie dokładnego wsparcia wszystkich częstych podzbiorów bez skanowania bazy (kompresja bezstratna). Wsparcie dowolnego zbioru X jest równe wsparciu jego najmniejszego domkniętego nadzbioru.

Relacja:

$$\text{Maksymalne} \subseteq \text{Domknięte} \subseteq \text{Częste} \quad (48.166)$$

Każdy maksymalny zbiór jest domknięty, ale nie każdy domknięty jest maksymalny.

49. Ćwiczenie 49 – Złożoność Algorytmu Apriori

Niech d to liczba unikalnych przedmiotów, N to liczba transakcji, a w to maksymalna szerokość transakcji.

1. **Złożoność czasowa:** Głównym kosztem jest zliczanie wsparcia dla kandydatów C_k . W najgorszym przypadku algorytm generuje $O(2^d)$ kandydatów. Koszt zliczania to:

$$O\left(\sum_k |C_k| \cdot N \cdot w\right) \quad (49.167)$$

W praktyce często upraszcza się to do $O(2^d)$, co wskazuje na wykładniczą złożoność względem liczby produktów.

2. **Złożoność pamięciowa:** Wymaga przechowywania kandydatów na danym poziomie oraz liczników.

$$O\left(\max_k |C_k|\right) \quad (49.168)$$

W najgorszym przypadku (gdy $k \approx \frac{d}{2}$) pamięć rośnie wykładniczo.

Wpływ progu wsparcia ($\text{Support}_{\min}$): Tak, próg ma krytyczny wpływ.

- **Zmniejszanie $\text{Support}_{\min}$:** Powoduje gwałtowny wzrost liczby częstych zbiorów i kandydatów.
- **Negatywne konsekwencje:** Wykładniczy wzrost czasu obliczeń i zapotrzebowania na pamięć. Może dojść do wygenerowania tak dużej liczby kandydatów na poziomie 2 (pary), że algorytm nie zmieści się w pamięci RAM.

Algorytmiczna Analiza Danych

Ćwiczenia 14

23 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

50. Ćwiczenie 50 – Liczba reguł asocjacyjnych

Mamy d zmiennych. Reguła ma postać $X \rightarrow Y$, gdzie $X, Y \subseteq I$, $X \cap Y = \emptyset$, $X \neq \emptyset$, $Y \neq \emptyset$.

Dla każdego z d elementów mamy 3 możliwości:

1. Element jest w antecedenencie (X).
2. Element jest w następniku (Y).
3. Element nie występuje w regule (nie jest ani w X , ani w Y).

Daje to 3^d kombinacji. Należy jednak odjąć przypadki niepoprawne:

- **Zbiór X jest pusty:** Elementy mogą być tylko w Y lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- **Zbiór Y jest pusty:** Elementy mogą być tylko w X lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- Odejmując $2^d + 2^d$, dwukrotnie odjęliśmy przypadek, gdzie zarówno X jak i Y są puste (wszystkie elementy są „nigdzie”). Należy go dodać (+1).

Zatem liczba reguł:

$$|R| = 3^d - (2^d + 2^d - 1) = 3^d - 2 \cdot 2^d + 1 = 3^d - 2^{d+1} + 1 \quad (50.169)$$

■

51. Ćwiczenie 51 – Przechodniość reguł

Pytanie: Czy jeśli $\text{Conf}(A \rightarrow B) > \text{próg}$ i $\text{Conf}(B \rightarrow C) > \text{próg}$, to $\text{Conf}(A \rightarrow C)$ musi być wysokie?

Odpowiedź: Nie. Reguły asocjacyjne nie są przechodnie.

Przykład: Rozważmy 100 transakcji.

- A występuje w 10 transakcjach.
- B występuje w 10 transakcjach.
- C występuje w 10 transakcjach.
- A i B współwystępują w 9 transakcjach ($A \rightarrow B$, $\text{conf} = 0.9$).
- B i C współwystępują w 9 transakcjach ($B \rightarrow C$, $\text{conf} = 0.9$).
- Jednak zbiory A , B oraz B , C mogą „wymijać się” wewnątrz B tak bardzo, jak to możliwe. W skrajnym przypadku część wspólna A i C może być za mała.

A	A	A	A	A	A	A	A	A	A		
	B	B	B	B	B	B	B	B	B	B	
		C	C	C	C	C	C	C	C	C	C

W powyższym przykładzie $\text{Conf}(A \rightarrow B) = 0.9$ oraz $\text{Conf}(B \rightarrow C) = 0.9$, ale $\text{Conf}(A \rightarrow C) = 0.8$. Dla $\text{Conf}_{\min} \in (0.8, 0.9)$ reguła przechodnia $A \rightarrow C$ ma mniejszą ufność.

52. Ćwiczenie 52 – Dowód nierówności

Założenie: Ufność reguły $A \rightarrow B$ jest mniejsza niż wsparcie B , co zapisujemy jako:

$$\text{Conf}(A \rightarrow B) < \text{Supp}(B) \quad (52.170)$$

W języku prawdopodobieństwa warunkowego oznacza to:

$$P(B|A) < P(B) \quad (52.171)$$

(Obecność A zmniejsza prawdopodobieństwo wystąpienia B — korelacja ujemna).

Chcemy udowodnić, że dla $\bar{A}$ („brak A ”):

- a) $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$
- b) $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Kolejność dowodzenia: Najpierw udowodnimy podpunkt **b)**, ponieważ podpunkt **a)** wynika z niego bezpośrednio.

52.1. Podpunkt b)

Theorem 52.3. $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Proof. Skorzystajmy z Prawa Prawdopodobieństwa Całkowitego dla zdarzenia B . Prawdopodobieństwo $P(B)$ jest średnią ważoną prawdopodobieństw warunkowych:

$$\begin{aligned} P(B) &= P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) \\ P(B) &= P(B|A)P(A) + P(B|\bar{A})(1 - P(A)) \end{aligned} \quad (52.172)$$

$$P(B) - P(B|A)P(A) = P(B|\bar{A})(1 - P(A))$$

$$\begin{aligned} P(B|A) &< P(B) \\ \Downarrow \end{aligned} \quad (52.173)$$

$$P(B|A) = P(B) - \varepsilon, \quad 0 < \varepsilon < 1$$

Podstawiając do lewej strony równania:

$$\begin{aligned} P(B) - (P(B) - \varepsilon)P(A) &= P(B) - P(B)P(A) + \varepsilon P(A) \\ &= P(B)(1 - P(A)) + \varepsilon P(A) \end{aligned} \quad (52.174)$$

$$P(B)(1 - P(A)) + \varepsilon P(A) = P(B|\bar{A})(1 - P(A)) \quad (52.175)$$

Dzielimy obie strony przez $(1 - P(A))$ (zakładając, że $P(A) \neq 1$):

$$P(B) + \frac{\varepsilon P(A)}{1 - P(A)} = P(B|\bar{A}) \quad (52.176)$$

Ponieważ $\varepsilon > 0$ oraz $P(A) \geq 0$, ułamek $\frac{\varepsilon P(A)}{1 - P(A)}$ jest liczbą dodatnią. Zatem:

$$P(B|\bar{A}) > P(B) \quad (52.177)$$

Co w notacji reguł asocjacyjnych oznacza:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (52.178)$$

■

52.2. Podpunkt a)

Theorem 52.4. $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$

Proof. Korzystamy z własności przechodniości nierówności.

1. Z udowodnionego przed chwilą punktu **b)** wiemy, że:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (52.179)$$

2. Z **założenia** w treści zadania wiemy, że:

$$\text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (52.180)$$

Łącząc te dwa fakty otrzymujemy ciąg nierówności:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (52.181)$$

Z czego wynika bezpośrednio:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B) \quad (52.182)$$

■

53. Ćwiczenie 53 – Miary oceny reguł

Poniższa tabela przedstawia definicje miar (gdzie $P(X)$ oznacza $\text{Supp}(X)$) wraz z ich intuicyjnym znaczeniem.

Miara	Definicja / Wzór	Intuicja / Interpretacja
Lift (Uniesienie)	$\frac{P(A \cap B)}{P(A)P(B)} = \frac{\text{Conf}(A \rightarrow B)}{\text{Supp}(B)}$	O ile razy częściej A i B występują razem, niż gdyby były niezależne? 1 = brak związku (losowość). > 1 = A przyciąga B (promocja łączona ma sens).
Leverage	$P(A \cap B) - P(A)P(B)$	Mierzy „nadwyżkę” transakcji. Ile dokładnie transakcji więcej (lub mniej) obserwujemy w porównaniu do oczekiwań losowych? W

		przeciwieństwie do Lift, jest to różnica bezwzględna.
Conviction (Przekonanie)	$\frac{1 - \text{Supp}(B)}{1 - \text{Conf}(A \rightarrow B)} = \frac{P(A)P(\neq B)}{P(A \cap \neq B)}$	Mierzy siłę implikacji. Jak bardzo reguła myliłaby się, gdyby A i B były niezależne? Wartość ∞ oznacza, że reguła $A \rightarrow B$ jest zawsze prawdziwa (pełna implikacja logiczna).
Jaccard	$\frac{P(A \cap B)}{P(A \cup B)} = \frac{P(A \cap B)}{P(A) + P(B) - P(A \cap B)}$	Podobieństwo zbiorów. Jaki procent transakcji zawierających przynajmniej jeden z tych produktów, zawiera oba ? Ignoruje transakcje, w których nie ma ani A, ani B.
Cosine	$\frac{P(A \cap B)}{\sqrt{P(A)P(B)}}$	Podobieństwo geometryczne. Wartość między 0 a 1. Jest to średnia geometryczna z ufności w obie strony ($A \rightarrow B$ i $B \rightarrow A$). Dobra miara, gdy licznosci A i B są podobne.
Kulczyński	$\frac{1}{2}(P(B A) + P(A B))$	Średnia arytmetyczna z ufności w obu kierunkach. Neutralizuje problem, gdy jeden produkt jest bardzo popularny, a drugi niszowy (nie faworyzuje żadnej strony).
Zhang	$\frac{P(A \cap B) - P(A)P(B)}{\max(P(A \cap B)(1 - P(A)), P(A)(P(B) - P(A \cap B)))}$	Kompleksowa miara (od -1 do $+1$). $+1$: Idealna pozytywna asocjacja. -1 : Idealna negatywna asocjacja (rozłączność). 0 : Brak związku.

Algorytmiczna Analiza Danych

Ćwiczenia 15

30 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

54. Ćwiczenie 54 – Algorytm K-Means

54.1. Działanie algorytmu

Algorytm k-means służy do podziału zbioru na k rozłącznych klastrow. Jego działanie można opisać w następujących krokach:

1. **Inicjalizacja** - Wybierz losowo k punktów ze zbioru danych. Połóż je za początkowe centroidy.
2. **Przypisanie** - Dla każdego punktu w zbiorze danych oblicz jego odległości do wszystkich k centroidów. Przypisz punkt do klastra, reprezentowanego przez centroid, do którego ma najmniejszą odległość.
3. **Aktualizacja** - Oblicz współrzędne centroidów jako średnią arytmetyczną wszystkich punktów przypisanych do danego klastra.
4. **Powtórzenie** - Powtarzaj kroki 2 i 3, aż do spełnienia warunku stopu.

54.2. Złożoność obliczeniowa

- **Czasowa:** $O(t \cdot k \cdot n \cdot d)$, gdzie:
 - t : liczba iteracji,
 - k : liczba klastrow,
 - n : liczba punktów danych,
 - d : wymiarowość danych.

Zazwyczaj $k, t, d \ll n$, więc algorytm jest liniowy względem liczby punktów.

- **Pamięciowa:** $O((n + k) \cdot d)$ ponieważ musimy przechowywać d parametrów, jeden na każdy wymiar, dla każdego punktu i centroidu.

54.3. Dlaczego Potrzebne jest wielokrotne uruchomienie

Algorytm jest heurystyką, to oznacza że nie gwarantuje znalezienia globalnego minimum. Ponad to algorytm bazuje na wyborze losowym początkowych centroidów a jako że wynik końcowy jest w dużej mierze zależny od początkowych wartości, to jest też zależny od tej losowości. Kilukrotne uruchomienie z różnymi losowymi inicjalizacjami zwiększa szansę na znalezienie optymalnego podziału.

54.4. Pechowy wybór centroidów

Przykład: Załóżmy że są dwa naturalne klastry punktów na wykresie, jeśli dwa początkowe centroidy znajdują się w klastrze A, to K-Means nie zmieni tego i podzieli A na dwa klastry a B przypisze do jednego z nich, co jest oczywiście błędne.

55. Ćwiczenie 55 – Dowód na postać centroidu

a) **Theorem 55.5.** $\sum_{i=1}^k \sum_{x \in C_i} (x - c_i)^2$, centroid ma postać średniej punktów w klastrze

Proof. Funkcja kosztu dla dowolnego klastra i to:

$$J(c_i) = \sum_{x \in C_i} (x - c_i)^2 \quad (55.183)$$

Aby znaleźć minimum, obliczamy pochodną po c i przyrównujemy do 0.

$$\begin{aligned} \frac{dJ}{dc_i} &= \sum_{x \in C_i} (x^2 - 2xc_i + c_i^2)' \\ &= \sum_{x \in C_i} (-2x + 2c_i) \\ &= 2 \cdot |C_i| \cdot c_i - 2 \cdot \sum_{x \in C_i} x = 0 \end{aligned} \quad (55.184)$$

$$\begin{aligned} 2 \cdot |C_i| \cdot c_i &= 2 \cdot \sum_{x \in C_i} x \\ c_i &= \frac{1}{|C_i|} \sum_{x \in C_i} x \end{aligned}$$

■

b) **Theorem 55.6.** $\sum_{i=1}^k \sum_{x \in C_i} |x - c_i|$, centroid ma postać mediany punktów w klastrze

Podobnie jak w podpunkcie a) obliczamy pochodną kosztu centroidu c_i :

$$J(c_i) = \sum_{x \in C_i} |x - c_i| \quad (55.185)$$

$$\begin{aligned} \frac{dJ}{dc} &= \sum_{x \in C} \frac{d}{dc} |x - c_i| \\ &= \sum_{x \in C} -\text{sgn}(x - c_i) = 0 \end{aligned} \quad (55.186)$$

Suma znaków wyrażeń $x - c_i$ będzie równa zero tylko i wyłącznie wtedy kiedy będzie tyle samo wyrażeń -1 czyli $x < c_i$ co wyrażeń $+1$ produkowanych przez $x > c_i$:

$$|\{x \in C_i : x < c_i\}| = |\{x \in C_i : x > c_i\}| \quad (55.187)$$

a to z kolei znaczy że c_i dzieli zbiór punktów C_i idealnie na poł co jest definicją mediany.

56. Ćwiczenie 56 – DBSCAN

56.1. Działanie DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) grupuje punkty na podstawie gęstości ich rozmieszczenia.

1. Dla każdego punktu sprawdzamy jego ε -sąsiedztwo.
2. Jeśli punkt ma co najmniej $MinPts$ sąsiadów, staje się **rdzeniem** (core point) i tworzy nowy klaster.
3. Do klastra dołączane są wszystkie punkty osiągalne gęstościowo (sąsiedzi rdzenia, sąsiedzi ich sąsiadów itd.).
4. Punkty, które nie są rdzeniami, ale leżą w sąsiedztwie rdzenia, to **punkty brzegowe**.
5. Punkty nieprzypisane do żadnego klastra to **szum** (noise).

56.2. Ustalanie parametrów

- **MinPts:** Zazwyczaj ustala się jako $2 \cdot d$ (gdzie d to wymiar danych). Dla większych zbiorów z szumem warto zwiększyć tę wartość.
- **ε (epsilon):** Stosuje się metodę **k-distance graph**. Obliczamy odległość każdego punktu do jego k -tego najbliższego sąsiada (gdzie $k = MinPts - 1$). Sortujemy te odległości i wykreślamy. Punkt „kolanka” (gwałtownego wzrostu wykresu) wskazuje optymalne ε .

56.3. Porównanie k-means i DBSCAN

k-means	DBSCAN
Wymaga podania liczby klastrów k .	Sam ustala liczbę klastrów.
Zakłada kulisty kształt klastrów.	Wykrywa klastry o dowolnych kształtach.
Wrażliwy na szum (przypisuje wszystko).	Odporny na szum (oznacza jako noise).
Szybki ($O(n)$).	Wolniejszy w pesymistycznym przypadku ($O(n^2)$), ale $O(n \log n)$ z indeksowaniem.
Działa dobrze, gdy gęstość jest zmienna.	Problemy przy klastrach o bardzo różnej gęstości.

56.4. Co lepsze dla dokumentów (dane wielowymiarowe)?

Dla zbioru dokumentów (bardzo wysoki wymiar, rzadkie dane) zazwyczaj **k-means** (często w wariacie sferycznym lub z metryką cosinusową) okazuje się skuteczniejszy. DBSCAN w bardzo wielu wymiarach cierpi na „klątwę wymiarowości” – odległości między wszystkimi punktami stają się do siebie zbliżone, co utrudnia dobranie sensownego ε i odróżnienie gęstych regionów od rzadkich.

57. Ćwiczenie 57 — Klasteryzacja hierarchiczna

57.1. Działanie

Klasteryzacja hierarchiczna (aglomeracyjna) zaczyna od sytuacji, gdzie każdy punkt jest osobnym klastrem. W każdym kroku łączy dwa najbliższe klastry w jeden, aż wszystkie punkty znajdą się w jednym klastrze. Wynikiem jest dendrogram (drzewo połączeń).

57.1.1. Single Linkage

Odległość między klastrami to odległość między **najbliższymi** punktami z tych klastrów.

1. Najmniejsze odległości to 2 (pary $\{1,3\}$ oraz $\{8,10\}$). Łączymy je.

- Klastry: $\{1,3\}$, $\{8,10\}$, $\{16\}$.


2. Odległości między nowymi klastrami:

- $d(\{1,3\}, \{8,10\}) = d(3,8) = 5$
- $d(\{8,10\}, \{16\}) = d(10,16) = 6$

Najmniejsza to 5. Łączymy $\{1,3\}$ i $\{8,10\}$.

- Klastry: $\{1,3,8,10\}$, $\{16\}$.

3. Łączymy wszystko z $\{16\}$. Odległość: $d(10,16) = 6$.



57.1.2. Complete Linkage

Odległość między klastrami to odległość między **najdalszymi** punktami.

1. Najmniejsze odległości to 2. Łączymy $\{1,3\}$ i $\{8,10\}$.

- Klastry: $\{1,3\}$, $\{8,10\}$, $\{16\}$.


2. Aktualizujemy macierz odległości (bierzemy maksimum):

- $d(\{1,3\}, \{8,10\}) = d(1,10) = 9$
- $d(\{8,10\}, \{16\}) = d(8,16) = 8$
- $d(\{1,3\}, \{16\}) = d(1,16) = 15$

Najmniejsza z tych wartości to 8. Łączymy $\{8,10\}$ i $\{16\}$.

- Klasy: $\{1, 3\}, \{8, 10, 16\}$.

3. Łączymy pozostałe dwie grupy. Odległość to $\max(d(1, 16), d(3, 16)) = 15$.



57.2. Ustalanie liczby klastrów z dendrogramu

Należy „ciąć” dendrogram w miejscu, gdzie występuje najdłuższa pionowa linia (największy skok odległości) bez przecinania poziomych linii łączenia. Sugeruje to dużą separację między powstałymi grupami.

58. Ćwiczenie 58 – Wybór metody dla klastrów o nietypowych kształtach

58.1. Poprawne metody:

- **DBSCAN** z odpowiednio dobranymi parametrami: DBSCAN grupuje na podstawie gęstości. Ponieważ linia i okrąg są gęstymi zbiorami punktów oddzielonymi pustą przestrzenią, DBSCAN poradzi sobie bez problemów.
- **Klasteryzacja hierarchiczna - single linkage**: Efektem algorytmu single linkage jest łańcuchowanie się punktów. Jeśli jakiś punkt nie należy do klastra ale jego bliski sąsiad należy, to klaster przyjmie też ten punkt nie zwracając uwagi na to jak daleko jest od centroidu.

58.2. Niepoprawne metody:

- **K-Means**: dąży do tworzenia klastrów wypukłych, najlepiej w kształcie okręgu, o podobnych wielkościach. W tym przypadku linia nie jest okrągła więc K-Means najprawdopodobniej ją podzieli.
- **Klasteryzacja hierarchiczna - complete linkage**: Preferuje małe zwarte zbiory. Najprawdopodobniej będzie próbował podzielić linie na mniejsze zbiory.