

Algorytmiczna Analiza Danych

Wszystkie Ćwiczenia

2026-01-09

Adrian Herda
Politechnika Wrocławska

Spis treści

1.	Zadanie 1	5
1.1.	Podpunkt a) wynagrodzenie prezesa a czynniki firmowe	5
1.2.	Podpunkt b) wprowadzenie nowego produktu na rynek	5
1.3.	Podpunkt c) prognozowanie zmian kursu dolara	5
2.	Zadanie 2	5
2.1.	Klasyfikacja	6
2.1.1.	Przykład 1 - rozpoznawanie rodzajów wina	6
2.1.2.	Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami	6
2.2.	Regresja	6
2.2.1.	Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)	6
2.2.2.	Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów	6
2.3.	Analiza klastrow	7
2.3.1.	Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)	7
2.3.2.	Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach	7
3.	Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne	7
3.1.	Parametryczne	8
3.2.	Nieparametryczna	8
3.3.	Zalety i wady	9
4.	Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)	9
4.1.	a) odległość euklidesowa dla każdego punktu	9
4.2.	b) predykcja dla $K = 1$	9
4.3.	c) predykcja dla $K = 3$	9
4.4.	d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa	9
5.	Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych	10
5.1.	a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$	10
5.2.	b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$	10
6.	Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami ...	10
6.1.	Definicje	11
6.2.	Przykłady	11
6.2.1.	Nieobciążony	11

6.2.2.	Obciążony	11
7.	Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza	11
7.1.	Wnioski	12
8.	Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu	13
8.1.	Rozwiązanie	13
8.2.	Równowaga bias-variance	13
9.	Zadanie 9 - Wykresy względem elastyczności modelu	14
9.1.	Wytlumaczenie każdej funkcji	14
10.	Zadanie 10 - Obliczanie wzorów na parametry modelu linowego	14
10.1.	Dane	14
10.2.	Cel	15
10.3.	Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$	16
11.	Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym	16
11.1.	Błąd systematyczny	17
11.2.	Wariancja	17
11.2.1.	Reprezentacja estymatorów za pomocą szumów	17
11.2.2.	Wariancja estymatorów	17
11.3.	Błąd standardowy estymatorów	18
12.	Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny	18
13.	Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale	20
13.1.	Reguła trzech sigm	20
13.2.	Ustandaryzowana zmienna	20
14.	Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami	21
14.1.	Teza	21
14.2.	Dowód	21
15.	Zadanie 15 - Korelacja	23
16.	Zadanie 16 - t-statystyka i p-wartość	24
16.1.	t-statystyka	24
16.2.	p-wartość	24
17.	Zadanie 17 - Odległość Mahalanobisa	24
17.1.	odpowiedź	24
18.	Zadanie 18 - Double descent	24
18.1.	Odpowiedź	25
19.	Zadanie 19	26
19.1.	Odpowiedź	26
19.1.1.	Definicja	26
19.1.2.	Własności	26
20.	Zadanie 20	27
20.1.	Rozwiązanie	27
21.	Zadanie 21	28
21.1.	Rozwiązanie	28
22.	Zadanie 22	29
22.1.	Rozwiązanie	29
22.2.	Czy estymator nieobciążony?	29

23.	Zadanie 23	30
23.1.	a) $p = 1$	30
23.2.	b) $p = 2$	30
23.3.	c) $p = 100$	30
23.4.	d)	30
23.5.	e)	31
23.5.1.	Wzór	31
23.5.2.	Wyniki	31
24.	Zadanie 24 – Ocena modelu w problemie klasyfikacji	32
24.1.	Oznaczenia	32
24.2.	a) Metryki: Accuracy, Precision, Recall oraz F1	32
24.2.1.	Definicje metryk	32
24.2.2.	Przykład	32
24.3.	b) Różnica wersji <i>micro</i> od <i>macro</i>	33
24.4.	c) Potoczne rozumienie a definicja	33
25.	Zadanie 25 – Naiwny Klasyfikator Bayesa	33
25.1.	Definicja	33
25.2.	Dowód wzoru	33
26.	Zadanie 26 – Klasyfikacja Spam vs Nie-spam	34
27.	Zadanie 27 – Regresja Logistyczna	35
27.1.	a) Dlaczego nie regresja liniowa?	35
27.2.	b) Obliczenie szans (Odds)	35
27.3.	c) Dowód równoważności z Log-Odds	35
27.4.	d) Zależność sigma a logit	36
28.	Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych	37
29.	Ćwiczenie 29 – Funkcja Softmax	37
29.1.	Wzór i intuicja	37
29.1.1.	Intuicja	38
29.1.2.	Dlaczego „ciągły argmax”?	38
29.2.	Klasyfikacja wieloetykietowa (Multi-label)	38
30.	Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax	38
30.1.	Macierz Jacobiego	38
30.2.	Analiza znaków pochodnych	39
31.	Ćwiczenie 31 – Gradient Entropii Krzyżowej	39
32.	Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)	40
33.	Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa	41
34.	Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL	41
34.1.	Związek między miarami	42
35.	Ćwiczenie 35 – Entropia różniczkowa	42
35.1.	Definicja	42
35.2.	Ujemna wartość entropii różniczkowej	42
35.3.	Skalowanie zmiennej ($H(aX)$)	43
35.4.	Maksymalna entropia rozkładu normalnego	43
36.	Ćwiczenie 36 – Miary odległości między rozkładami	43
37.	Ćwiczenie 37 – Własności próby bootstrapowej	45
37.1.	Wartość oczekiwana X	45
37.2.	Wariancja X	45
37.3.	Odsetek unikalnych obserwacji i jego wariancja	46

37.3.1.	Średnia	46
37.3.2.	Wariancja	46
37.4.	Prawdopodobieństwo braku obserwacji w k próbkach	46
38.	Ćwiczenie 38 – Konstrukcja drzewa i predyktory katagoryczne	47
38.1.	Konstrukcja drzewa	47
38.2.	Problem z predyktorem katagorycznym	47
38.3.	Rozwiązanie problemu	47
39.	Ćwiczenie 39 – Miary jakości podziału	47
39.1.	a) Interpretacja indeksu Giniego	47
39.2.	b) Porównanie podziałów	48
39.3.	Obliczenie Indeksu Giniego	48
39.3.1.	Wniosek	49
40.	Zadanie 40 – Współczynnik Giniego	50
40.1.	Intuicja geometryczna (Krzywa Lorenza)	50
40.2.	Pozycja Polski w OECD	50
40.3.	Poziom graniczny napięcie społecznych	50
41.	Zadanie 41 – Algorytm Random Forest	51
41.1.	Pseudokod	51
41.2.	Predykcja	51
42.	Ćwiczenie 42 – Algorytm Boosting (Regresja)	51
42.1.	Pseudokod (na podstawie ISL)	51
42.2.	Wyjaśnienie kluczowych parametrów	51
43.	Zadanie 43 – Obliczenia PCA	52
43.1.	Średnia każdej zmiennej	52
43.2.	Macierz kowariancji	52
43.3.	Wartości własne i wektory własne	52
43.4.	Interpretacja	53
44.	Zadanie 44 – Ortogonalność wektorów własnych	54
45.	Zadanie 45 – Prawda czy Fałsz o PCA	54

Algorytmiczna Analiza Danych

Ćwiczenia 2

14 października 2025 r.

Adrian Herda

Informatyka Algorytmiczna

Politechnika Wrocławska

1. Zadanie 1

Wyjaśnij, czy dany scenariusz jest związany z problemem klasyfikacji, czy regresji, oraz wskaż, czy bardziej interesuje nas wnioskowanie (ang. inference), czy przewidywanie (ang. prediction). Podaj rozmiar próby n i liczbę predyktorów p

1.1. Podpunkt a) wynagrodzenie prezesa a czynniki firmowe

Typ problemu: problem regresji - wynagrodzenie to zmienna ciągła

Cel: wnioskowanie - chcemy zrozumieć zależności a nie przewidzieć przyszłe zarobki prezesów

Rozmiar próby n : 500 - liczba firm

Liczba predyktorów p : 3 - zysk, liczba pracowników, branża - predyktory do dane które pozwalają na znalezienie korelacji

1.2. Podpunkt b) wprowadzenie nowego produktu na rynek

Typ problemu: problem klasyfikacji - kategoryzujemy produkty na te które odniosły sukces lub porażkę, są dwie klasy

Cel: przewidywanie - chcemy przewidzieć jak produkt poradzi sobie na rynku

Rozmiar próby n : 20 - liczba podobnych produktów

Liczba predyktorów p : 3 - cena, cena bezpośredniej konkurencji, budżet marketingowy

1.3. Podpunkt c) prognozowanie zmian kursu dolara

Typ problemu: problem regresji - procentowe zmiany kursu to wartość liniowa

Cel: przewidywanie - „*prognoza*” to próba przewidzenia danych w przyszłości

Rozmiar próby n : 52 - liczba tygodni w roku

Liczba predyktorów p : 4 - liczba porównywanych rynków akcji: USA, Wielka Brytania, Niemcy, Japonia

2. Zadanie 2

Praktyczne zastosowania uczenia maszynowego: dla każdego z poniższych punktów zaproponuj dwa niesztafpowe praktyczne zastosowania. Opisz jakie dane są potrzebne w wybranych zastosowaniach, np. jakie cechy (ang. features) mogą zostać użyte jako predyktory, a jakie odpowiedzi, czy potrzebna jest duża liczba obserwacji.

2.1. Klasyfikacja

2.1.1. Przykład 1 - rozpoznawanie rodzajów wina

- Predyktory:
 - gęstość / lepkość
 - zapach
 - kolor
 - smak
- Odpowiedzi
 - rodzaje wina

Potrzebna jest duża ilość obserwacji ze względu na ilość rodzajów wina oraz ze względu na podobieństwo niektórych rodzajów.

2.1.2. Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami

- Predyktory:
 - ton mowy
 - tempo mowy
 - używane wyrażenia
 - głośność
- Odpowiedzi
 - odpowiedzi na pytanie o zadowolenie z obsługi (bardzo pozytywne, pozytywne, neutralne, negatywne, bardzo negatywne)

Potrzebna jest duża ilość danych ponieważ ludzkie emocje są bardzo skomplikowane i często niezrozumiałe nawet dla nas samych. Nawet do setek tysięcy

2.2. Regresja

2.2.1. Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)

- Predyktory:
 - kolor włosów
 - zmarszczki
 - proporcje oczu do głowy (szczególnie u dzieci)
 - kolor skóry
 - przebarwienia
- Odpowiedzi:
 - wiek

Potrzebne może być nawet do dziesiątek tysięcy obserwacji może być potrzebne gdyż fizjologia ludzka jest skomplikowana

2.2.2. Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów

- Predyktory:
 - skład chemiczny
 - gęstość
 - porowatość

- temperatura
- wilgotność
- rodzaj środowiska (gleba, woda, kompost).
- Odpowiedź:
 - czas rozkładu

Potrzebne będą setki eksperymentów laboratoryjnych i terenowych.

2.3. Analiza klastrow

2.3.1. Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)

- Predyktory:
 - tempo
 - tonacja
 - analiza tekstu - używane słowa i wyrażenia
 - głośność
 - użyte instrumenty
 - użyte narzędzia modyfikowania dźwięku
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: muzyka melancholijna, wesoła, skoczna, buntownicza

Setki tysięcy lub nawet miliony utworów będą potrzebne by znaleźć widocznie wyróżniające się klastry.

2.3.2. Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach

- Predyktory:
 - średnia wartość zakupów
 - częstotliwość zakupów
 - najczęściej kupowane i przeglądane oferty
 - ocena satysfakcji klienta
 - lokalizacja klienta (może być nie dokładna, np. region - ciepły czy zimny)
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: klient zainteresowany ciuchami zimowymi / letnimi, wędkarz, sportowiec, kolekcjoner butów, stały klient, klient jednorazowy

Setki tysięcy klientów będą potrzebne by znaleźć wyróżniające się klastry.

3. Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne

Opisz różnice między parametrycznym a nieparametrycznym podejściem do uczenia statystycznego. Jakie są wady i zalety podejścia parametrycznego w porównaniu do podejścia nieparametrycznego?

3.1. Parametryczne

Zakłada pewien rozkład danych, za pomocą skończonej (nie ogromnej) ilości parametrów. Umożliwia stosunkowo łatwą analizę modelu ale sprawia że jest ona tylko przybliżeniem. To podejście jest też mniej elastyczne i jest podatne na błędy związane z biasem.

3.2. Nieparametryczna

Nie wymaga założeń co do rozkładu danych . Model uczy się bardziej elastycznie dopasowując się do obserwacji. Dzięki temu otrzymujemy mniejszy bias ale możliwym jest zbyt dopasować model do danych (ang. overfitting). Podejście to wymaga dużej liczby obserwacji i przez to jest bardziej kosztowne niż podejście parametryczne.

3.3. Zalety i wady

	Uczenie parametryczne	Uczenie nieparametryczne
Zalety	• mały wariancja • łatwość analizy i interpretacji modelu • niski koszt obliczeń	• mały bias • duża elastyczność i dopasowanie do danych • Nie wymaga założeń o danych
Wady	• duży bias • mała elastyczność • słaba moc predykcyjna • wymaga założeń o danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń

4. Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)

4.1. a) odległość euklidesowa dla każdego punktu

1. $\sqrt{0^2 + 3^2 + 0^2} = \sqrt{9} = 3$,
2. $\sqrt{2^2 + 0^2 + 0^2} = \sqrt{4} = 2$,
3. $\sqrt{0^2 + 1^2 + 3^2} = \sqrt{10}$,
4. $\sqrt{0^2 + 1^2 + 2^2} = \sqrt{5}$,
5. $\sqrt{(-1)^2 + 0^2 + 1^2} = \sqrt{2}$,
6. $\sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}$

4.2. b) predykcja dla $K = 1$

Bierzemy najbliższego sąsiada którym jest obserwacja 5 i bierzemy jego odpowiedź → **Green**

4.3. c) predykcja dla $K = 3$

Bierzemy 3 najbliższych sąsiadów którymi są obserwacje 5 → Green, 6 → Red oraz 2 → Red i bierzemy najpopularniejszą odpowiedź wśród tych obserwacji → **Red**

4.4. d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa

Jeśli granica decyzyjna Bayesa jest silnie nieliniowa (czyli prawdziwa granica między klasami jest bardzo złożona), to potrzebujemy bardziej elastycznego modelu, aby tę złożoność uchwycić. Małe wartości K dają klasyfikatorowi KNN większą elastyczność (niższy bias, wyższa wariancja) i pozwalają na odwzorowanie skomplikowanych, lokalnych zależności. Dlatego przy silnie nieliniowej granicy Bayesa zwykle lepiej sprawdzają się małe wartości K . (Przy przeciwnym założeniu — gładkiej granicy — większe K redukuje wariancję i może dać lepsze wyniki).

5. Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych

$$\text{Cov}(X, Y) = 0 \quad (5.1)$$

5.1. a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$

Proof.

$$\begin{aligned} \mathbb{E}(X + Y) &= \sum_x \sum_y (x + y) \Pr(X = x, Y = y) \\ &= \sum_x \sum_y x \cdot \Pr(X = x, Y = y) + \sum_x \sum_y y \cdot \Pr(X = x, Y = y) \\ &= \sum_x x \cdot \left(\sum_y \Pr(X = x, Y = y) \right) + \sum_y y \cdot \left(\sum_x \Pr(X = x, Y = y) \right) \quad (5.2) \\ &= \sum_x x \cdot \Pr(X = x) + \sum_y y \cdot \Pr(Y = y) \\ &= \mathbb{E}(X) + \mathbb{E}(Y) \end{aligned}$$

■

5.2. b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Proof.

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mathbb{E}(X))^2] \wedge (1) \\ &\Downarrow \end{aligned} \quad (5.3)$$

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X + Y - \mathbb{E}(X + Y))^2] \\ &= \mathbb{E}[((X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y)))^2] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2 + (Y - \mathbb{E}(Y))^2 + 2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2] + \mathbb{E}[(Y - \mathbb{E}(Y))^2] + \mathbb{E}[2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \quad (5.4) \\ &= \text{Var}(X) + \text{Var}(Y) + \underbrace{2 \cdot \text{Cov}(X, Y)}_0 \\ &= \text{Var}(X) + \text{Var}(Y) \end{aligned}$$

■

6. Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami

Przypomnij, co to jest estymator oraz co to jest obciążenie (ang. bias) i wariancja estymatora. Podaj przykłady estymatorów obciążonych i nieobciążonych

6.1. Definicje

Estymator - To funkcja mająca za zadanie przybliżyć (wyestymować) wybrany parametr.

$$\theta \approx \hat{\theta}(X_1, X_2, \dots, X_n) \quad (6.5)$$

Bias estymatora - Jest wartość opisująca tendencję estymatora do zawyżania lub zaniżania wartości estymowanej

$$\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta \quad (6.6)$$

- Estymator nazywamy obciążonym gdy $\text{Bias}(\hat{\theta}) \neq 0$
- Estymator nazywamy nieobciążonym gdy $\text{Bias}(\hat{\theta}) = 0 \Rightarrow \mathbb{E}(\hat{\theta}) = \theta$

Wariancja estymatora - służy ocenianiu jak daleko, zazwyczaj, będzie estymator od estymowanej wartości

$$\text{Var}(\hat{\theta}) = \mathbb{E}\left(\left(\mathbb{E}(\hat{\theta}) - \hat{\theta}\right)^2\right) \quad (6.7)$$

MSE - Mean Square Error (ang. Błąd średniokwadratowy) tak samo jak wariancja

$$\text{MSE}(\hat{\theta}) = \mathbb{E}\left(\left(\hat{\theta}(X) - \theta\right)^2\right) \quad (6.8)$$

6.2. Przykłady

6.2.1. Nieobciążony

Typ estymatora	Przykład	Obciążenie
Średnia z próby	$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$	$\mathbb{E}(\hat{\mu}) = \mu \Rightarrow \text{Bias}(\hat{\mu}) = 0$
Wariancja z $n-1$	$\hat{\sigma}_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_{n-1}^2) = \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_{n-1}^2) = 0$

6.2.2. Obciążony

Typ estymatora	Przykład	Obciążenie
Wariancja z n	$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_n^2) = \frac{n-1}{n} \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_n^2) = -\frac{\sigma^2}{n}$
$X \sim \text{Exp}(\lambda)$	MLE $\hat{\lambda} = \frac{1}{\bar{X}}$	$\mathbb{E}(\hat{\lambda}) = \frac{n}{n-1} \Rightarrow \text{Bias}(\hat{\lambda}) = \frac{1}{n-1} \lambda$

7. Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza

Szukamy odpowiedniego modelu dla problemu związanego z uczeniem nadzorowanym. Dla każdego z punktów od (a) do (d), wskaż, czy ogólnie oczekivalibyśmy, że mało „elastyczny” model będzie lepszy czy gorsza od bardziej „elastycznego”. Uzasadnij swoją odpowiedź.

- Rozmiar próby n jest bardzo duży, a liczba predyktorów (and. predictor) p jest mała.
- Liczba predyktorów p jest bardzo duża, a liczba obserwacji n jest mała.
- Zależność między predyktorami a odpowiedzią (and. response) wykazuje wyraźnie nieliniowy charakter.
- Wariancja błędów, tj. $\sigma^2 = \text{Var}(\varepsilon)$, jest bardzo wysoka.

Sformułuj wnioski dotyczące tego, jakie są zalety i wady bardziej elastycznego modelu, w porównaniu z mniej elastycznym? W jakich okolicznościach bardziej elastyczny model może być preferowany? Kiedy preferowany może być mniej elastyczny model?

Przypadek	Elastyczność modelu	Uzasadnienie
a) n - duże, p - małe	Bardziej elastyczny	Elastyczny model może wykorzystać dużą liczbę obserwacji aby dopasować się i dzięki temu obniża bias
b) n - małe p - duże	Mniej elastyczny	Duża liczba predyktorów grozi overfittingiem, należy najpierw dokonać redukcji wymiaru tak aby p było mniejsze od n a następnie wykorzystać mniej elastyczny model aby uzyskać model zwiększyć wydajność na małej ilości danych
c) silna nieliniowość danych	Bardziej elastyczny	Elastyczny model lepiej dopasuje się do danych i lepiej przedstawi nieliniowość, nie uśredniając jej tak jak zrobiłby to model mniej elastyczny
d) Wysoka wariancja szumu	Mniej elastyczny	Mniej elastyczny model uśredni dane i zniweluje w ten sposób wysoką wariancję szumu

7.1. Wnioski

	Model mniej elastyczny	Model bardziej elastyczny
Zalety	• stabilny, z małą wariancją • łatwiejszy do interpretacji • bardziej odporny na szum • sprawdza się lepiej dla małych n względem p	• niski bias • świetny dla dużych n • uchwyci złożone zależności
Wady	• duży bias • słaby przy dużej nieliniowości danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń • kiepski dla małych n • ryzyko overfittingu

Algorytmiczna Analiza Danych

Ćwiczenia 3

17 października 2025 r.

Adrian Herda
Politechnika Wrocławska

8. Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu

$$MSE = \mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \quad (8.9)$$

8.1. Rozwiązanie

1. $\mathbb{E}[\varepsilon] = 0 \Rightarrow \mathbb{E}[\varepsilon]^2 = 0 \Rightarrow \sigma_\varepsilon^2 = \mathbb{E}[\varepsilon^2]$
2. Szum jest niezależny z żadną inną zmienną

Proof.

$$\begin{aligned} \mathbb{E}[(y_0 - \hat{f}(x_0))^2] &= \mathbb{E}[(f(x_0) + \varepsilon - \hat{f}(x_0))^2] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \underbrace{\mathbb{E}[\varepsilon^2]}_{\sigma_\varepsilon^2} + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \sigma_\varepsilon^2 + \underbrace{2(f(x_0) - \mathbb{E}[\hat{f}(x_0)])\mathbb{E}[\varepsilon]}_0 \\ &= \mathbb{E}[f(x_0)^2 + \hat{f}(x_0)^2 - 2f(x_0)\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 + \mathbb{E}[\hat{f}(x_0)^2] - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \underbrace{\mathbb{E}[\hat{f}(x_0)]^2 - \mathbb{E}[\hat{f}(x_0)]^2}_0 + \mathbb{E}[\hat{f}(x_0)^2] + \sigma_\varepsilon^2 \\ &= (f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2 + (\mathbb{E}[\hat{f}(x_0)^2] - \mathbb{E}[\hat{f}(x_0)]^2) + \sigma_\varepsilon^2 \\ &= \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \end{aligned} \quad (8.10)$$


■

8.2. Równowaga bias-variance

W miarę jak model staje się bardziej elastyczny, jego zdolność do uchwycenia złożoności danych rośnie, co prowadzi do zmniejszenia błędu bias. Jednakże, większa elastyczność może również prowadzić do większej wariancji, ponieważ model może zacząć „przeuczać” się na dane treningowe. W rezultacie, istnieje kompromis między bias a wariancją, który należy uwzględnić podczas projektowania modeli.

Optymalny wybór złożoności/regularizacji minimalizuje sumę $\text{Bias}^2 + \text{Var}$.
Składnik ε jest nieredukowalny.

9. Zadanie 9 - Wykresy względem elastyczności modelu



9.1. Wytlumaczenie każdej funkcji

Niebieski - W miarę jak modele stają się bardziej elastyczne i złożone, błąd treningowy maleje, ale z coraz mniejszym zyskiem.

Czerwony - Często obserwujemy kształt litery U w błędzie na zbiorze walidacyjnym. Jest to kombinacja błędu Bias (obserwowanego przy najmniej elastycznym modelu), błędu Variance (wynikającego z przeuczenia najbardziej elastycznych modeli) oraz składnika błędu nieusuwalnego.

Niebieski - Składnik błędu Bias, im bardziej elastyczny model tym lepiej się dopasowuje tym mniejszy jest Bias.

Brązowy - Składnik błędu Variance. Im bardziej elastyczny model tym większe różnice w wynikach na zbiorze treningowym i walidacyjnym.

Czarny - Składnik błędu nieusuwalnego. Niezmienna wartość szumu.

10. Zadanie 10 - Obliczanie wzorów na parametry modelu linowego

10.1. Dane

- n obserwacji: $\{(x_1, y_1), \dots, (x_n, y_n)\}$,
- model linowy: $y_i = \beta_0 + \beta_1 x_i + e_i$

10.2. Cel

Szacujemy β_0, β_1 poprzez minimalizację błędu średniokwadratowego:

$$\text{MSE}(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \quad (10.11)$$

Udowodnij że:

1. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
2. $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

Proof. Różniczkujemy i przyrównujemy do zera:

$$\frac{\partial}{\partial \hat{\beta}_0} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.12)$$

$$\frac{\partial}{\partial \hat{\beta}_1} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.13)$$

Z równania (10.12) mamy:

$$\begin{aligned} \sum_{i=1}^n y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i &= 0 \\ n\hat{\beta}_0 &= \sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned} \quad (10.14)$$

Podstawiając do równania (10.13) mamy:

$$\begin{aligned}
0 &= \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \cdot n\bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\bar{y}\bar{x} - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2\bar{x}x_i + \sum_{i=1}^n \bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n \bar{y}x_i + \sum_{i=1}^n \bar{y}\bar{x} - \sum_{i=1}^n \bar{x}y_i \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) &= \sum_{i=1}^n (x_i y_i - \bar{y}x_i) + (\bar{y}\bar{x} - \bar{x}y_i) \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - \bar{x}^2) &= \sum_{i=1}^n x_i(y_i - \bar{y}) - \bar{x}(y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}
\end{aligned} \tag{10.15}$$

■

10.3. Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$

Proof. Podstawiając $x = \bar{x}$ do równania (10.12) prostej:

$$\begin{aligned}
y &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \\
&= (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} \\
&= \bar{y}
\end{aligned} \tag{10.16}$$

■

11. Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym

$$y_i = \beta_0 + \beta_1 x_i + e_i \tag{11.17}$$

Estymaotry jak w modelu z zadania w sekcji 10.

Oraz niech: $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$

11.1. Błąd systematyczny

$$E[\hat{\beta}_0] = \beta_0 \Rightarrow \text{Bias}(\hat{\beta}_0) = 0 \quad (11.18)$$

$$E[\hat{\beta}_1] = \beta_1 \Rightarrow \text{Bias}(\hat{\beta}_1) = 0 \quad (11.19)$$

11.2. Wariancja

Zmienne e_i dla $i \in \{1, \dots, n\}$ są niezależne

11.2.1. Reprezentacja estymatorów za pomocą szumów

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.20)$$

$$\hat{\beta}_0 = \beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.21)$$

11.2.2. Wariancja estymatorów

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \text{Var}\left(\frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \frac{1}{(S_{xx})^2} \text{Var}\left(\sum_{i=1}^n (x_i - \bar{x})e_i\right) \\ &= \frac{1}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) \\ &= \frac{\sigma^2}{S_{xx}} \end{aligned} \quad (11.22)$$

$$\begin{aligned}
\text{Var}(\hat{\beta}_0) &= \text{Var}\left(\beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i\right) + \text{Var}\left(\bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) - 2 \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n e_i, \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(e_i) + \frac{\bar{x}^2}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) - 2 \frac{\bar{x}}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \text{Var}(e_i) \quad (11.23) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \cdot 0 \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} \\
&= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)
\end{aligned}$$

11.3. Błąd standardowy estymatorów

$$\text{SE}(\hat{\beta}_0) = \sqrt{\text{Var}(\hat{\beta}_0)} = \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} = \sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \quad (11.24)$$

$$\text{SE}(\hat{\beta}_1) = \sqrt{\text{Var}(\hat{\beta}_1)} = \sqrt{\frac{\sigma^2}{S_{xx}}} = \frac{\sigma}{\sqrt{S_{xx}}} \quad (11.25)$$

12. Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny

1. $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$
2. $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$
3. $Z = X + Y$

Udowodnij że $Z \sim \mathcal{N}(\mu_Z, \sigma_Z^2)$

Proof. Funkcje charakterystyczne zmiennych losowych:

$$\varphi_X(t) = \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right), \quad \varphi_Y(t) = \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \quad (12.26)$$

Zmienna losowa Z jest sumą niezależnych zmiennych losowych X i Y , więc jej funkcja charakterystyczna jest iloczynem funkcji charakterystycznych X i Y :

$$\begin{aligned}\varphi_Z(t) &= \varphi_X(t) \cdot \varphi_Y(t) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right) \cdot \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2} + i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i(\mu_X + \mu_Y)t - (\sigma_X^2 + \sigma_Y^2) \frac{t^2}{2}\right) \\&= \exp\left(i\mu_Z t - \sigma_Z^2 \frac{t^2}{2}\right)\end{aligned}\tag{12.27}$$

■

Algorytmiczna Analiza Danych

Ćwiczenia 4

24 października 2025 r.

Adrian Herda
Politechnika Wrocławska

13. Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale

Jako że $e_i \sim \mathcal{N}(0, \sigma^2)$ oraz są niezależne, to zgodnie z własnościami rozkładu normalnego, estymator $\hat{\beta}_1$ również ma rozkład normalny z wartością oczekiwaną równą β_1 oraz wariancją $\text{Var}(\hat{\beta}_1)$.

13.1. Reguła trzech sigm

Reguła trzech sigm mówi, że w rozkładzie normalnym ok. 99.7% masy leży w przedziale $\mathbb{E}[X] \pm 3\sigma_X$ dla każdej zmiennej losowej $X \sim \mathcal{N}(\mathbb{E}[X], \sigma_X)$. Dla $\mathbb{E}[X] \pm 2\sigma_X$ mamy ok. 95%.

To tylko krótkie heurystyczne odwołanie do „regułki 68 – 95 – 99.7” dla rozkładu normalnego ($1\sigma \approx 68\%$, $2\sigma \approx 95\%$, $3\sigma \approx 99.7\%$).

13.2. Ustandaryzowana zmienna

Niech

$$Z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim \mathcal{N}(0, 1) \quad (13.28)$$

Wtedy:

$$\Pr(|\hat{\beta}_1 - \beta_1| \leq 2\sqrt{\text{Var}(\hat{\beta}_1)}) = \Pr(|Z| \leq 2) \quad (13.29)$$

Ze wzoru na gęstość prawdopodobieństwa w standardowym rozkładzie normalnym mamy:

$$\begin{aligned} \Pr(|Z| \leq 2) &= \int_{-2}^2 \varphi(x) dx \\ &= \Phi(2) - \Phi(-2) \\ &= \Phi(2) - (1 - \Phi(2)) \\ &= 2\Phi(2) - 1 \\ &= 0.9545 \end{aligned} \quad (13.30)$$

14. Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami

14.1. Teza

Estymatory:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} \in \mathbb{R}^{k+1} \quad (14.31)$$

Wzór:

$$\hat{\beta} = (X^T X)^{-1} X^T \vec{y} \quad (14.32)$$

gdzie X to macierz danych a $\vec{y}$ to wektor odpowiedzi.

14.2. Dowód

$$y = f(x) + \varepsilon \quad (14.33)$$

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k \quad (14.34)$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (14.35)$$

$$\vec{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad (14.36)$$

$$\vec{y} = X\beta + \varepsilon$$

$\Downarrow$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \beta_0 + \beta_1 x_{11} + \dots + \beta_k x_{1k} + \varepsilon_1 \\ \beta_0 + \beta_1 x_{21} + \dots + \beta_k x_{2k} + \varepsilon_2 \\ \vdots \\ \beta_0 + \beta_1 x_{n1} + \dots + \beta_k x_{nk} + \varepsilon_n \end{pmatrix} \quad (14.37)$$

$$\varepsilon = \vec{y} - \hat{y} \wedge \text{RSS} = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon^T \varepsilon \quad (14.38)$$

$\Downarrow$

$$\text{RSS} = (\vec{y} - \hat{y})^T (\vec{y} - \hat{y})$$

$$\begin{aligned} J(\hat{\beta}) &= (\vec{y} - X\hat{\beta})^T (\vec{y} - X\hat{\beta}) \\ &= (\vec{y}^T - \hat{\beta}^T X^T) (\vec{y} - X\hat{\beta}) \\ &= \vec{y}^T \vec{y} - \vec{y}^T X\hat{\beta} - \hat{\beta}^T X^T \vec{y} + X^T \hat{\beta}^T X\hat{\beta} \\ &= \vec{y}^T \vec{y} - 2\vec{y}^T X\hat{\beta} + \hat{\beta}^T X^T X\hat{\beta} \end{aligned} \quad (14.39)$$

Chcemy najmniejszą wartość RSS. Liczymy pochodną cząstkową po $\hat{\beta}$ i przyrównujemy do zera:

$$\begin{aligned}\frac{\partial J}{\partial \hat{\beta}} &= 2X^T X \hat{\beta} - 2X^T \vec{y} = 0 \\ X^T X \hat{\beta} &= X^T \vec{y} \\ \hat{\beta} &= (X^T X)^{-1} X^T \vec{y}\end{aligned}\tag{14.40}$$

Algorytmiczna Analiza Danych

Ćwiczenia 5

7 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

15. Zadanie 15 - Korelacja

$$\begin{aligned}
 \text{TSS} &= \sum_{i=1}^n (Y_i - \bar{Y}_i)^2 = S_{yy} \\
 &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y}_i)^2 \\
 &= \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{RSS}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}_{\text{ESS}} - 2 \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}_i)}_{\text{Własność ortogonalności reszt} \rightarrow 0} \\
 &= \text{RSS} + \text{ESS}
 \end{aligned} \tag{15.41}$$

$$\begin{aligned}
 \hat{\beta}_0 &= \bar{Y}_i - \hat{\beta}_1 \bar{X} \\
 \hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\
 &= (\bar{Y}_i - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 X_i \\
 &= \bar{Y}_i + \hat{\beta}_1 (X_i - \bar{X}) \\
 \hat{Y}_i - \bar{Y}_i &= \hat{\beta}_1 (X_i - \bar{X})
 \end{aligned} \tag{15.42}$$

$$\text{ESS} = \hat{\beta}_1^2 S_{yy}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$\begin{aligned}
 R^2 &= 1 - \frac{\text{RSS}}{\text{TSS}} \\
 &= \frac{\text{RSS} + \text{ESS} - \text{RSS}}{\text{TSS}} \\
 &= \frac{\text{ESS}}{\text{TSS}} \\
 &= \left(\frac{S_{xy}}{S_{xx}} \right)^2 \frac{S_{xx}}{S_{yy}} \\
 &= \frac{S_{xy}^2}{S_{xx} S_{yy}} \\
 &= \text{Corr}(X, Y)^2
 \end{aligned} \tag{15.43}$$

■

16. Zadanie 16 - t-statystyka i p-wartość

Wyjaśnij czym jest t-statystyka i w jaki sposób możemy jej użyć w kontekście regresji liniowej. Czym jest p-wartość?

16.1. t-statystyka

t-statystyka to miara używana w statystyce do oceny istotności współczynników regresji w modelu regresji liniowej. Określa, jak wiele standardowych błędów odchyła się estymowany współczynnik od wartości zerowej (hipoteza zerowa). Wzór na t-statystykę dla współczynnika regresji $\hat{\beta}_j$ jest następujący:

$$t_j = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \quad (16.44)$$

gdzie $\text{SE}(\hat{\beta}_j)$ to standardowy błąd estymatora współczynnika regresji $\hat{\beta}_j$.

16.2. p-wartość

p-wartość to prawdopodobieństwo uzyskania wyników co najmniej tak ekstremalnych jak obserwowane, zakładając, że hipoteza zerowa jest prawdziwa. W kontekście regresji liniowej, p-wartość jest używana do oceny istotności statystycznej współczynników regresji. Niska p-wartość (zazwyczaj poniżej 0.05) sugeruje odrzucenie hipotezy zerowej, co oznacza, że istnieje statystycznie istotny związek między zmienną niezależną a zmienną zależną.

17. Zadanie 17 - Odległość Mahalanobisa

Wyjaśnij czym jest odległość Mahalanobisa i jaki jest jej związek z leverage statistic.

17.1. odpowiedź

Odległość Mahalanobisa to miara odległości między punktem a rozkładem prawdopodobieństwa. W przeciwieństwie do standardowej odległości euklidesowej, odległość Mahalanobisa uwzględnia korelacje między zmiennymi i skalę danych. Jest definiowana jako:

$$D_{M(x)} = \sqrt{(x - \mu)^T S^{-1} (x - \mu)} \quad (17.45)$$

gdzie μ to wektor średnich zmiennych, a S to macierz kowariancji.

Odległość Mahalanobisa jest szczególnie użyteczna w kontekście analizy regresji, ponieważ pozwala na identyfikację obserwacji, które są nietypowe lub odstające w kontekście całego zbioru danych. Wartości odległości Mahalanobisa mogą być używane do obliczania statystyki leverage, która mierzy wpływ danej obserwacji na dopasowanie modelu regresji. Obserwacje o wysokiej odległości Mahalanobisa mogą mieć duży wpływ na estymację współczynników regresji i mogą być potencjalnymi punktami odstającymi.

18. Zadanie 18 - Double descent

Na podstawie materiału wideo i rozdziału 10.8 w książce ISL opisz zjawisko double descent

18.1. Odpowiedź

- W fazie podparametryzowanej („under-parameterized”) - model nie ma wystarczającej mocy, by dobrze dopasować dane $\rightarrow$ testowy błąd jest stosunkowo wysoki, ale spada wraz ze wzrostem złożoności.
- Następnie w okolicy punktu, kiedy liczba parametrów $\approx$ liczba próbek (lub model może dokładnie dopasować dane) - następuje wzrost błędu testowego (szczyt) z powodu dużej wariancji, niestabilności.
- Potem, w nadparametryzowanej („over-parameterized”) fazie - mimo że model może „przeuczyć” dane, okazuje się, że zwiększanie złożoności dalej prowadzi do spadku błędu testowego. Model bardzo duży generalizuje lepiej niż średni.

Algorytmiczna Analiza Danych

Ćwiczenia 6

14 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

19. Zadanie 19

Przypomnij, czym jest estymator największej wiarygodności. Przedstaw i wyjaśnij własności takiego estymatora (w szczególności asymptotyczną nieobciążoność i efektywność).

19.1. Odpowiedź

19.1.1. Definicja

Założmy, że mamy próbę losową $X_1, \dots, X_n$ pochodzącą z rozkładu o funkcji gęstości (lub masie prawdopodobieństwa) $f(x; \theta)$, gdzie θ to nieznaną parametr populacji (np. średnia, wariancja, parametr Bernoulliego itd.).

Funkcja wiarygodności (likelihood function) określa prawdopodobieństwo zaobserwowania danej próby przy danym parametrze θ :

$$L(\theta) = f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta) \quad (19.46)$$

albo w postaci logarytmicznej (częściej stosowanej dla wygody obliczeń):

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta) \quad (19.47)$$

Estymator największej wiarygodności (ENW) to wartość $\hat{\theta}$, która maksymalizuje funkcję wiarygodności:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} L(\theta) \quad (19.48)$$

lub równoważnie:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} \ell(\theta) \quad (19.49)$$

19.1.2. Własności

Spójność - Gdy liczba obserwacji $n \rightarrow \infty$ to estymator największej wiarygodności zbliża się do prawdziwej wartości parametru θ

$$\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta \quad (19.50)$$

Efektywność - Przy pewnych warunkach estymator największej wiarygodności zbliża się, w dystrybucji, do rozkładu normalnego:

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \sim \mathcal{N}(0, \mathcal{I}^{-1}) \quad (19.51)$$

gdzie

$$\mathcal{J}_{jk} = \mathbb{E} \left[-\frac{\partial^2 f_{\theta_0}(X_t)}{\partial \theta_j \partial \theta_k} \right] \quad (19.52)$$

to macierz informacji Fishera.

20. Zadanie 20

Założmy, że mamy n obserwacji $x_1, \dots, x_n$ pochodzących z rozkładu normalnego zmiennej losowej $X \sim \mathcal{N}(\mu, \sigma^2)$. Wyprowadź estymator największej wiarygodności dla parametru μ

20.1. Rozwiązanie

$$f(x_i; \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (20.53)$$

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(x_i; \mu) \\ \ell(\mu) &= \sum_{i=1}^n \ln f(x_i; \mu) \\ &= \sum_{i=1}^n \ln \left((2\pi\sigma^2)^{-\frac{1}{2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right) \\ &= \sum_{i=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (20.54)$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\mu} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\mu} &= \frac{d}{d\mu} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right) \\
&= -\frac{1}{2\sigma^2} \frac{d}{d\mu} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n \frac{d}{d\mu} (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n (-2x_i + 2\mu) \\
&= -\frac{1}{\sigma^2} \sum_{i=1}^n (-x_i + \mu) \\
&= \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) \\
&= \sum_{i=1}^n (\mu - x_i) \\
&= n\mu - \sum_{i=1}^n x_i \\
n\mu &= \sum_{i=1}^n x_i \\
\hat{\mu}_{\text{MLE}} &= \frac{1}{n} \sum_{i=1}^n x_i
\end{aligned} \tag{20.55}$$

21. Zadanie 21

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu wykładniczego z nieznanym parametrem λ . Wyprowadź estymator największej wiarygodności dla parametru λ . Wskaż intuicyjnie, dlaczego ten estymator ma sens.

21.1. Rozwiązanie

$$f(x; \lambda) = \lambda e^{-\lambda x} \tag{21.56}$$

$$\begin{aligned}
L(\lambda) &= \prod_{i=1}^n f(x_i; \lambda) \\
&= \lambda^n \exp(-\lambda n x_i) \\
&= \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right) \\
\ell(\lambda) &= n \ln \lambda - \lambda \sum_{i=1}^n x_i
\end{aligned} \tag{21.57}$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\lambda} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
0 &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
\frac{n}{\lambda} &= \sum_{i=1}^n x_i \\
\hat{\lambda}_{\text{MLE}} &= \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}
\end{aligned} \tag{21.58}$$

22. Zadanie 22

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu jednostajnego na przedziale $[0, \theta]$, gdzie θ jest nieznanym parametrem. Wyprowadź estymator największej wiarygodności dla parametru θ . Wskaż intuicyjnie, dlaczego ten estymator ma sens. Czy ten estymator jest nieobciążony?

22.1. Rozwiązanie

$$f(x; \theta) = \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x) \tag{22.59}$$

$$\begin{aligned}
L(\theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) \\
&= \theta^{-n} \mathbf{1}_{\{\forall_i, x_i \leq \theta\}} \\
&= \theta^{-n} \mathbf{1}_{\{\max_i x_i \leq \theta\}} \\
&= \begin{cases} 0, & \max_i x_i > \theta \\ \theta^{-n}, & \max_i x_i \leq \theta, \text{ funkcja malejąca} \end{cases}
\end{aligned} \tag{22.60}$$

Chcąc osiągnąć największe możliwe $L(\theta)$ musimy zminimalizować θ tak aby nadal $\forall_i x_i \leq \theta \Rightarrow \max_i x_i \leq \theta$. Więc największa wartość $L(\theta)$ jest osiągnięta dla:

$$\hat{\theta}_{\text{MLE}} = \max_i x_i = x_{(n)} \tag{22.61}$$

22.2. Czy estymator nieobciążony?

Nie, estymator jest obciążony.

Proof. Rozkład $x_{(n)}$ (maksimum) dla $x \in [0, \theta]$:

$$F_{x_{(n)}}(x) = P(x_{(n)} < x) = \left(\frac{x}{\theta}\right)^n \tag{22.62}$$

$$\begin{aligned}
\mathbb{E}[\hat{\theta}_{\text{MLE}}] &= \mathbb{E}[x_{(n)}] = \int_0^\theta x dF_{x_{(n)}}(x) \\
&= \int_0^\theta x \cdot n \frac{x^{n-1}}{\theta^n} dx \\
&= \frac{n}{\theta^n} \int_0^\theta x^n dx \\
&= \frac{n}{\theta^n} \left(\frac{x^{n+1}}{n+1} \right) \Big|_0^\theta \\
&= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \\
&= \frac{n}{n+1} \theta \neq \theta
\end{aligned} \tag{22.63}$$

$$\begin{aligned}
\text{Bias}(\hat{\theta}_{\text{MLE}}) &= \mathbb{E}[\hat{\theta}_{\text{MLE}}] - \theta \\
&= \frac{n}{n+1} \theta - \theta \\
&= -\frac{1}{n+1} \theta
\end{aligned} \tag{22.64}$$

■

23. Zadanie 23

23.1. a) $p = 1$

Ułamek próby który użyjemy $\frac{0.10}{1} = 0.1$

23.2. b) $p = 2$

Teraz chcemy wykorzystać kwadrat o długości $X_1 = 0.1$ oraz szerokości $X_2 = 0.1$

Ułamek próby który użyjemy: $\frac{0.1 \cdot 0.1}{1} = 0.01$

23.3. c) $p = 100$

Teraz chcemy wykorzystać hiperkostkę o długości boku 0.1

Ułamek próby który użyjemy: $\frac{0.1^{100}}{1} = 10^{-100} \approx 0$

23.4. d)

Im większe p tym mniej punktów leży w odległości 0.1 od testowego, więc metody oparte na lokalności się trochę psują, mając mało danych do porządnego przewidywania. Rośnie wariancja a żeby ją kontrolować musimy zwiększać K lub zwiększać okno szukania co psuje założenie lokalności.

23.5. e)**23.5.1. Wzór**

Niech w to długość krawędzi hiperkostki wewnętrznej, zawierającej $\approx 10\%$ obserwacji treningowych

$$\begin{aligned} 0.1 &= w^p \\ w &= \sqrt[p]{0.1} \end{aligned} \tag{23.65}$$

23.5.2. Wyniki

p	w
1	0.1
2	$\sqrt{0.1} \approx 0.31$
100	$\sqrt[100]{0.1} \approx 0.977$

Prawie cała objętość hiperkostki leży w jej brzegach. Nie da się być lokalnym i mieć wystarczająco dużo sąsiadów $\rightarrow$ Klątwa wielowymiarowości

Algorytmiczna Analiza Danych

Ćwiczenia 7

21 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

24. Zadanie 24 – Ocena modelu w problemie klasyfikacji

24.1. Oznaczenia

Stosujemy następujące oznaczenia w macierzy pomyłek:

- **TP (True Positive)** - Prawdziwie pozytywne.
- **TN (True Negative)** - Prawdziwie negatywne.
- **FP (False Positive)** - Fałszywie pozytywne (błąd I rodzaju).
- **FN (False Negative)** - Fałszywie negatywne (błąd II rodzaju).

24.2. a) Metryki: Accuracy, Precision, Recall oraz F1

24.2.1. Definicje metryk

1. **Accuracy (Dokładność)** - Określa, jak często model ma rację.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (24.66)$$

2. **Precision (Precyzja)** - Określa wiarygodność pozytywnej predykcji (ile z przewidzianych „jedynek” to faktycznie „jedynek”).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (24.67)$$

3. **Recall (Czułość)** - Określa zdolność modelu do wykrywania klasy pozytywnej (ile faktycznych „jedynek” udało się znaleźć).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (24.68)$$

4. **F1-Score** - Średnia harmoniczna precyzji i czułości. Jest lepszą miarą niż Accuracy przy niebalansowanych danych.

$$F1 = 2 \cdot \left(\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \right) \quad (24.69)$$

24.2.2. Przykład

Testujemy wykrywacz choroby (10 chorych, 90 zdrowych). Model wykrył 8 chorych, ale też błędnie wskazał 10 zdrowych jako chorych.

- $\text{Accuracy} = \frac{8+80}{100} = 0.88$
- $\text{Precision} = \frac{8}{8+10} \approx 0.44$

- $\text{Recall} = \frac{8}{8+2} = 0.80$

24.3. b) Różnica wersji *micro* od *macro*

- **Macro Average** - Liczymy metrykę (np. F1) dla każdej klasy osobno, a potem wyciągamy z nich średnią. Traktuje każdą klasę równoważnie (dobre do wykrywania błędów w rzadkich klasach).
- **Micro Average** - Sumujemy wszystkie TP, FP, FN globalnie i liczymy metrykę raz. W klasyfikacji wieloklasowej (single-label) Micro-F1 jest równoważne Accuracy. Faworyzuje klasy większościowe.

Przykład: Klasa A (100 próbek, model idealny), Klasa B (10 próbek, model tragiczny).

- **Micro** będzie wysokie (zdominowane przez A).
- **Macro** będzie niskie (uwidoczni błąd na B).

24.4. c) Potoczne rozumienie a definicja

- **Accuracy** - Potocznie „jakość”. W *ML* może być mylące - model przewidujący zawsze brak rzadkiego zdarzenia (np. wygrana w lotto) ma 99.9% accuracy, a jest bezużyteczny.
- **Precision** - Potocznie kojarzy się z „dokładnością pomiaru”. W *ML* to „brak fałszywych alarmów”.

25. Zadanie 25 – Naiwny Klasyfikator Bayesa

25.1. Definicja

Naiwny klasyfikator Bayesa - model probabilistyczny oparty na twierdzeniu Bayesa, który zakłada **warunkową niezależność** cech (x_i) od siebie przy znanej klasie (C_k).

Warto go stosować, gdy mamy mało danych (szybka zbieżność), bardzo wysoki wymiar danych (np. tekst) lub potrzebujemy szybkiego modelu bazowego.

25.2. Dowód wzoru

Theorem 25.1.

$$\Pr(C_k \mid x_1, \dots, x_n) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.70)$$

Proof. Wychodzimy z twierdzenia Bayesa:

$$\Pr(C_k \mid x) = \frac{\Pr(x \mid C_k) \Pr(C_k)}{\Pr(x)} \quad (25.71)$$

Gdzie $x = (x_1, \dots, x_n)$. W liczniku mamy prawdopodobieństwo łączne $\Pr(x_1, \dots, x_n \mid C_k)$. Stosujemy „naiwne” założenie o niezależności cech:

$$\Pr(x_1, \dots, x_n \mid C_k) \approx \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.72)$$

Podstawiając do licznika:

$$\Pr(C_k | x) = \frac{\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k)}{\Pr(x)} \quad (25.73)$$

$$\Pr(C_k | x) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \quad (25.74)$$

Mianownik $\Pr(x)$ jest sumą po wszystkich klasach (z prawa całkowitego prawdopodobieństwa):

$$\Pr(x) = \sum_k \Pr(x | C_k) \Pr(C_k) = \sum_k \left(\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \right) \quad (25.75)$$

■

26. Zadanie 26 – Klasyfikacja Spam vs Nie-spam

Dane:

- $N = 1000$ e-maili.
- Klasa C_1 (Spam): 100 e-maili (wszystkie $x_1 = 1, x_2 = 1$).
- Klasa C_2 (Nie-spam): 900 e-maili (450: $x_1 = 1, x_2 = 0$ oraz 450: $x_1 = 0, x_2 = 1$).

Szukamy predykcji dla nowego e-maila $x = (x_1 = 1, x_2 = 1)$.

1. Prawdopodobieństwa a priori (Priors):

$$\Pr(C_1) = \frac{100}{1000} = 0.1 \quad (26.76)$$

$$\Pr(C_2) = \frac{900}{1000} = 0.9 \quad (26.77)$$

2. Prawdopodobieństwa warunkowe (Likelihoods):

- Dla C_1 (Spam):
 - $\Pr(x_1 = 1 | C_1) = \frac{100}{100} = 1$
 - $\Pr(x_2 = 1 | C_1) = \frac{100}{100} = 1$
- Dla C_2 (Nie-spam):
 - $\Pr(x_1 = 1 | C_2) = \frac{450}{900} = 0.5$
 - $\Pr(x_2 = 1 | C_2) = \frac{450}{900} = 0.5$

3. Obliczenia dla nowego e-maila (licznik wzoru Bayesa):

- Dla Spam:

$$L(C_1) = \Pr(C_1) \cdot \Pr(x_1 = 1 | C_1) \cdot \Pr(x_2 = 1 | C_1) = 0.1 \cdot 1 \cdot 1 = 0.1 \quad (26.78)$$

- Dla Nie-spam:

$$L(C_2) = \Pr(C_2) \cdot \Pr(x_1 = 1 | C_2) \cdot \Pr(x_2 = 1 | C_2) = 0.9 \cdot 0.5 \cdot 0.5 = 0.225 \quad (26.79)$$

4. Normalizacja i wynik:

$$\text{Evidence } \Pr(x) = 1 \cdot 1 \cdot 0.1 + 0.5 \cdot 0.5 \cdot 0.9 = 0.1 + 0.225 = 0.325.$$

$$\Pr(C_1 | x) = \frac{0.1}{0.325} \approx 0.308 \quad (26.80)$$

$$\Pr(C_2 | x) = \frac{0.225}{0.325} \approx 0.692 \quad (26.81)$$

Odp: Prawdopodobieństwo, że to Spam wynosi ok. 30.8%, a że Nie-spam ok. 69.2%.

27. Zadanie 27 – Regresja Logistyczna

27.1. a) Dlaczego nie regresja liniowa?

- Predykcje mogą wykraczać poza przedział $[0, 1]$.
- Zależność rzadko jest liniowa (często przyjmuje kształt litery S).
- Niespełnione założenie o stałej wariancji reszt (heteroskedastyczność).

27.2. b) Obliczenie szans (Odds)

Dane: $p = 0.75$.

$$\text{Odds} = \frac{p}{1-p} = \frac{0.75}{1-0.75} = \frac{0.75}{0.25} = 3 \quad (27.82)$$

Szanse wynoszą 3 do 1.

27.3. c) Dowód równoważności z Log-Odds

Model:

$$\Pr(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (27.83)$$

Oznaczmy $z = \beta_0 + \beta_1 X$. Wtedy $p = \frac{e^z}{1+e^z}$.

1. Obliczamy $1 - p$:

$$1 - p = 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z - e^z}{1 + e^z} = \frac{1}{1 + e^z} \quad (27.84)$$

2. Dzielimy p przez $1 - p$:

$$\frac{p}{1-p} = \frac{\frac{e^z}{1+e^z}}{\frac{1}{1+e^z}} = \left(\frac{e^z}{1+e^z} \right) \cdot \left(\frac{1+e^z}{1} \right) = e^z \quad (27.85)$$

3. Logarytmujemy obustronnie:

$$\ln\left(\frac{p}{1-p}\right) = \ln(e^z) = z \quad (27.86)$$

Podstawiając z :

$$\ln\left(\frac{\Pr(X)}{1 - \Pr(X)}\right) = \beta_0 + \beta_1 X \quad (27.87)$$

27.4. d) Zależność sigma a logit

Funkcja logistyczna $\sigma(x)$ i funkcja logit $l(p)$ są **funkcjami odwrotnymi**.

$$\sigma(x) = \frac{e^x}{1 + e^x} \quad (\text{odwzorowuje } \mathbb{R} \rightarrow (0, 1)) \quad (27.88)$$

$$l(p) = \ln\left(\frac{p}{1-p}\right) \quad (\text{odwzorowuje } (0, 1) \rightarrow \mathbb{R}) \quad (27.89)$$

Zachodzi:

$$l(\sigma(x)) = x \quad (27.90)$$

oraz

$$\sigma(l(p)) = p \quad (27.91)$$

.

Algorytmiczna Analiza Danych

Ćwiczenia 8

28 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

28. Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych

Aby uzyskać model dla K klas, wykorzystując $K - 1$ modeli binarnej regresji logistycznej, stosujemy podejście oparte na **klasie referencyjnej** (bazowej). Załóżmy, że klasa K jest naszą klasą bazową.

Budujemy $K - 1$ klasyfikatorów binarnych, gdzie k -ty model (dla $k = 1, \dots, K - 1$) uczy się przewidywać logarytm szansy (log-odds) bycia w klasie k względem klasy K :

$$\ln\left(\frac{\Pr(Y = k)}{\Pr(Y = K)}\right) = \beta_k^T x \quad (28.92)$$

Gdzie β_k to wektor wag dla klasy k . Przekształcając to równanie, otrzymujemy:

$$P(Y = k) = P(Y = K) \cdot e^{\beta_k^T x} \quad (28.93)$$

Ponieważ suma prawdopodobieństw wszystkich klas musi wynosić 1 ($\sum_{j=1}^K \Pr(Y = j) = 1$), możemy wyznaczyć $\Pr(Y = K)$:

$$\begin{aligned} \Pr(Y = K) + \sum_{k=1}^{K-1} \Pr(Y = K) \cdot e^{\beta_k^T x} &= 1 \\ \Pr(Y = K) \left(1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}\right) &= 1 \\ \Pr(Y = K) &= \frac{1}{1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}} \end{aligned} \quad (28.94)$$

Dla dowolnego $k < K$ prawdopodobieństwo wynosi zatem:

$$\Pr(Y = k) = \frac{e^{\beta_k^T x}}{1 + \sum_{j=1}^{K-1} e^{\beta_j^T x}} \quad (28.95)$$

Jest to równoważne funkcji Softmax, gdzie dla klasy referencyjnej przyjmujemy wektor wag $\beta_K = 0$ (wektor zerowy).

29. Ćwiczenie 29 – Funkcja Softmax

29.1. Wzór i intuicja

Wzór funkcji Softmax dla j -tego elementu wektora z :

$$p_j(z) = \frac{e^{z_j}}{\sum_{k=1}^n e^{z_k}} \quad (29.96)$$

29.1.1. Intuicja

Funkcja ta realizuje dwa cele:

1. **Exponentiation (e^x)** - Przekształca logity (które mogą być ujemne) na wartości dodatnie oraz wzmacnia różnice między wartościami (duże wartości stają się znacznie większe od małych).
2. **Normalizacja** - Dzielenie przez sumę sprawia, że wszystkie wartości sumują się do 1, tworząc poprawny rozkład prawdopodobieństwa.

29.1.2. Dlaczego „ciągły argmax”?

Zwykła funkcja `argmax` zwraca indeks największej wartości (np. wektor one-hot). Jest ona jednak nieciągła i nieróżniczkowalna. Softmax jest jej gładkim przybliżeniem. Jeśli wprowadzimy parametr temperatury T ($\frac{z_j}{T}$) i $T \rightarrow 0$, rozkład softmax dąży do rozkładu punktowego (1 dla maksimum, 0 dla reszty), zachowując jednak różniczkowalność, co jest kluczowe dla uczenia sieci metodą spadku gradientu.

29.2. Klasyfikacja wieloetykietowa (Multi-label)

Gdy obserwacja może należeć do kilku klas jednocześnie, Softmax nie jest odpowiedni, ponieważ wymusza sumowanie się prawdopodobieństw do 1 (konkurencja między klasami).

Rozwiązanie: Stosuje się funkcję **Sigmoid** ($\sigma(z) = \frac{1}{1+e^{-z}}$) niezależnie dla każdego wyjścia (dla każdej klasy). Traktujemy to jako n niezależnych problemów klasyfikacji binarnej („czy należy do klasy A?”, „czy należy do klasy B?” itd.). Funkcją kosztu jest wtedy suma binarnych entropii krzyżowych.

30. Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax

Mamy wektor $p(z)$ o składowych $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$.

30.1. Macierz Jacobiego

Macierz Jacobiego J ma wymiary $n \times n$, a jej element na pozycji (j, k) to pochodna cząstkowa j -tego wyjścia po k -tym wejściu:

$$J_{jk} = \frac{\partial p_j}{\partial z_k} \quad (30.97)$$

Wzór ogólny (z wykorzystaniem delty Kroneckera δ_{jk}):

$$\frac{\partial p_j}{\partial z_k} = p_j(\delta_{jk} - p_k) \quad (30.98)$$

Co w rozwinięciu daje:

- Na przekątnej ($j = k$): $p_j(1 - p_j)$
- Poza przekątną ($j \neq k$): $-p_j p_k$

30.2. Analiza znaków pochodnych

- **Gdy $j = k$:** $\frac{\partial p_j}{\partial z_k} = p_j(1 - p_j)$. Ponieważ p_j jest prawdopodobieństwem z funkcji Softmax (dla skończonych z), to $0 < p_j < 1$. Zatem iloczyn dwóch liczb dodatnich jest **dodatni**.
- **Gdy $j \neq k$:** $\frac{\partial p_j}{\partial z_k} = -p_j p_k$. Ponieważ $p_j > 0$ i $p_k > 0$, to ich iloczyn ze znakiem minus jest **ujemny**.

Konsekwencje: Zwiększenie wartości logitu z_k (sygnału dla klasy k) powoduje wzrost prawdopodobieństwa tej klasy (p_k), ale jednocześnie **obniżenie** prawdopodobieństw wszystkich pozostałych klas (p_j). Potwierdza to konkurencyjną naturę Softmaxu - klasy „walczą” o zasoby (sumę równą 1).

31. Ćwiczenie 31 – Gradient Entropii Krzyżowej

Chcemy policzyć $\frac{\partial L}{\partial z_i}$, gdzie $L = -\sum_k y_k \log(p_{k(z)})$.

Korzystając z reguły łańcuchowej (dla wielu zmiennych):

$$\frac{\partial L}{\partial z_i} = \sum_{k=1}^n \frac{\partial L}{\partial p_k} \cdot \frac{\partial p_k}{\partial z_i} \quad (31.99)$$

1. Pochodna L po p_k :

$$\frac{\partial}{\partial p_k} \left(-\sum_j y_j \log(p_j) \right) = -\frac{y_k}{p_k} \quad (31.100)$$

2. Pochodna Softmaxu (z Ćwiczenia 30):

$$\frac{\partial p_k}{\partial z_i} = p_k(\delta_{ki} - p_i) \quad (31.101)$$

Podstawiając:

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= \sum_k \left(-\frac{y_k}{p_k} \right) \cdot p_k(\delta_{ki} - p_i) \\ &= -\sum_k y_k(\delta_{ki} - p_i) \\ &= -\left(y_i(1 - p_i) + \sum_{k \neq i} y_k(-p_i) \right) \\ &= -\left(y_i - y_i p_i - \sum_{k \neq i} y_k p_i \right) \\ &= -\left(y_i - p_i \underbrace{\sum_k y_k}_{=1} \right) \\ &= p_i - y_i \end{aligned} \quad (31.102)$$

Wynik:

$$\frac{\partial L}{\partial z_i} = p_i - y_i \quad (31.103)$$

Wykorzystanie: Wzór $p_i - y_i$ reprezentuje **błąd predykcji** (różnicę między przewidywanym prawdopodobieństwem a rzeczywistą etykietą). Jest to sygnał błędu przekazywany wstecz (backpropagation) do aktualizacji wag modelu.

- Jeśli $y_i = 1$, a model dał $p_i = 0.8$, gradient wynosi -0.2 (dążymy do zwiększenia z_i).
- Jego prostota obliczeniowa sprawia, że połączenie Softmax + Cross-Entropy jest standardem w sieciach neuronowych.

32. Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)

Wykres pudełkowy służy do wizualizacji rozkładu cechy statystycznej i składa się z następujących elementów:

1. Pudełko (Box):

- Dolna krawędź pudełka wyznacza *pierwszy kwartył* ($Q1$) (25. centyl).
- Górna krawędź wyznacza *trzeci kwartył* ($Q3$) (75. centyl).
- Wysokość pudełka to *rozstęp międzykwartyłowy* ($IQR = Q3 - Q1$), w którym znajduje się 50% środkowych obserwacji.

2. Linia wewnątrz pudełka:

- Oznacza *medianę* ($Q2$), czyli wartość środkową. Jej położenie wskazuje na skośność rozkładu (np. jeśli jest bliżej dołu, rozkład może być prawoskośny).

3. Wąsy (Whiskers):

- Linie wychodzące z pudełka w górę i w dół.
- Zazwyczaj sięgają do ostatniego punktu danych mieszczącego się w przedziale $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$.

4. Punkty poza wąsami (Outliers):

- Obserwacje odstające, które wykraczają poza zasięg wąsów. Są zaznaczane jako pojedyncze kropki lub gwiazdki.

Algorytmiczna Analiza Danych

Ćwiczenia 9

5 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

33. Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa

W problemie klasyfikacji wieloklasowej (gdzie mamy K klas), zmienną celu dla i -tej obserwacji możemy zapisać jako wektor one-hot $\mathbf{y}^{(i)} = [y_1^{(i)}, \dots, y_K^{(i)}]$, gdzie $y_k^{(i)} = 1$ jeśli obserwacja należy do klasy k , a 0 w przeciwnym razie. Model przewiduje prawdopodobieństwa $\hat{y}_k^{(i)}$ (np. za pomocą funkcji Softmax).

Funkcja wiarygodności (Likelihood) dla N niezależnych obserwacji ma postać:

$$L(\theta) = \prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \quad (33.104)$$

Aby ułatwić optymalizację, stosujemy logarytm naturalny wiarygodności (Log-Likelihood):

$$\ln L(\theta) = \ln \left(\prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \right) = \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.105)$$

Maksymalizacja funkcji wiarygodności jest równoważna minimalizacji jej odwrotności ze znakiem minus (negative log-likelihood):

$$\text{NLL} = - \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.106)$$

Powyższy wzór to nic innego jak suma **entropii krzyżowych** pomiędzy rozkładem rzeczywistym y a przewidywanym $\hat{y}$. Zatem maksymalizacja wiarygodności w klasyfikacji wieloklasowej jest tożsama z minimalizacją entropii krzyżowej.

34. Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL

Niech P będzie prawdziwym rozkładem prawdopodobieństwa, a Q rozkładem aproksymującym (modelowanym). Zdefiniujmy miary dla zmiennych dyskretnych:

1. **Entropia Shannona ($H(P)$)** - Miara niepewności lub ilości informacji zawartej w rozkładzie P .

$$H(P) = - \sum_x P(x) \log P(x) \quad (34.107)$$

2. **Entropia krzyżowa ($H(P, Q)$)** - Średnia liczba bitów potrzebna do zakodowania zdarzeń z rozkładu P przy użyciu kodowania optymalnego dla rozkładu Q .

$$H(P, Q) = - \sum_x P(x) \log Q(x) \quad (34.108)$$

3. **Dywergencja Kullbacka-Leiblera ($D_{\text{KL}(P \parallel Q)}$)** - Miara „odległości” (straty informacji) przy zastąpieniu prawdziwego rozkładu P rozkładem Q .

$$D_{\text{KL}(P \parallel Q)} = \sum_x P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (34.109)$$

34.1. Związek między miarami

Rozpisując wzór na dywergencję KL:

$$\begin{aligned} D_{\text{KL}(P \parallel Q)} &= \sum_x P(x) (\log P(x) - \log Q(x)) \\ &= \sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned} \quad (34.110)$$

Stąd otrzymujemy kluczową zależność:

$$H(P, Q) = H(P) + D_{\text{KL}(P \parallel Q)} \quad (34.111)$$

Interpretacja: Entropia krzyżowa to entropia własna danych plus „kara” (dywergencja KL) za niedopasowanie modelu Q do rzeczywistości P .

35. Ćwiczenie 35 – Entropia różniczkowa

35.1. Definicja

Dla zmiennej losowej ciągłej X o gęstości prawdopodobieństwa $f(x)$, entropia różniczkowa wynosi:

$$h(X) = - \int_{-\infty}^{\infty} f(x) \log f(x) dx \quad (35.112)$$

35.2. Ujemna wartość entropii różniczkowej

W przeciwieństwie do przypadku dyskretnego, $h(X)$ może być ujemna, ponieważ $f(x)$ może przyjmować wartości > 1 . **Przykład:** Rozkład jednostajny na przedziale $[0, a]$, gdzie $a < 1$ (np. $a = 0.5$).

$$f(x) = \begin{cases} \frac{1}{a} & \text{dla } x \in [0, a] \\ 0 & \text{w p.p.} \end{cases} \quad (35.113)$$

$$h(X) = - \int_0^a \frac{1}{a} \log \left(\frac{1}{a} \right) dx = - \frac{1}{a} \log \left(\frac{1}{a} \right) \cdot a = - \log \left(\frac{1}{a} \right) = \log(a) \quad (35.114)$$

Dla $a = 0.5$, $h(X) = \log(0.5) < 0$.

35.3. Skalowanie zmiennej ($H(aX)$)

Niech $Y = aX$ dla $a > 0$. Gęstość prawdopodobieństwa Y to $f_{Y(y)} = \frac{1}{a}f_{X(\frac{y}{a})}$.

$$\begin{aligned} h(Y) &= - \int f_{Y(y)} \log f_{Y(y)} dy \\ &= - \int \frac{1}{a} f_{X(\frac{y}{a})} \log \left(\frac{1}{a} f_{X(\frac{y}{a})} \right) dy \end{aligned} \quad (35.115)$$

Podstawiając $x = \frac{y}{a}$ (więc $dy = a dx$):

$$\begin{aligned} &= - \int \frac{1}{a} f_{X(x)} (\log f_{X(x)} - \log a) a dx \\ &= - \int f_{X(x)} \log f_{X(x)} dx + \log a \int f_{X(x)} dx \\ &= h(X) + \log a \end{aligned} \quad (35.116)$$

35.4. Maksymalna entropia rozkładu normalnego

Wiemy, że $D_{\text{KL}}(f \parallel g) \geq 0$ (Nierówność Gibbsa). Niech $f(x)$ będzie dowolnym rozkładem o średniej μ i wariancji σ^2 , a $g(x)$ będzie rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

$$D_{\text{KL}}(f \parallel g) = \int f(x) \log \left(\frac{f(x)}{g(x)} \right) dx = -h(f) - \int f(x) \log g(x) dx \geq 0 \quad (35.117)$$

Stąd: $h(f) \leq - \int f(x) \log g(x) dx$.

Obliczmy prawą stronę dla $g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$:

$$\begin{aligned} &- \int f(x) \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2} \right] dx \\ &= \frac{1}{2} \log(2\pi\sigma^2) \int f(x) dx + \frac{1}{2\sigma^2} \int f(x)(x-\mu)^2 dx \end{aligned} \quad (35.118)$$

Ponieważ f ma wariancję σ^2 , całka $\int f(x)(x-\mu)^2 dx = \sigma^2$. Oraz $\int f(x) dx = 1$.

$$= \frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2} = \frac{1}{2} \log(2\pi e\sigma^2) \quad (35.119)$$

Wartość ta jest dokładnie entropią rozkładu normalnego $h(g)$. Zatem $h(f) \leq h(g)$, co dowodzi, że rozkład normalny ma największą entropię przy ustalonej wariancji.

36. Ćwiczenie 36 – Miary odległości między rozkładami

Oto zestawienie popularnych miar dla rozkładów P i Q (gęstości $p(x)$ i $q(x)$):

Miara	Opis i Własności
-------	------------------

Dywergencja Kullbacka-Leiblera (KL) $D_{\text{KL}(P \parallel Q)} = \int p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$	• Intuicja: Strata informacji przy aproksymacji P przez Q. • Własności: Nieujemna (≥ 0), równa 0 wtw gdy $P = Q$. • Uwaga: Nie jest metryką (nie jest symetryczna: $D_{\text{KL}(P \parallel Q)} \neq D_{\text{KL}(Q \parallel P)}$ i nie spełnia nierówności trójkąta).
Odległość Hellingera $H^2(P, Q) = \frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx$	• Intuicja: Euklidesowa odległość między pierwiastkami z gęstości. • Własności: Jest to metryka. Przyjmuje wartości w zakresie $[0, 1]$. Jest symetryczna. • Przydatna w teorii estymacji i statystyce asymptotycznej.
Total Variation Distance (TV) $TV(P, Q) = \sup_A P(A) - Q(A) $ $= \frac{1}{2} \int p(x) - q(x) dx$	• Intuicja: Największa możliwa różnica w prawdopodobieństwie przypisanym temu samemu zdarzeniu przez dwa rozkłady. • Własności: Jest metryką (L_1 norm). Ograniczona $0 \leq TV \leq 1$. • Bardzo restrykcyjna miara zbieżności.
Odległość Wassersteina (Earth Mover's) $W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\ x - y\]$	• Intuicja: Minimalny „koszt” (masa $\times$ droga) przesunięcia masy prawdopodobieństwa z rozkładu P, by uformować Q. • Własności: Jest metryką. Działa świetnie nawet gdy rozkłady mają rozłączne nośniki (gdzie KL byłoby nieskończone). Kluczowa w GAN-ach (WGAN).

Algorytmiczna Analiza Danych

Ćwiczenia 10

12 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

37. Ćwiczenie 37– Własności próby bootstrapowej

Niech X oznacza liczbę unikalnych obserwacji w próbie bootstrapowej rozmiaru n .

37.1. Wartość oczekiwana X

Zdefiniujmy zmienną indykatorową I_j dla j -tej obserwacji z oryginalnej próby (gdzie $j = 1, \dots, n$):

$$I_j = \begin{cases} 1 & \text{jeśli obserwacja } j \text{ znalazła się w próbie bootstrapowej} \\ 0 & \text{w przeciwnym wypadku} \end{cases} \quad (37.120)$$

Liczba unikalnych obserwacji to suma indykatorów: $X = \sum_{j=1}^n I_j$.

Prawdopodobieństwo, że konkretna obserwacja j **nie** zostanie wylosowana w pojedynczym losowaniu wynosi $(1 - \frac{1}{n})$. Ponieważ próba bootstrapowa polega na n -krotnym losowaniu ze zwracaniem, prawdopodobieństwo, że obserwacja j nie znajdzie się w całej próbie wynosi:

$$P(I_j = 0) = \left(1 - \frac{1}{n}\right)^n \quad (37.121)$$

Zatem prawdopodobieństwo, że obserwacja j znajdzie się w próbie (jest unikalna) to:

$$\mathbb{E}[I_j] = P(I_j = 1) = 1 - \left(1 - \frac{1}{n}\right)^n \quad (37.122)$$

Korzystając z liniowości wartości oczekiwanej:

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^n I_j\right] = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \quad (37.123)$$

Dla dużych n , korzystając z granicy $\lim_{n \rightarrow \infty} \left(1 - \frac{a}{n}\right)^n = e^{-a}$:

$$\mathbb{E}[X] \approx n(1 - e^{-1}) \approx 0.632n \quad (37.124)$$

37.2. Wariancja X

Wariancję sumy zmiennych zależnych wyrażamy wzorem:

$$\text{Var}(X) = \sum_{j=1}^n \text{Var}(I_j) + \sum_{j \neq k} \text{Cov}(I_j, I_k) \quad (37.125)$$

Wariancja pojedynczego indykatora:

$$\begin{aligned}
\text{Var}(I_j) &= \mathbb{E}[I_j^2] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] (1 - \mathbb{E}[I_j]) \\
&= \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \left(1 - \frac{1}{n}\right)^n
\end{aligned} \tag{37.126}$$

Kowariancja:

$$\text{Cov}(I_j, I_k) = E[I_j I_k] - E[I_j] E[I_k] \tag{37.127}$$

$$\begin{aligned}
E[I_j I_k] &= 1 \cdot P(j \in S \wedge k \in S) + 0 \cdot P(j \in S \wedge k \notin S) \\
&= P(j \in S \wedge k \in S)
\end{aligned} \tag{37.128}$$

to prawdopodobieństwo, że **zarówno** j jak i k są w próbie. Łatwiej policzyć to przez dopełnienie:

$$P(j \in S \wedge k \in S) = 1 - P(j \notin S \vee k \notin S) \tag{37.129}$$

$$= 1 - [P(j \notin S) + P(k \notin S) - P(j \notin S \wedge k \notin S)] \tag{37.130}$$

Gdzie $P(j \notin S \wedge k \notin S) = \left(1 - \frac{2}{n}\right)^n$.

Po podstawieniu i uproszczeniu dla dużych n , otrzymujemy przybliżenie:

$$\text{Var}(X) \approx n[e^{-1}(1 - e^{-1}) - n(e^{-1} - e^{-2})] \tag{37.131}$$

W praktyce dla dużych n wariancja ta dąży do:

$$\text{Var}(X) \approx n \cdot e^{-1}(1 - e^{-1}) \approx n \cdot 0.233 \tag{37.132}$$

37.3. Odsetek unikalnych obserwacji i jego wariancja

Niech $\hat{p}$ będzie odsetkiem unikalnych obserwacji: $\hat{p} = \frac{X}{n}$.

37.3.1. Średnia

$$E[\hat{p}] = E\left[\frac{X}{n}\right] = \frac{1}{n} E[X] = 1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - e^{-1} \approx 0.632 \tag{37.133}$$

37.3.2. Wariancja

$$\text{Var}(\hat{p}) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) \tag{37.134}$$

Dla dużych n , wariancja odsetka maleje rzędu $\frac{1}{n}$.

37.4. Prawdopodobieństwo braku obserwacji w k próbkach

Prawdopodobieństwo, że dana obserwacja nie znajdzie się w jednej próbie bootstrapowej wynosi $\left(1 - \frac{1}{n}\right)^n \approx e^{-1}$. Ponieważ próbki są generowane niezależnie, prawdopodobieństwo, że obserwacja nie znajdzie się w żadnej z k próbek wynosi:

$$P(\text{brak w } k \text{ próbkach}) = \left[\left(1 - \frac{1}{n} \right)^n \right]^k \approx (e^{-1})^k = e^{-k} \quad (37.135)$$

38. Ćwiczenie 38 – Konstrukcja drzewa i predyktory kategori- goryczne

38.1. Konstrukcja drzewa

Drzewa decyzyjne konstruowane są zazwyczaj za pomocą algorytmu zachłannego (np. CART, C4.5). Proces polega na rekurencyjnym podziale przestrzeni cech na prostokątne regiony. W każdym kroku wybierana jest zmienna oraz punkt podziału, które najlepiej rozdzielają dane względem zmiennej celu (minimalizując np. RSS dla regresji lub wskaźnik Giniego/entropię dla klasyfikacji).

38.2. Problem z predyktorem kategoriowym

Dla predyktora kategoriowego z q możliwymi nieuporządkowanymi wartościami, podział polega na przydzieleniu pewnego podzbioru wartości do lewego węzła, a reszty do prawego.

Liczba możliwych podziałów: Aby podzielić zbiór q wartości na dwie niepuste grupy, rozważamy wszystkie możliwe podzbiory. Zbiór q -elementowy ma 2^q podzbiorów.

1. Odejmujemy zbiór pusty i zbiór pełny (podział musi być na dwie grupy): $2^q - 2$.
2. Ponieważ podział $\{A, B\}$ vs $\{C\}$ jest tożsamy z $\{C\}$ vs $\{A, B\}$, wynik dzielimy przez 2.

Liczba podziałów wynosi:

$$\frac{2^q - 2}{2} = 2^{q-1} - 1 \quad (38.136)$$

Problem: Liczba ta rośnie wykładniczo wraz z q . Przeszukiwanie wszystkich podziałów jest obliczeniowo bardzo kosztowne dla dużego q . Dodatkowo, zmienne o dużej liczbie kategorii są faworyzowane przez algorytm doboru zmiennych (tzw. bias doboru).

38.3. Rozwiązanie problemu

Dla binarnej klasyfikacji (0/1) lub regresji istnieje efektywne rozwiązanie (Fisher, 1958):

1. Oblicz średnią wartość zmiennej celu dla każdej kategorii predyktora.
2. Uporządkuj kategorie według tych średnich rosnąco.
3. Potraktuj zmienną kategoriową jak zmienną ciągłą (uporządkowaną) i sprawdzaj podziały tylko wzdłuż tego porządku.

Redukuje to liczbę sprawdzanych podziałów z $2^{q-1} - 1$ do $q - 1$.

39. Ćwiczenie 39 – Miary jakości podziału

39.1. a) Interpretacja indeksu Giniego

Indeks Giniego dla węzła m zdefiniowany jest jako:

$$G = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2 \quad (39.137)$$

gdzie p_{mk} to frakcja obserwacji klasy k w węźle m .

Interpretacja: Indeks Giniego można interpretować jako miarę „nieczystości” węzła. Reprezentuje on oczekiwany poziom błędu, jeśli klasyfikowalibyśmy losowo obserwację z węzła, losując jej etykietę zgodnie z rozkładem klas w tym węźle. Im mniejszy indeks Giniego, tym bardziej „czysty” węzeł (zdominowany przez jedną klasę).

39.2. b) Porównanie podziałów

Mamy problem dwuklasowy (klasy A i B). W korzeniu mamy (400, 400). Całkowita liczba obserwacji $N = 800$.

- **Analiza Podziału 1:**

Tworzy węzły: $N_1(300, 100)$ oraz $N_2(100, 300)$.

- ▶ N_1 (400 obs): Dominująca klasa A. Błędne: 100 (klasa B).
- ▶ N_2 (400 obs): Dominująca klasa B. Błędne: 100 (klasa A).
- ▶ Całkowita liczba błędów: $100 + 100 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

- **Analiza Podziału 2:**

Tworzy węzły: $N_3(200, 400)$ oraz $N_4(200, 0)$.

- ▶ N_3 (600 obs): Dominująca klasa B. Błędne: 200 (klasa A).
- ▶ N_4 (200 obs): Dominująca klasa A. Błędne: 0 (czysty węzeł).
- ▶ Całkowita liczba błędów: $200 + 0 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

Oba podziały mają ten sam Misclassification Rate (0.25).

39.3. Obliczenie Indeksu Giniego

Wzór dla dwóch klas: $2p(1 - p)$.

- **Dla Podziału 1:**

- ▶ Węzeł N_1 ($p = 0.75$): $G_1 = 1 - (0.75^2 + 0.25^2) = 1 - (0.5625 + 0.0625) = 375$.
- ▶ Węzeł N_2 ($p = 0.25$): $G_2 = 1 - (0.25^2 + 0.75^2) = 375$.
- ▶ Średni ważony Gini:

$$G_{\text{split 1}} = \frac{400}{800} \cdot 0.375 + \frac{400}{800} \cdot 0.375 = 375 \quad (39.138)$$

- **Dla Podziału 2:**

- ▶ Węzeł N_3 (200, 400), $p_A = \frac{1}{3}$, $p_B = \frac{2}{3}$:

$$G_3 = 1 - \left(\left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right) = 1 - \left(\frac{1}{9} + \frac{4}{9} \right) = \frac{4}{9} \approx 0.444 \quad (39.139)$$

- ▶ Węzeł N_4 (200, 0), $p_A = 1$:

$$G_4 = 1 - (1^2 + 0^2) = 0 \quad (39.140)$$

(węzeł czysty)

- Średni ważony Gini (wagi: $\frac{600}{800} = \frac{3}{4}$ i $\frac{200}{800} = \frac{1}{4}$):

$$G_{\text{split } 2} = \frac{3}{4} \cdot \frac{4}{9} + \frac{1}{4} \cdot 0 = \frac{3}{9} = \frac{1}{3} \approx 0.333 \quad (39.141)$$

39.3.1. Wniosek

$$G_{\text{split } 2}(0.333) < G_{\text{split } 1}(0.375) \quad (39.142)$$

Indeks Giniego jest niższy dla drugiego podziału, co oznacza, że preferuje on podział, który wydziela czysty węzeł („pure node”), nawet jeśli globalny błąd klasyfikacji jest taki sam.

Algorytmiczna Analiza Danych

Ćwiczenia 11

19 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

40. Zadanie 40 – Współczynnik Giniego

Współczynnik Giniego - to statystyczna miara koncentracji (nierówności) rozkładu dochodów lub bogactwa w danym społeczeństwie. Przyjmuje wartości od 0 do 1 (lub od 0% do 100%).

- **0 (Idealna równość)** - Każdy obywatel ma dokładnie taki sam dochód.
- **1 (Idealna nierówność)** - Jedna osoba posiada cały dochód kraju, a reszta nie posiada nic.

40.1. Intuicja geometryczna (Krzywa Lorenza)

Współczynnik Giniego oblicza się na podstawie wykresu, gdzie na osi X mamy skumulowany odsetek populacji, a na osi Y skumulowany odsetek dochodu.

1. **Linia 45 stopni** - To linia idealnej równości.
2. **Krzywa Lorenza** - Rzeczywisty rozkład dochodów w populacji.
3. **Obliczanie** - Jeśli oznaczymy pole między linią 45 stopni a Krzywą Lorenza jako A , a pole pod Krzywą Lorenza jako B , współczynnik Giniego (G) wyraża się wzorem:

$$G = \frac{A}{A + B} \quad (40.143)$$

40.2. Pozycja Polski w OECD

Polska na tle krajów OECD prezentuje się jako kraj o **średnio-niskich** nierównościach, szczególnie po uwzględnieniu transferów społecznych:

- **Przed transferami i podatkami:** Współczynnik Giniego w Polsce jest relatywnie wysoki (podobnie jak w większości krajów rozwiniętych), co wynika z rynkowego zróżnicowania płac.
- **Po transferach i podatkach:** Polska odnotowuje jeden z większych spadków współczynnika w OECD. Obecnie wartość ta oscyluje wokół **0.27 – 0.28**, co plasuje Polskę poniżej średniej OECD (czyli jesteśmy krajem o mniejszych nierównościach niż np. USA, Wielka Brytania czy kraje bałtyckie).

40.3. Poziom graniczny napięcie społecznych

W literaturze ekonomicznej i socjologicznej (m.in. ONZ) przyjmuje się często, że wartości współczynnika Giniego powyżej **0.40** stanowią „czerwoną linię”. Przekroczenie tego poziomu sugeruje głębokie nierówności, które mogą prowadzić do destabilizacji politycznej, protestów i wzrostu przestępczości.

41. Zadanie 41 – Algorytm Random Forest

Random Forest to metoda zespołowa (ensemble learning) oparta na budowie wielu drzew decyzyjnych i agregacji ich wyników.

41.1. Pseudokod

- Dla $b = 1$ do B (liczba drzew):
 - Wylosuj próbkę bootstrapową Z^* z danych treningowych (losowanie ze zwracaniem).
 - Wyhoduj drzewo T_b na podstawie próbki Z^* :
 - Powtarzaj, aż osiągniesz minimalny rozmiar liścia:
 - Wybierz losowo m zmiennych spośród wszystkich p predyktorów.
 - Wybierz najlepszą zmienną i punkt podziału spośród m zmiennych.
 - Podziel węzeł na dwa węzły potomne.
- Zwróć zespół drzew $\{T_b\}_1^B$.

41.2. Predykcja

- Klasyfikacja** - Głosowanie większościowe (Majority Vote) - klasa najczęściej wskazywana przez drzewa.
- Regresja** - Średnia arytmetyczna z przewidywań wszystkich B drzew.

42. Ćwiczenie 42 – Algorytm Boosting (Regresja)

W przeciwieństwie do Random Forest, Boosting buduje drzewa sekwencyjnie. Każde kolejne drzewo uczy się na błędach (resztach) swoich poprzedników.

42.1. Pseudokod (na podstawie ISL)

- Ustaw $\hat{f}(x) = 0$ oraz reszty $r_i = y_i$ dla wszystkich obserwacji w zbiorze treningowym.
- Dla $b = 1, 2, \dots, B$:
 - Dopasuj drzewo $\hat{f}^b$ z d podziałami (liczba liści = $d + 1$) do danych treningowych (X, r) .
 - Zaktualizuj model główny, dodając nową wersję drzewa z parametrem uczenia (shrinkage) λ :

$$\hat{f}(x) \leftarrow \hat{f}(x) + \lambda \hat{f}^b(x) \quad (42.144)$$

- Zaktualizuj reszty:

$$r_i \leftarrow r_i - \lambda \hat{f}^b(x_i) \quad (42.145)$$

- Zwróć model końcowy: $\hat{f}(x) = \sum_{b=1}^B \lambda \hat{f}^b(x)$.

42.2. Wyjaśnienie kluczowych parametrów

- B (Liczba drzew)** - Zbyt duża może prowadzić do overfittingu (inaczej niż w RF).
- λ (Shrinkage)** - Mała wartość (np. 0.01) spowalnia naukę, wymagając więcej drzew, ale zazwyczaj poprawia generalizację.
- d (Liczba podziałów)** - Kontroluje złożoność każdego drzewa (często wystarczają bardzo proste drzewa, tzw. stumps, gdzie $d = 1$).

Algorytmiczna Analiza Danych

Ćwiczenia 12

9 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

43. Zadanie 43 – Obliczenia PCA

Dane są punkty: $(2, 3), (3, 4), (4, 5), (5, 6), (6, 7)$. Liczba obserwacji $n = 5$.

43.1. Średnia każdej zmiennej

Obliczamy średnie arytmetyczne dla X i Y :

$$\bar{X} = \frac{2 + 3 + 4 + 5 + 6}{5} = \frac{20}{5} = 4 \quad (43.146)$$

$$\bar{Y} = \frac{3 + 4 + 5 + 6 + 7}{5} = \frac{25}{5} = 5 \quad (43.147)$$

43.2. Macierz kowariancji

Najpierw centrujemy dane (odejmujemy średnie od każdej obserwacji):

$$X_c = [-2, -1, 0, 1, 2] \quad (43.148)$$

$$Y_c = [-2, -1, 0, 1, 2] \quad (43.149)$$

Wzór na kowariancję dla próbki (dzielenie przez $n - 1$):

$$\text{Cov}(A, B) = \frac{\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})}{n - 1} \quad (43.150)$$

Obliczamy wariancje i kowariancję (gdzie $n - 1 = 4$):

$$s_X^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{4} = \frac{4 + 1 + 0 + 1 + 4}{4} = \frac{10}{4} = 2.5$$

$$s_Y^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{4} = \frac{10}{4} = 2.5 \quad (43.151)$$

$$\text{Cov}(X, Y) = \frac{(-2)(-2) + (-1)(-1) + 0 + 1(1) + 2(2)}{4} = \frac{4 + 1 + 0 + 1 + 4}{4} = 2.5$$

Macierz kowariancji C :

$$C = \begin{pmatrix} 2.5 & 2.5 \\ 2.5 & 2.5 \end{pmatrix} \quad (43.152)$$

43.3. Wartości własne i wektory własne

Rozwiązujemy równanie charakterystyczne $\det(C - \lambda I) = 0$:

$$\begin{aligned}
\det \begin{pmatrix} 2.5 - \lambda & 2.5 \\ 2.5 & 2.5 - \lambda \end{pmatrix} &= 0 \\
(2.5 - \lambda)^2 - 2.5^2 &= 0 \\
(2.5 - \lambda - 2.5)(2.5 - \lambda + 2.5) &= 0 \\
-\lambda(5 - \lambda) &= 0
\end{aligned} \tag{43.153}$$

Wartości własne to:

$$\lambda_1 = 5, \quad \lambda_2 = 0 \tag{43.154}$$

Wyznaczamy wektory własne:

Dla $\lambda_1 = 5$:

$$\begin{aligned}
\begin{pmatrix} 2.5 - 5 & 2.5 \\ 2.5 & 2.5 - 5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\
\begin{pmatrix} -2.5 & 2.5 \\ 2.5 & -2.5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix}
\end{aligned} \tag{43.155}$$

Równanie: $-2.5x + 2.5y = 0 \rightarrow x = y$. Znormalizowany wektor własny:

$$v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \vee v_1 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \tag{43.156}$$

Dla $\lambda_2 = 0$:

$$\begin{pmatrix} 2.5 & 2.5 \\ 2.5 & 2.5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow x = -y \tag{43.157}$$

Znormalizowany wektor własny:

$$v_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \vee v_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \tag{43.158}$$

43.4. Interpretacja

Wybór głównych składowych: Całkowita wariancja wynosi $\lambda_1 + \lambda_2 = 5 + 0 = 5$. **Pierwsza składowa ($PC1$, związana z λ_1) wyjaśnia $\frac{5}{5} = 100\%$ wariancji.** Druga składowa ($PC2$, związana z λ_2) wyjaśnia 0% wariancji.

Decyzja: Należy wybrać tylko **pierwszą główną składową**. **Uzasadnienie:** Wszystkie punkty leżą idealnie na prostej ($y = x + 1$). Redukcja do jednego wymiaru nie powoduje żadnej utraty informacji. Druga składowa jest zbędna (szum wynosi zero).

Analiza przypadku odstającego: punkt (6, 7) zamieniony na (6, 107)

Zastąpienie punktu (6, 7) punktem (6, 107) drastycznie zmienia sytuację:

1. **Średnia** - Średnia Y znacznie wzrosła.
2. **Wariancja** - Wariancja zmiennej Y stanie się ogromna w porównaniu do wariancji X .
3. **Kierunek** - Główna składowa ($PC1$) obróci się i będzie prawie równoległa do osi Y (ponieważ tam jest teraz największa zmienność).

4. **Wynik** - PCA jest bardzo wrażliwe na wartości odstające (outliers), ponieważ opiera się na kowariancji/wariancji (kwadratach odchylenia). Ten jeden punkt zdominuje wynik analizy.

44. Zadanie 44 – Ortogonalność wektorów własnych

Theorem 44.2. Pokaż, że wektory własne symetrycznej macierzy kowariancji C odpowiadające różnym wartościom własnym $\lambda_i \neq \lambda_j$ są ortogonalne.

Proof. Niech v_i oraz v_j będą wektorami własnymi macierzy C odpowiadającymi odpowiednio wartościom własnym λ_i oraz λ_j . Z definicji mamy:

$$Cv_i = \lambda_i v_i \quad \text{oraz} \quad Cv_j = \lambda_j v_j \quad (44.159)$$

Rozważmy wyrażenie $v_i^T Cv_j$. Ponieważ $Cv_j = \lambda_j v_j$, mamy:

$$v_i^T Cv_j = v_i^T (\lambda_j v_j) = \lambda_j v_i^T v_j \quad (44.160)$$

Z drugiej strony, transponując skalar (który jest równy swojej transpozycji) i korzystając z faktu, że macierz kowariancji jest symetryczna ($C = C^T$):

$$v_i^T Cv_j = (v_i^T Cv_j)^T = v_j^T C^T v_i = v_j^T Cv_i \quad (44.161)$$

Podstawiając $Cv_i = \lambda_i v_i$:

$$v_j^T (\lambda_i v_i) = \lambda_i v_j^T v_i = \lambda_i v_i^T v_j \quad (44.162)$$

Mamy zatem równość:

$$\lambda_j v_i^T v_j = \lambda_i v_i^T v_j \quad (44.163)$$

Przekształcając:

$$(\lambda_i - \lambda_j) v_i^T v_j = 0 \quad (44.164)$$

Ponieważ z założenia $\lambda_i \neq \lambda_j$, to różnica $(\lambda_i - \lambda_j) \neq 0$. Aby równanie było prawdziwe, musi zachodzić:

$$v_i^T v_j = 0 \quad (44.165)$$

Oznacza to, że wektory v_i i v_j są ortogonalne. ■

45. Zadanie 45 – Prawda czy Fałsz o PCA

Zakładamy, że wartości własne są unikalne.

1. **Dodanie jedynki na końcu każdego punktu próbki nie zmienia wyników przeprowadzenia PCA (z wyjątkiem dodatkowej składowej z wartością własną 0).**

Odpowiedź: PRAWDA. PCA operuje na macierzy kowariancji (dane scentrowane). Dodanie stałej wartości (np. 1) jako nowej cechy oznacza, że wariancja tej cechy wynosi

0. Po scentrowaniu otrzymamy kolumnę zer. Nie wpłynie to na relacje wariancji między oryginalnymi cechami, a jedynie doda wymiar o zerowej wariancji (wartość własna 0).
2. **Sekwencyjna redukcja wymiarowości ($d \rightarrow j \rightarrow k$) daje ten sam wynik co bezpośrednia redukcja ($d \rightarrow k$).**

Odpowiedź: PRAWDA. PCA sortuje składowe według wariancji. Wybranie najlepszych j składowych, a następnie wybranie z nich najlepszych k składowych, jest tożsame z wybraniem od razu k najlepszych składowych z pierwotnego zbioru (ponieważ zbiór k najlepszych zawiera się w zbiorze j najlepszych dla $k < j$).

3. **Obrót punktów przed PCA nie zmienia kierunków głównych składowych.**

Odpowiedź: FAŁSZ. Jeśli obrócimy dane wejściowe, struktura kowariancji się zmienia. Główne składowe (wektory własne) obracają się wraz z danymi. Chociaż **względna** geometria chmury punktów jest taka sama, to wektory własne (które są wyrażone w układzie współrzędnych cech) zmieniają swoje współrzędne.

4. **Obrót punktów przed PCA nie zmienia największej wartości własnej.**

Odpowiedź: PRAWDA. Wartości własne reprezentują wariancję (rozrzut) danych wzdłuż głównych osi. Obrót chmury punktów w przestrzeni nie zmienia „kształtu” tej chmury ani wielkości jej rozrzutu, jedynie jej orientację względem osi. Zatem wielkość maksymalnej wariancji (λ_1) pozostaje taka sama.