

Algorytmiczna Analiza Danych

Wszystkie Ćwiczenia

2025-12-04

Adrian Herda
Politechnika Wrocławska

Spis treści

1.	Zadanie 1	4
1.1.	Podpunkt a) wynagrodzenie prezesa a czynniki firmowe	4
1.2.	Podpunkt b) wprowadzenie nowego produktu na rynek	4
1.3.	Podpunkt c) prognozowanie zmian kursu dolara	4
2.	Zadanie 2	4
2.1.	Klasyfikacja	5
2.1.1.	Przykład 1 - rozpoznawanie rodzajów wina	5
2.1.2.	Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami	5
2.2.	Regresja	5
2.2.1.	Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)	5
2.2.2.	Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów	5
2.3.	Analiza klastrow	6
2.3.1.	Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)	6
2.3.2.	Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach	6
3.	Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne	6
3.1.	Parametryczne	7
3.2.	Nieparametryczna	7
3.3.	Zalety i wady	8
4.	Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)	8
4.1.	a) odległość euklidesowa dla każdego punktu	8
4.2.	b) predykcja dla $K = 1$	8
4.3.	c) predykcja dla $K = 3$	8
4.4.	d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa	8
5.	Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych	9
5.1.	a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$	9
5.2.	b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$	9
6.	Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami	9
6.1.	Definicje	9
6.2.	Przykłady	10
6.2.1.	Nieobciążony	10

6.2.2.	Obciążony	10
7.	Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza	10
7.1.	Wnioski	11
8.	Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu	12
8.1.	Rozwiązanie	12
8.2.	Równowaga bias-variance	12
9.	Zadanie 9 - Wykresy względem elastyczności modelu	13
9.1.	Wytlumaczenie każdej funkcji	13
10.	Zadanie 10 - Obliczanie wzorów na parametry modelu linowego	13
10.1.	Dane	13
10.2.	Cel	14
10.3.	Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$	15
11.	Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym	15
11.1.	Błąd systematyczny	16
11.2.	Wariancja	16
11.2.1.	Reprezentacja estymatorów za pomocą szumów	16
11.2.2.	Wariancja estymatorów	16
11.3.	Błąd standardowy estymatorów	17
12.	Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny	17
13.	Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale	19
13.1.	Reguła trzech sigm	19
13.2.	Ustandaryzowana zmienna	19
14.	Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami	20
14.1.	Teza	20
14.2.	Dowód	20
15.	Zadanie 15 - Korelacja	22
16.	Zadanie 16 - t-statystyka i p-wartość	23
16.1.	t-statystyka	23
16.2.	p-wartość	23
17.	Zadanie 17 - Odległość Mahalanobisa	23
17.1.	odpowiedź	23
18.	Zadanie 18 - Double descent	23
18.1.	Odpowiedź	24
19.	Zadanie 19	25
19.1.	Odpowiedź	25
19.1.1.	Definicja	25
19.1.2.	Własności	25
20.	Zadanie 20	26
20.1.	Rozwiązanie	26
21.	Zadanie 21	27
21.1.	Rozwiązanie	27
22.	Zadanie 22	28
22.1.	Rozwiązanie	28
22.2.	Czy estymator nieobciążony?	28

23.	Zadanie 23	29
23.1.	a) $p = 1$	29
23.2.	b) $p = 2$	29
23.3.	c) $p = 100$	29
23.4.	d)	29
23.5.	e)	30
23.5.1.	Wzór	30
23.5.2.	Wyniki	30
24.	Zadanie 24 – Ocena modelu w problemie klasyfikacji	31
24.1.	Oznaczenia	31
24.2.	a) Metryki: Accuracy, Precision, Recall oraz F1	31
24.2.1.	Definicje metryk	31
24.2.2.	Przykład	31
24.3.	b) Różnica wersji <i>micro</i> od <i>macro</i>	32
24.4.	c) Potoczne rozumienie a definicja	32
25.	Zadanie 25 – Naiwny Klasyfikator Bayesa	32
25.1.	Definicja	32
25.2.	Dowód wzoru	32
26.	Zadanie 26 – Klasyfikacja Spam vs Nie-spam	33
27.	Zadanie 27 – Regresja Logistyczna	34
27.1.	a) Dlaczego nie regresja liniowa?	34
27.2.	b) Obliczenie szans (Odds)	34
27.3.	c) Dowód równoważności z Log-Odds	34
27.4.	d) Zależność sigma a logit	35
28.	Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych	36
29.	Ćwiczenie 29 – Funkcja Softmax	36
29.1.	Wzór i intuicja	36
29.1.1.	Intuicja	37
29.1.2.	Dlaczego „ciągły argmax”?	37
29.2.	Klasyfikacja wieloetykietowa (Multi-label)	37
30.	Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax	37
30.1.	Macierz Jacobiego	37
30.2.	Analiza znaków pochodnych	38
31.	Ćwiczenie 31 – Gradient Entropii Krzyżowej	38
32.	Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)	39
33.	Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa	40
34.	Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL	40
34.1.	Związek między miarami	41
35.	Ćwiczenie 35 – Entropia różniczkowa	41
35.1.	Definicja	41
35.2.	Ujemna wartość entropii różniczkowej	41
35.3.	Skalowanie zmiennej ($H(aX)$)	42
35.4.	Maksymalna entropia rozkładu normalnego	42
36.	Ćwiczenie 36 – Miary odległości między rozkładami	42

Algorytmiczna Analiza Danych

Ćwiczenia 2

14 października 2025 r.

Adrian Herda

Informatyka Algorytmiczna

Politechnika Wrocławska

1. Zadanie 1

Wyjaśnij, czy dany scenariusz jest związany z problemem klasyfikacji, czy regresji, oraz wskaż, czy bardziej interesuje nas wnioskowanie (ang. inference), czy przewidywanie (ang. prediction). Podaj rozmiar próby n i liczbę predyktorów p

1.1. Podpunkt a) wynagrodzenie prezesa a czynniki firmowe

Typ problemu: problem regresji - wynagrodzenie to zmienna ciągła

Cel: wnioskowanie - chcemy zrozumieć zależności a nie przewidzieć przyszłe zarobki prezesów

Rozmiar próby n : 500 - liczba firm

Liczba predyktorów p : 3 - zysk, liczba pracowników, branża - predyktory do dane które pozwalają na znalezienie korelacji

1.2. Podpunkt b) wprowadzenie nowego produktu na rynek

Typ problemu: problem klasyfikacji - kategoryzujemy produkty na te które odniosły sukces lub porażkę, są dwie klasy

Cel: przewidywanie - chcemy przewidzieć jak produkt poradzi sobie na rynku

Rozmiar próby n : 20 - liczba podobnych produktów

Liczba predyktorów p : 3 - cena, cena bezpośredniej konkurencji, budżet marketingowy

1.3. Podpunkt c) prognozowanie zmian kursu dolara

Typ problemu: problem regresji - procentowe zmiany kursu to wartość liniowa

Cel: przewidywanie - „prognoza” to próba przewidzenia danych w przyszłości

Rozmiar próby n : 52 - liczba tygodni w roku

Liczba predyktorów p : 4 - liczba porównywanych rynków akcji: USA, Wielka Brytania, Niemcy, Japonia

2. Zadanie 2

Praktyczne zastosowania uczenia maszynowego: dla każdego z poniższych punktów zaproponuj dwa niesztafpowe praktyczne zastosowania. Opisz jakie dane są potrzebne w wybranych zastosowaniach, np. jakie cechy (ang. features) mogą zostać użyte jako predyktory, a jakie odpowiedzi, czy potrzebna jest duża liczba obserwacji.

2.1. Klasyfikacja

2.1.1. Przykład 1 - rozpoznawanie rodzajów wina

- Predyktory:
 - gęstość / lepkość
 - zapach
 - kolor
 - smak
- Odpowiedzi
 - rodzaje wina

Potrzebna jest duża ilość obserwacji ze względu na ilość rodzajów wina oraz ze względu na podobieństwo niektórych rodzajów.

2.1.2. Przykład 2 - klasyfikacja emocji w rozmowach telefonicznych z klientami

- Predyktory:
 - ton mowy
 - tempo mowy
 - używane wyrażenia
 - głośność
- Odpowiedzi
 - odpowiedzi na pytanie o zadowolenie z obsługi (bardzo pozytywne, pozytywne, neutralne, negatywne, bardzo negatywne)

Potrzebna jest duża ilość danych ponieważ ludzkie emocje są bardzo skomplikowane i często niezrozumiałe nawet dla nas samych. Nawet do setek tysięcy

2.2. Regresja

2.2.1. Przykład 1 - Szacowanie wieku człowieka na podstawie zdjęcia (np takiego do ID)

- Predyktory:
 - kolor włosów
 - zmarszczki
 - proporcje oczu do głowy (szczególnie u dzieci)
 - kolor skóry
 - przebarwienia
- Odpowiedzi:
 - wiek

Potrzebne może być nawet do dziesiątek tysięcy obserwacji może być potrzebne gdyż fizjologia ludzka jest skomplikowana

2.2.2. Przykład 2 - Prognozowanie czasu rozkładu biodegradowalnych materiałów

- Predyktory:
 - skład chemiczny
 - gęstość
 - porowatość

- temperatura
- wilgotność
- rodzaj środowiska (gleba, woda, kompost).
- Odpowiedź:
 - czas rozkładu

Potrzebne będą setki eksperymentów laboratoryjnych i terenowych.

2.3. Analiza klastrów

2.3.1. Przykład 1 - Grupowanie utworów muzyczny według klas np. nastroju czy gatunku (np. Spotify)

- Predyktory:
 - tempo
 - tonacja
 - analiza tekstu - używane słowa i wyrażenia
 - głośność
 - użyte instrumenty
 - użyte narzędzia modyfikowania dźwięku
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: muzyka melancholijna, wesoła, skoczna, buntownicza

Setki tysięcy lub nawet miliony utworów będą potrzebne by znaleźć widocznie wyróżniające się klastry.

2.3.2. Przykład 2 - Podział klientów sklepu na grupy o podobnych zainteresowaniach

- Predyktory:
 - średnia wartość zakupów
 - częstotliwość zakupów
 - najczęściej kupowane i przeglądane oferty
 - ocena satysfakcji klienta
 - lokalizacja klienta (może być nie dokładna, np. region - ciepły czy zimny)
- Odpowiedzi: brak klastrowanie odbywa się bez nadzoru i tworzy własne klasy / etykiety.
- Przykładowe etykiety nadane przez algorytm: klient zainteresowany ciuchami zimowymi / letnimi, wędkarz, sportowiec, kolekcjoner butów, stały klient, klient jednorazowy

Setki tysięcy klientów będą potrzebne by znaleźć wyróżniające się klastry.

3. Zadanie 3 - uczenie statystyczne - parametryczne a nieparametryczne

Opisz różnice między parametrycznym a nieparametrycznym podejściem do uczenia statystycznego. Jakie są wady i zalety podejścia parametrycznego w porównaniu do podejścia nieparametrycznego?

3.1. Parametryczne

Zakłada pewien rozkład danych, za pomocą skończonej (nie ogromnej) ilości parametrów. Umożliwia stosunkowo łatwą analizę modelu ale sprawia że jest ona tylko przybliżeniem. To podejście jest też mniej elastyczne i jest podatne na błędy związane z biasem.

3.2. Nieparametryczna

Nie wymaga założeń co do rozkładu danych. Model uczy się bardziej elastycznie dopasowując się do obserwacji. Dzięki temu otrzymujemy mniejszy bias ale możliwym jest zbyt dopasować model do danych (ang. overfitting). Podejście to wymaga dużej liczby obserwacji i przez to jest bardziej kosztowne niż podejście parametryczne.

3.3. Zalety i wady

	Uczenie parametryczne	Uczenie nieparametryczne
Zalety	• mały wariancja • łatwość analizy i interpretacji modelu • niski koszt obliczeń	• mały bias • duża elastyczność i dopasowanie do danych • Nie wymaga założeń o danych
Wady	• duży bias • mała elastyczność • słaba moc predykcyjna • wymaga założeń o danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń

4. Zadanie 4 - zbiór treningowy dla metody K najbliższych sąsiadów (ang. K -nearest neighbors)

4.1. a) odległość euklidesowa dla każdego punktu

1. $\sqrt{0^2 + 3^2 + 0^2} = \sqrt{9} = 3$,
2. $\sqrt{2^2 + 0^2 + 0^2} = \sqrt{4} = 2$,
3. $\sqrt{0^2 + 1^2 + 3^2} = \sqrt{10}$,
4. $\sqrt{0^2 + 1^2 + 2^2} = \sqrt{5}$,
5. $\sqrt{(-1)^2 + 0^2 + 1^2} = \sqrt{2}$,
6. $\sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}$

4.2. b) predykcja dla $K = 1$

Bierzemy najbliższego sąsiada którym jest obserwacja 5 i bierzemy jego odpowiedź → **Green**

4.3. c) predykcja dla $K = 3$

Bierzemy 3 najbliższych sąsiadów którymi są obserwacje 5 → Green, 6 → Red oraz 2 → Red i bierzemy najpopularniejszą odpowiedź wśród tych obserwacji → **Red**

4.4. d) lepsze małe czy duże wartości K dla silnie nieliniowej granicy decyzyjnej Bayesa

Jeśli granica decyzyjna Bayesa jest silnie nieliniowa (czyli prawdziwa granica między klasami jest bardzo złożona), to potrzebujemy bardziej elastycznego modelu, aby tę złożoność uchwycić. Małe wartości K dają klasyfikatorowi KNN większą elastyczność (niższy bias, wyższa wariancja) i pozwalają na odwzorowanie skomplikowanych, lokalnych zależności. Dlatego przy silnie nieliniowej granicy Bayesa zwykle lepiej sprawdzają się małe wartości K . (Przy przeciwnym założeniu — gładkiej granicy — większe K redukuje wariancję i może dać lepsze wyniki).

5. Zadanie 5 - Wartość oczekiwana i wariancja sumy zmiennych losowych

$$\text{Cov}(X, Y) = 0 \quad (5.1)$$

5.1. a) $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$

Proof.

$$\begin{aligned} \mathbb{E}(X + Y) &= \sum_x \sum_y (x + y) \Pr(X = x, Y = y) \\ &= \sum_x \sum_y x \cdot \Pr(X = x, Y = y) + \sum_x \sum_y y \cdot \Pr(X = x, Y = y) \\ &= \sum_x x \cdot \left(\sum_y \Pr(X = x, Y = y) \right) + \sum_y y \cdot \left(\sum_x \Pr(X = x, Y = y) \right) \quad (5.2) \\ &= \sum_x x \cdot \Pr(X = x) + \sum_y y \cdot \Pr(Y = y) \\ &= \mathbb{E}(X) + \mathbb{E}(Y) \end{aligned}$$

■

5.2. b) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Proof.

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[(X - \mathbb{E}(X))^2] \wedge (1) \\ &\Downarrow \end{aligned} \quad (5.3)$$

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X + Y - \mathbb{E}(X + Y))^2] \\ &= \mathbb{E}[((X - \mathbb{E}(X)) + (Y - \mathbb{E}(Y)))^2] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2 + (Y - \mathbb{E}(Y))^2 + 2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \\ &= \mathbb{E}[(X - \mathbb{E}(X))^2] + \mathbb{E}[(Y - \mathbb{E}(Y))^2] + \mathbb{E}[2 \cdot (X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \quad (5.4) \\ &= \text{Var}(X) + \text{Var}(Y) + \underbrace{2 \cdot \text{Cov}(X, Y)}_0 \\ &= \text{Var}(X) + \text{Var}(Y) \end{aligned}$$

■

6. Zadanie 6 - Przypomnienie estymatorów, jego bias'u i wariancji wrac z przykładami

Przypomnij, co to jest estymator oraz co to jest obciążenie (ang. bias) i wariancja estymatora. Podaj przykłady estymatorów obciążonych i nieobciążonych

6.1. Definicje

Estymator - To funkcja mająca za zadanie przybliżyć (wyestymować) wybrany parametr.

$$\theta \approx \hat{\theta}(X_1, X_2, \dots, X_n) \quad (6.5)$$

Bias estymatora - Jest wartość opisująca tendencje estymatora do zawyżania lub zaniżania wartości estymowanej

$$\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta \quad (6.6)$$

- Estymator nazywamy obciążonym gdy $\text{Bias}(\hat{\theta}) \neq 0$
- Estymator nazywamy nieobciążonym gdy $\text{Bias}(\hat{\theta}) = 0 \Rightarrow \mathbb{E}(\hat{\theta}) = \theta$

Wariancja estymatora - służy ocenianiu jak daleko, zazwyczaj, będzie estymator od estymowanej wartości

$$\text{Var}(\hat{\theta}) = \mathbb{E}\left(\left(\mathbb{E}(\hat{\theta}) - \hat{\theta}\right)^2\right) \quad (6.7)$$

MSE - Mean Square Error (ang. Błąd średniokwadratowy) tak samo jak wariancja

$$\text{MSE}(\hat{\theta}) = \mathbb{E}\left(\left(\hat{\theta}(X) - \theta\right)^2\right) \quad (6.8)$$

6.2. Przykłady

6.2.1. Nieobciążony

Typ estymatora	Przykład	Obciążenie
Średnia z próby	$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$	$\mathbb{E}(\hat{\mu}) = \mu \Rightarrow \text{Bias}(\hat{\mu}) = 0$
Wariancja z $n-1$	$\hat{\sigma}_{n-1}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_{n-1}^2) = \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_{n-1}^2) = 0$

6.2.2. Obciążony

Typ estymatora	Przykład	Obciążenie
Wariancja z n	$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$\mathbb{E}(\hat{\sigma}_n^2) = \frac{n-1}{n} \sigma^2 \Rightarrow \text{Bias}(\hat{\sigma}_n^2) = -\frac{\sigma^2}{n}$
$X \sim \text{Exp}(\lambda)$	MLE $\hat{\lambda} = \frac{1}{\bar{X}}$	$\mathbb{E}(\hat{\lambda}) = \frac{n}{n-1} \Rightarrow \text{Bias}(\hat{\lambda}) = \frac{1}{n-1} \lambda$

7. Zadanie 7 - dopasowywanie elastyczności modelu do scenariusza

Szukamy odpowiedniego modelu dla problemu związanego z uczeniem nadzorowanym. Dla każdego z punktów od (a) do (d), wskaż, czy ogólnie oczekivalibyśmy, że mało „elastyczny” model będzie lepszy czy gorsza od bardziej „elastycznego”. Uzasadnij swoją odpowiedź.

- Rozmiar próby n jest bardzo duży, a liczba predyktorów (and. predictor) p jest mała.
- Liczba predyktorów p jest bardzo duża, a liczba obserwacji n jest mała.
- Zależność między predyktorami a odpowiedzią (and. response) wykazuje wyraźnie nieliniowy charakter.
- Wariancja błędów, tj. $\sigma^2 = \text{Var}(\varepsilon)$, jest bardzo wysoka.

Sformułuj wnioski dotyczące tego, jakie są zalety i wady bardziej elastycznego modelu, w porównaniu z mniej elastycznym? W jakich okolicznościach bardziej elastyczny model może być preferowany? Kiedy preferowany może być mniej elastyczny model?

Przypadek	Elastyczność modelu	Uzasadnienie
a) n - duże, p - małe	Bardziej elastyczny	Elastyczny model może wykorzystać dużą liczbę obserwacji aby dopasować się i dzięki temu obniża bias
b) n - małe p - duże	Mniej elastyczny	Duża liczba predyktorów grozi overfittingiem, należy najpierw dokonać redukcji wymiaru tak aby p było mniejsze od n a następnie wykorzystać mniej elastyczny model aby uzyskać model zwiększyć wydajność na małej ilości danych
c) silna nieliniowość danych	Bardziej elastyczny	Elastyczny model lepiej dopasuje się do danych i lepiej przedstawi nieliniowość, nie uśredniając jej tak jak zrobiłby to model mniej elastyczny
d) Wysoka wariancja szumu	Mniej elastyczny	Mniej elastyczny model uśredni dane i zniweluje w ten sposób wysoką wariancję szumu

7.1. Wnioski

	Model mniej elastyczny	Model bardziej elastyczny
Zalety	• stabilny, z małą wariancją • łatwiejszy do interpretacji • bardziej odporny na szum • sprawdza się lepiej dla małych n względem p	• niski bias • świetny dla dużych n • uchwyci złożone zależności
Wady	• duży bias • słaby przy dużej nieliniowości danych	• duża wariancja • niezrozumiały sposób działania (black box) • duży koszt obliczeń • kiepski dla małych n • ryzyko overfittingu

Algorytmiczna Analiza Danych

Ćwiczenia 3

17 października 2025 r.

Adrian Herda
Politechnika Wrocławska

8. Zadanie 8 - MSE jako suma kwadratu $bias$ 'u wariancji funkcji przybliżającej i wariancji szumu

$$MSE = \mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \quad (8.9)$$

8.1. Rozwiązanie

1. $\mathbb{E}[\varepsilon] = 0 \Rightarrow \mathbb{E}[\varepsilon]^2 = 0 \Rightarrow \sigma_\varepsilon^2 = \mathbb{E}[\varepsilon^2]$
2. Szum jest niezależny z żadną inną zmienną

Proof.

$$\begin{aligned} \mathbb{E}[(y_0 - \hat{f}(x_0))^2] &= \mathbb{E}[(f(x_0) + \varepsilon - \hat{f}(x_0))^2] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \underbrace{\mathbb{E}[\varepsilon^2]}_{\sigma_\varepsilon^2} + 2\mathbb{E}[(f(x_0) - \hat{f}(x_0))\varepsilon] \\ &= \mathbb{E}[(f(x_0) - \hat{f}(x_0))^2] + \sigma_\varepsilon^2 + \underbrace{2(f(x_0) - \mathbb{E}[\hat{f}(x_0)])\mathbb{E}[\varepsilon]}_0 \\ &= \mathbb{E}[f(x_0)^2 + \hat{f}(x_0)^2 - 2f(x_0)\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 + \mathbb{E}[\hat{f}(x_0)^2] - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \sigma_\varepsilon^2 \\ &= f(x_0)^2 - 2f(x_0)\mathbb{E}[\hat{f}(x_0)] + \underbrace{\mathbb{E}[\hat{f}(x_0)]^2 - \mathbb{E}[\hat{f}(x_0)]^2}_0 + \mathbb{E}[\hat{f}(x_0)^2] + \sigma_\varepsilon^2 \\ &= (f(x_0) - \mathbb{E}[\hat{f}(x_0)])^2 + (\mathbb{E}[\hat{f}(x_0)^2] - \mathbb{E}[\hat{f}(x_0)]^2) + \sigma_\varepsilon^2 \\ &= \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma_\varepsilon^2 \end{aligned} \quad (8.10)$$


■

8.2. Równowaga bias-variance

W miarę jak model staje się bardziej elastyczny, jego zdolność do uchwycenia złożoności danych rośnie, co prowadzi do zmniejszenia błędu bias. Jednakże, większa elastyczność może również prowadzić do większej wariancji, ponieważ model może zacząć „przeuczać” się na dane treningowe. W rezultacie, istnieje kompromis między bias a wariancją, który należy uwzględnić podczas projektowania modeli.

Optymalny wybór złożoności/regularizacji minimalizuje sumę $\text{Bias}^2 + \text{Var}$.
Składnik ε jest nieredukowalny.

9. Zadanie 9 - Wykresy względem elastyczności modelu



9.1. Wytlumaczenie każdej funkcji

Niebieski - W miarę jak modele stają się bardziej elastyczne i złożone, błąd treningowy maleje, ale z coraz mniejszym zyskiem.

Czerwony - Często obserwujemy kształt litery U w błędzie na zbiorze walidacyjnym. Jest to kombinacja błędu Bias (obserwowanego przy najmniej elastycznym modelu), błędu Variance (wynikającego z przeuczenia najbardziej elastycznych modeli) oraz składnika błędu nieusuwalnego.

Niebieski - Składnik błędu Bias, im bardziej elastyczny model tym lepiej się dopasowuje tym mniejszy jest Bias.

Brązowy - Składnik błędu Variance. Im bardziej elastyczny model tym większe różnice w wynikach na zbiorze treningowym i walidacyjnym.

Czarny - Składnik błędu nieusuwalnego. Niezmienna wartość szumu.

10. Zadanie 10 - Obliczanie wzorów na parametry modelu linowego

10.1. Dane

- n obserwacji: $\{(x_1, y_1), \dots, (x_n, y_n)\}$,
- model linowy: $y_i = \beta_0 + \beta_1 x_i + e_i$

10.2. Cel

Szacujemy β_0, β_1 poprzez minimalizację błędu średniokwadratowego:

$$\text{MSE}(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \quad (10.11)$$

Udowodnij że:

1. $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
2. $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

Proof. Różniczkujemy i przyrównujemy do zera:

$$\frac{\partial}{\partial \hat{\beta}_0} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.12)$$

$$\frac{\partial}{\partial \hat{\beta}_1} \text{MSE} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)) = 0 \quad (10.13)$$

Z równania (10.12) mamy:

$$\begin{aligned} \sum_{i=1}^n y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i &= 0 \\ n\hat{\beta}_0 &= \sum_{i=1}^n y_i - \hat{\beta}_1 \sum_{i=1}^n x_i \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned} \quad (10.14)$$

Podstawiając do równania (10.13) mamy:

$$\begin{aligned}
0 &= \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \cdot n\bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
0 &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - n\bar{y}\bar{x} + n\bar{y}\bar{x} - n\bar{y}\bar{x} \\
\hat{\beta}_1 \left(\sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2\bar{x}x_i + \sum_{i=1}^n \bar{x}^2 \right) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n \bar{y}x_i + \sum_{i=1}^n \bar{y}\bar{x} - \sum_{i=1}^n \bar{x}y_i \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) &= \sum_{i=1}^n (x_i y_i - \bar{y}x_i) + (\bar{y}\bar{x} - \bar{x}y_i) \\
\hat{\beta}_1 \sum_{i=1}^n (x_i^2 - \bar{x}^2)^2 &= \sum_{i=1}^n x_i (y_i - \bar{y}) - \bar{x} (y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i^2 - \bar{x}^2)^2}
\end{aligned} \tag{10.15}$$

■

10.3. Udowodnij że funkcja ta zawsze przejdzie przez punkt $(\bar{x}, \bar{y})$

Proof. Podstawiając $x = \bar{x}$ do równania (10.12) prostej:

$$\begin{aligned}
y &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \\
&= (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} \\
&= \bar{y}
\end{aligned} \tag{10.16}$$

■

11. Zadanie 11 - Błąd systematyczny, wariancja i błąd standardowy dla estymatorów w modelu liniowym

$$y_i = \beta_0 + \beta_1 x_i + e_i \tag{11.17}$$

Estymaotry jak w modelu z zadania w sekcji 10.

Oraz niech: $S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$

11.1. Błąd systematyczny

$$E[\hat{\beta}_0] = \beta_0 \Rightarrow \text{Bias}(\hat{\beta}_0) = 0 \quad (11.18)$$

$$E[\hat{\beta}_1] = \beta_1 \Rightarrow \text{Bias}(\hat{\beta}_1) = 0 \quad (11.19)$$

11.2. Wariancja

Zmienne e_i dla $i \in \{1, \dots, n\}$ są niezależne

11.2.1. Reprezentacja estymatorów za pomocą szumów

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.20)$$

$$\hat{\beta}_0 = \beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}} \quad (11.21)$$

11.2.2. Wariancja estymatorów

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left(\beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \text{Var}\left(\frac{\sum_{i=1}^n (x_i - \bar{x})e_i}{S_{xx}}\right) \\ &= \frac{1}{(S_{xx})^2} \text{Var}\left(\sum_{i=1}^n (x_i - \bar{x})e_i\right) \\ &= \frac{1}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) \\ &= \frac{\sigma^2}{S_{xx}} \end{aligned} \quad (11.22)$$

$$\begin{aligned}
\text{Var}(\hat{\beta}_0) &= \text{Var}\left(\beta_0 + \frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i - \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n e_i\right) + \text{Var}\left(\bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) - 2 \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n e_i, \bar{x} \frac{\sum_{i=1}^n (x_i - \bar{x}) e_i}{S_{xx}}\right) \\
&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(e_i) + \frac{\bar{x}^2}{(S_{xx})^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(e_i) - 2 \frac{\bar{x}}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \text{Var}(e_i) \quad (11.23) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} - 2 \bar{x} \frac{\sigma^2}{n S_{xx}} \cdot 0 \\
&= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{S_{xx}} \\
&= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)
\end{aligned}$$

11.3. Błąd standardowy estymatorów

$$\text{SE}(\hat{\beta}_0) = \sqrt{\text{Var}(\hat{\beta}_0)} = \sqrt{\sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} = \sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} \quad (11.24)$$

$$\text{SE}(\hat{\beta}_1) = \sqrt{\text{Var}(\hat{\beta}_1)} = \sqrt{\frac{\sigma^2}{S_{xx}}} = \frac{\sigma}{\sqrt{S_{xx}}} \quad (11.25)$$

12. Zadanie 12 - Suma zmiennych losowych o rozkładzie normalnym ma rozkład normalny

1. $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$
2. $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$
3. $Z = X + Y$

Udowodnij że $Z \sim \mathcal{N}(\mu_Z, \sigma_Z^2)$

Proof. Funkcje charakterystyczne zmiennych losowych:

$$\varphi_X(t) = \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right), \quad \varphi_Y(t) = \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \quad (12.26)$$

Zmienna losowa Z jest sumą niezależnych zmiennych losowych X i Y , więc jej funkcja charakterystyczna jest iloczynem funkcji charakterystycznych X i Y :

$$\begin{aligned}\varphi_Z(t) &= \varphi_X(t) \cdot \varphi_Y(t) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2}\right) \cdot \exp\left(i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i\mu_X t - \sigma_X^2 \frac{t^2}{2} + i\mu_Y t - \sigma_Y^2 \frac{t^2}{2}\right) \\&= \exp\left(i(\mu_X + \mu_Y)t - (\sigma_X^2 + \sigma_Y^2) \frac{t^2}{2}\right) \\&= \exp\left(i\mu_Z t - \sigma_Z^2 \frac{t^2}{2}\right)\end{aligned}\tag{12.27}$$

■

Algorytmiczna Analiza Danych

Ćwiczenia 4

24 października 2025 r.

Adrian Herda
Politechnika Wrocławska

13. Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale

Jako że $e_i \sim \mathcal{N}(0, \sigma^2)$ oraz są niezależne, to zgodnie z własnościami rozkładu normalnego, estymator $\hat{\beta}_1$ również ma rozkład normalny z wartością oczekiwaną równą β_1 oraz wariancją $\text{Var}(\hat{\beta}_1)$.

13.1. Reguła trzech sigm

Reguła trzech sigm mówi, że w rozkładzie normalnym ok. 99.7% masy leży w przedziale $\mathbb{E}[X] \pm 3\sigma_X$ dla każdej zmiennej losowej $X \sim \mathcal{N}(\mathbb{E}[X], \sigma_X)$. Dla $\mathbb{E}[X] \pm 2\sigma_X$ mamy ok. 95%.

To tylko krótkie heurystyczne odwołanie do „regułki 68 – 95 – 99.7” dla rozkładu normalnego ($1\sigma \approx 68\%$, $2\sigma \approx 95\%$, $3\sigma \approx 99.7\%$).

13.2. Ustandaryzowana zmienna

Niech

$$Z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim \mathcal{N}(0, 1) \quad (13.28)$$

Wtedy:

$$\Pr(|\hat{\beta}_1 - \beta_1| \leq 2\sqrt{\text{Var}(\hat{\beta}_1)}) = \Pr(|Z| \leq 2) \quad (13.29)$$

Ze wzoru na gęstość prawdopodobieństwa w standardowym rozkładzie normalnym mamy:

$$\begin{aligned} \Pr(|Z| \leq 2) &= \int_{-2}^2 \varphi(x) dx \\ &= \Phi(2) - \Phi(-2) \\ &= \Phi(2) - (1 - \Phi(2)) \\ &= 2\Phi(2) - 1 \\ &= 0.9545 \end{aligned} \quad (13.30)$$

14. Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami

14.1. Teza

Estymatory:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} \in \mathbb{R}^{k+1} \quad (14.31)$$

Wzór:

$$\hat{\beta} = (X^T X)^{-1} X^T \vec{y} \quad (14.32)$$

gdzie X to macierz danych a $\vec{y}$ to wektor odpowiedzi.

14.2. Dowód

$$y = f(x) + \varepsilon \quad (14.33)$$

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k \quad (14.34)$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (14.35)$$

$$\vec{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad (14.36)$$

$$\vec{y} = X\beta + \varepsilon$$

$\Downarrow$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \beta_0 + \beta_1 x_{11} + \dots + \beta_k x_{1k} + \varepsilon_1 \\ \beta_0 + \beta_1 x_{21} + \dots + \beta_k x_{2k} + \varepsilon_2 \\ \vdots \\ \beta_0 + \beta_1 x_{n1} + \dots + \beta_k x_{nk} + \varepsilon_n \end{pmatrix} \quad (14.37)$$

$$\varepsilon = \vec{y} - \hat{y} \wedge \text{RSS} = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon^T \varepsilon \quad (14.38)$$

$\Downarrow$

$$\text{RSS} = (\vec{y} - \hat{y})^T (\vec{y} - \hat{y})$$

$$\begin{aligned} J(\hat{\beta}) &= (\vec{y} - X\hat{\beta})^T (\vec{y} - X\hat{\beta}) \\ &= (\vec{y}^T - \hat{\beta}^T X^T) (\vec{y} - X\hat{\beta}) \\ &= \vec{y}^T \vec{y} - \vec{y}^T X\hat{\beta} - \hat{\beta}^T X^T \vec{y} + X^T \hat{\beta}^T X\hat{\beta} \\ &= \vec{y}^T \vec{y} - 2\vec{y}^T X\hat{\beta} + \hat{\beta}^T X^T X\hat{\beta} \end{aligned} \quad (14.39)$$

Chcemy najmniejszą wartość RSS. Liczymy pochodną cząstkową po $\hat{\beta}$ i przyrównujemy do zera:

$$\begin{aligned}\frac{\partial J}{\partial \hat{\beta}} &= 2X^T X \hat{\beta} - 2X^T \vec{y} = 0 \\ X^T X \hat{\beta} &= X^T \vec{y} \\ \hat{\beta} &= (X^T X)^{-1} X^T \vec{y}\end{aligned}\tag{14.40}$$

Algorytmiczna Analiza Danych

Ćwiczenia 5

7 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

15. Zadanie 15 - Korelacja

$$\begin{aligned}
 \text{TSS} &= \sum_{i=1}^n (Y_i - \bar{Y}_i)^2 = S_{yy} \\
 &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y}_i)^2 \\
 &= \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{RSS}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}_{\text{ESS}} - 2 \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}_i)}_{\text{Własność ortogonalności reszt} \rightarrow 0} \\
 &= \text{RSS} + \text{ESS}
 \end{aligned} \tag{15.41}$$

$$\begin{aligned}
 \hat{\beta}_0 &= \bar{Y}_i - \hat{\beta}_1 \bar{X} \\
 \hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\
 &= (\bar{Y}_i - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 X_i \\
 &= \bar{Y}_i + \hat{\beta}_1 (X_i - \bar{X}) \\
 \hat{Y}_i - \bar{Y}_i &= \hat{\beta}_1 (X_i - \bar{X})
 \end{aligned} \tag{15.42}$$

$$\text{ESS} = \hat{\beta}_1^2 S_{yy}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$\begin{aligned}
 R^2 &= 1 - \frac{\text{RSS}}{\text{TSS}} \\
 &= \frac{\text{RSS} + \text{ESS} - \text{RSS}}{\text{TSS}} \\
 &= \frac{\text{ESS}}{\text{TSS}} \\
 &= \left(\frac{S_{xy}}{S_{xx}} \right)^2 \frac{S_{xx}}{S_{yy}} \\
 &= \frac{S_{xy}^2}{S_{xx} S_{yy}} \\
 &= \text{Corr}(X, Y)^2
 \end{aligned} \tag{15.43}$$

■

16. Zadanie 16 - t-statystyka i p-wartość

Wyjaśnij czym jest t-statystyka i w jaki sposób możemy jej użyć w kontekście regresji liniowej. Czym jest p-wartość?

16.1. t-statystyka

t-statystyka to miara używana w statystyce do oceny istotności współczynników regresji w modelu regresji liniowej. Określa, jak wiele standardowych błędów odchyła się estymowany współczynnik od wartości zerowej (hipoteza zerowa). Wzór na t-statystykę dla współczynnika regresji $\hat{\beta}_j$ jest następujący:

$$t_j = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \quad (16.44)$$

gdzie $\text{SE}(\hat{\beta}_j)$ to standardowy błąd estymatora współczynnika regresji $\hat{\beta}_j$.

16.2. p-wartość

p-wartość to prawdopodobieństwo uzyskania wyników co najmniej tak ekstremalnych jak obserwowane, zakładając, że hipoteza zerowa jest prawdziwa. W kontekście regresji liniowej, p-wartość jest używana do oceny istotności statystycznej współczynników regresji. Niska p-wartość (zazwyczaj poniżej 0.05) sugeruje odrzucenie hipotezy zerowej, co oznacza, że istnieje statystycznie istotny związek między zmienną niezależną a zmienną zależną.

17. Zadanie 17 - Odległość Mahalanobisa

Wyjaśnij czym jest odległość Mahalanobisa i jaki jest jej związek z leverage statistic.

17.1. odpowiedź

Odległość Mahalanobisa to miara odległości między punktem a rozkładem prawdopodobieństwa. W przeciwieństwie do standardowej odległości euklidesowej, odległość Mahalanobisa uwzględnia korelacje między zmiennymi i skalę danych. Jest definiowana jako:

$$D_{M(x)} = \sqrt{(x - \mu)^T S^{-1} (x - \mu)} \quad (17.45)$$

gdzie μ to wektor średnich zmiennych, a S to macierz kowariancji.

Odległość Mahalanobisa jest szczególnie użyteczna w kontekście analizy regresji, ponieważ pozwala na identyfikację obserwacji, które są nietypowe lub odstające w kontekście całego zbioru danych. Wartości odległości Mahalanobisa mogą być używane do obliczania statystyki leverage, która mierzy wpływ danej obserwacji na dopasowanie modelu regresji. Obserwacje o wysokiej odległości Mahalanobisa mogą mieć duży wpływ na estymację współczynników regresji i mogą być potencjalnymi punktami odstającymi.

18. Zadanie 18 - Double descent

Na podstawie materiału wideo i rozdziału 10.8 w książce ISL opisz zjawisko double descent

18.1. Odpowiedź

- W fazie podparametryzowanej („under-parameterized”) - model nie ma wystarczającej mocy, by dobrze dopasować dane $\rightarrow$ testowy błąd jest stosunkowo wysoki, ale spada wraz ze wzrostem złożoności.
- Następnie w okolicy punktu, kiedy liczba parametrów $\approx$ liczba próbek (lub model może dokładnie dopasować dane) - następuje wzrost błędu testowego (szczyt) z powodu dużej wariancji, niestabilności.
- Potem, w nadparametryzowanej („over-parameterized”) fazie - mimo że model może „przeuczyć” dane, okazuje się, że zwiększanie złożoności dalej prowadzi do spadku błędu testowego. Model bardzo duży generalizuje lepiej niż średni.

Algorytmiczna Analiza Danych

Ćwiczenia 6

14 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

19. Zadanie 19

Przypomnij, czym jest estymator największej wiarygodności. Przedstaw i wyjaśnij własności takiego estymatora (w szczególności asymptotyczną nieobciążoność i efektywność).

19.1. Odpowiedź

19.1.1. Definicja

Założmy, że mamy próbę losową $X_1, \dots, X_n$ pochodzącą z rozkładu o funkcji gęstości (lub masie prawdopodobieństwa) $f(x; \theta)$, gdzie θ to nieznaną parametr populacji (np. średnia, wariancja, parametr Bernoulliego itd.).

Funkcja wiarygodności (likelihood function) określa prawdopodobieństwo zaobserwowania danej próby przy danym parametrze θ :

$$L(\theta) = f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta) \quad (19.46)$$

albo w postaci logarytmicznej (częściej stosowanej dla wygody obliczeń):

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta) \quad (19.47)$$

Estymator największej wiarygodności (ENW) to wartość $\hat{\theta}$, która maksymalizuje funkcję wiarygodności:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} L(\theta) \quad (19.48)$$

lub równoważnie:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} \ell(\theta) \quad (19.49)$$

19.1.2. Własności

Spójność - Gdy liczba obserwacji $n \rightarrow \infty$ to estymator największej wiarygodności zbliża się do prawdziwej wartości parametru θ

$$\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta \quad (19.50)$$

Efektywność - Przy pewnych warunkach estymator największej wiarygodności zbliża się, w dystrybucji, do rozkładu normalnego:

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \sim \mathcal{N}(0, \mathcal{I}^{-1}) \quad (19.51)$$

gdzie

$$\mathcal{J}_{jk} = \mathbb{E} \left[-\frac{\partial^2 f_{\theta_0}(X_t)}{\partial \theta_j \partial \theta_k} \right] \quad (19.52)$$

to macierz informacji Fishera.

20. Zadanie 20

Założmy, że mamy n obserwacji $x_1, \dots, x_n$ pochodzących z rozkładu normalnego zmiennej losowej $X \sim \mathcal{N}(\mu, \sigma^2)$. Wyprowadź estymator największej wiarygodności dla parametru μ

20.1. Rozwiązanie

$$f(x_i; \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (20.53)$$

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(x_i; \mu) \\ \ell(\mu) &= \sum_{i=1}^n \ln f(x_i; \mu) \\ &= \sum_{i=1}^n \ln \left((2\pi\sigma^2)^{-\frac{1}{2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right) \\ &= \sum_{i=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (20.54)$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\mu} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\mu} &= \frac{d}{d\mu} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right) \\
&= -\frac{1}{2\sigma^2} \frac{d}{d\mu} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n \frac{d}{d\mu} (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n (-2x_i + 2\mu) \\
&= -\frac{1}{\sigma^2} \sum_{i=1}^n (-x_i + \mu) \\
&= \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) \\
&= \sum_{i=1}^n (\mu - x_i) \\
&= n\mu - \sum_{i=1}^n x_i \\
n\mu &= \sum_{i=1}^n x_i \\
\hat{\mu}_{\text{MLE}} &= \frac{1}{n} \sum_{i=1}^n x_i
\end{aligned} \tag{20.55}$$

21. Zadanie 21

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu wykładniczego z nieznanym parametrem λ . Wyprowadź estymator największej wiarygodności dla parametru λ . Wskaż intuicyjnie, dlaczego ten estymator ma sens.

21.1. Rozwiązanie

$$f(x; \lambda) = \lambda e^{-\lambda x} \tag{21.56}$$

$$\begin{aligned}
L(\lambda) &= \prod_{i=1}^n f(x_i; \lambda) \\
&= \lambda^n \exp(-\lambda n x_i) \\
&= \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right) \\
\ell(\lambda) &= n \ln \lambda - \lambda \sum_{i=1}^n x_i
\end{aligned} \tag{21.57}$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\lambda} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
0 &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
\frac{n}{\lambda} &= \sum_{i=1}^n x_i \\
\hat{\lambda}_{\text{MLE}} &= \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}
\end{aligned} \tag{21.58}$$

22. Zadanie 22

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu jednostajnego na przedziale $[0, \theta]$, gdzie θ jest nieznanym parametrem. Wyprowadź estymator największej wiarygodności dla parametru θ . Wskaż intuicyjnie, dlaczego ten estymator ma sens. Czy ten estymator jest nieobciążony?

22.1. Rozwiązanie

$$f(x; \theta) = \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x) \tag{22.59}$$

$$\begin{aligned}
L(\theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) \\
&= \theta^{-n} \mathbf{1}_{\{\forall_i, x_i \leq \theta\}} \\
&= \theta^{-n} \mathbf{1}_{\{\max_i x_i \leq \theta\}} \\
&= \begin{cases} 0, & \max_i x_i > \theta \\ \theta^{-n}, & \max_i x_i \leq \theta, \text{ funkcja malejąca} \end{cases}
\end{aligned} \tag{22.60}$$

Chcąc osiągnąć największe możliwe $L(\theta)$ musimy zminimalizować θ tak aby nadal $\forall_i x_i \leq \theta \Rightarrow \max_i x_i \leq \theta$. Więc największa wartość $L(\theta)$ jest osiągnięta dla:

$$\hat{\theta}_{\text{MLE}} = \max_i x_i = x_{(n)} \tag{22.61}$$

22.2. Czy estymator nieobciążony?

Nie, estymator jest obciążony.

Proof. Rozkład $x_{(n)}$ (maksimum) dla $x \in [0, \theta]$:

$$F_{x_{(n)}}(x) = P(x_{(n)} < x) = \left(\frac{x}{\theta}\right)^n \tag{22.62}$$

$$\begin{aligned}
\mathbb{E}[\hat{\theta}_{\text{MLE}}] &= \mathbb{E}[x_{(n)}] = \int_0^\theta x dF_{x_{(n)}}(x) \\
&= \int_0^\theta x \cdot n \frac{x^{n-1}}{\theta^n} dx \\
&= \frac{n}{\theta^n} \int_0^\theta x^n dx \\
&= \frac{n}{\theta^n} \left(\frac{x^{n+1}}{n+1} \right) \Big|_0^\theta \\
&= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \\
&= \frac{n}{n+1} \theta \neq \theta
\end{aligned} \tag{22.63}$$

$$\begin{aligned}
\text{Bias}(\hat{\theta}_{\text{MLE}}) &= \mathbb{E}[\hat{\theta}_{\text{MLE}}] - \theta \\
&= \frac{n}{n+1} \theta - \theta \\
&= -\frac{1}{n+1} \theta
\end{aligned} \tag{22.64}$$

■

23. Zadanie 23

23.1. a) $p = 1$

Ułamek próby który użyjemy $\frac{0.10}{1} = 0.1$

23.2. b) $p = 2$

Teraz chcemy wykorzystać kwadrat o długości $X_1 = 0.1$ oraz szerokości $X_2 = 0.1$

Ułamek próby który użyjemy: $\frac{0.1 \cdot 0.1}{1} = 0.01$

23.3. c) $p = 100$

Teraz chcemy wykorzystać hiperkostkę o długości boku 0.1

Ułamek próby który użyjemy: $\frac{0.1^{100}}{1} = 10^{-100} \approx 0$

23.4. d)

Im większe p tym mniej punktów leży w odległości 0.1 od testowego, więc metody oparte na lokalności się trochę psują, mając mało danych do porządnego przewidywania. Rośnie wariancja a żeby ją kontrolować musimy zwiększać K lub zwiększać okno szukania co psuje założenie lokalności.

23.5. e)**23.5.1. Wzór**

Niech w to długość krawędzi hiperkostki wewnętrznej, zawierającej $\approx 10\%$ obszaru trenin-
gowych

$$\begin{aligned} 0.1 &= w^p \\ w &= \sqrt[p]{0.1} \end{aligned} \tag{23.65}$$

23.5.2. Wyniki

p	w
1	0.1
2	$\sqrt{0.1} \approx 0.31$
100	$\sqrt[100]{0.1} \approx 0.977$

Prawie cała objętość hiperkostki leży w jej brzegach. Nie da się być lokalnym i mieć wystar-
czająco dużo sąsiadów $\rightarrow$ Klątwa wielowymiarowości

Algorytmiczna Analiza Danych

Ćwiczenia 7

21 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

24. Zadanie 24 – Ocena modelu w problemie klasyfikacji

24.1. Oznaczenia

Stosujemy następujące oznaczenia w macierzy pomyłek:

- **TP (True Positive)** - Prawdziwie pozytywne.
- **TN (True Negative)** - Prawdziwie negatywne.
- **FP (False Positive)** - Fałszywie pozytywne (błąd I rodzaju).
- **FN (False Negative)** - Fałszywie negatywne (błąd II rodzaju).

24.2. a) Metryki: Accuracy, Precision, Recall oraz F1

24.2.1. Definicje metryk

1. **Accuracy (Dokładność)** - Określa, jak często model ma rację.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (24.66)$$

2. **Precision (Precyzja)** - Określa wiarygodność pozytywnej predykcji (ile z przewidzianych „jedynek” to faktycznie „jedynki”).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (24.67)$$

3. **Recall (Czułość)** - Określa zdolność modelu do wykrywania klasy pozytywnej (ile faktycznych „jedynek” udało się znaleźć).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (24.68)$$

4. **F1-Score** - Średnia harmoniczna precyzji i czułości. Jest lepszą miarą niż Accuracy przy niebalansowanych danych.

$$F1 = 2 \cdot \left(\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \right) \quad (24.69)$$

24.2.2. Przykład

Testujemy wykrywacz choroby (10 chorych, 90 zdrowych). Model wykrył 8 chorych, ale też błędnie wskazał 10 zdrowych jako chorych.

- $\text{Accuracy} = \frac{8+80}{100} = 0.88$
- $\text{Precision} = \frac{8}{8+10} \approx 0.44$

- $\text{Recall} = \frac{8}{8+2} = 0.80$

24.3. b) Różnica wersji *micro* od *macro*

- **Macro Average** - Liczymy metrykę (np. F1) dla każdej klasy osobno, a potem wyciągamy z nich średnią. Traktuje każdą klasę równoważnie (dobre do wykrywania błędów w rzadkich klasach).
- **Micro Average** - Sumujemy wszystkie TP, FP, FN globalnie i liczymy metrykę raz. W klasyfikacji wieloklasowej (single-label) Micro-F1 jest równoważne Accuracy. Faworyzuje klasy większościowe.

Przykład: Klasa A (100 próbek, model idealny), Klasa B (10 próbek, model tragiczny).

- **Micro** będzie wysokie (zdominowane przez A).
- **Macro** będzie niskie (uwidoczni błąd na B).

24.4. c) Potoczne rozumienie a definicja

- **Accuracy** - Potocznie „jakość”. W *ML* może być mylące - model przewidujący zawsze brak rzadkiego zdarzenia (np. wygrana w lotto) ma 99.9% accuracy, a jest bezużyteczny.
- **Precision** - Potocznie kojarzy się z „dokładnością pomiaru”. W *ML* to „brak fałszywych alarmów”.

25. Zadanie 25 – Naiwny Klasyfikator Bayesa

25.1. Definicja

Naiwny klasyfikator Bayesa - model probabilistyczny oparty na twierdzeniu Bayesa, który zakłada **warunkową niezależność** cech (x_i) od siebie przy znanej klasie (C_k).

Warto go stosować, gdy mamy mało danych (szybka zbieżność), bardzo wysoki wymiar danych (np. tekst) lub potrzebujemy szybkiego modelu bazowego.

25.2. Dowód wzoru

Theorem 25.1.

$$\Pr(C_k \mid x_1, \dots, x_n) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.70)$$

Proof. Wychodzimy z twierdzenia Bayesa:

$$\Pr(C_k \mid x) = \frac{\Pr(x \mid C_k) \Pr(C_k)}{\Pr(x)} \quad (25.71)$$

Gdzie $x = (x_1, \dots, x_n)$. W liczniku mamy prawdopodobieństwo łączne $\Pr(x_1, \dots, x_n \mid C_k)$. Stosujemy „naiwne” założenie o niezależności cech:

$$\Pr(x_1, \dots, x_n \mid C_k) \approx \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (25.72)$$

Podstawiając do licznika:

$$\Pr(C_k | x) = \frac{\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k)}{\Pr(x)} \quad (25.73)$$

$$\Pr(C_k | x) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \quad (25.74)$$

Mianownik $\Pr(x)$ jest sumą po wszystkich klasach (z prawa całkowitego prawdopodobieństwa):

$$\Pr(x) = \sum_k \Pr(x | C_k) \Pr(C_k) = \sum_k \left(\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \right) \quad (25.75)$$

■

26. Zadanie 26 – Klasyfikacja Spam vs Nie-spam

Dane:

- $N = 1000$ e-maili.
- Klasa C_1 (Spam): 100 e-maili (wszystkie $x_1 = 1, x_2 = 1$).
- Klasa C_2 (Nie-spam): 900 e-maili (450: $x_1 = 1, x_2 = 0$ oraz 450: $x_1 = 0, x_2 = 1$).

Szukamy predykcji dla nowego e-maila $x = (x_1 = 1, x_2 = 1)$.

1. Prawdopodobieństwa a priori (Priors):

$$\Pr(C_1) = \frac{100}{1000} = 0.1 \quad (26.76)$$

$$\Pr(C_2) = \frac{900}{1000} = 0.9 \quad (26.77)$$

2. Prawdopodobieństwa warunkowe (Likelihoods):

- Dla C_1 (Spam):
 - $\Pr(x_1 = 1 | C_1) = \frac{100}{100} = 1$
 - $\Pr(x_2 = 1 | C_1) = \frac{100}{100} = 1$
- Dla C_2 (Nie-spam):
 - $\Pr(x_1 = 1 | C_2) = \frac{450}{900} = 0.5$
 - $\Pr(x_2 = 1 | C_2) = \frac{450}{900} = 0.5$

3. Obliczenia dla nowego e-maila (licznik wzoru Bayesa):

- Dla Spam:

$$L(C_1) = \Pr(C_1) \cdot \Pr(x_1 = 1 | C_1) \cdot \Pr(x_2 = 1 | C_1) = 0.1 \cdot 1 \cdot 1 = 0.1 \quad (26.78)$$

- Dla Nie-spam:

$$L(C_2) = \Pr(C_2) \cdot \Pr(x_1 = 1 | C_2) \cdot \Pr(x_2 = 1 | C_2) = 0.9 \cdot 0.5 \cdot 0.5 = 0.225 \quad (26.79)$$

4. Normalizacja i wynik:

$$\text{Evidence } \Pr(x) = 1 \cdot 1 \cdot 0.1 + 0.5 \cdot 0.5 \cdot 0.9 = 0.1 + 0.225 = 0.325.$$

$$\Pr(C_1 | x) = \frac{0.1}{0.325} \approx 0.308 \quad (26.80)$$

$$\Pr(C_2 | x) = \frac{0.225}{0.325} \approx 0.692 \quad (26.81)$$

Odp: Prawdopodobieństwo, że to Spam wynosi ok. 30.8%, a że Nie-spam ok. 69.2%.

27. Zadanie 27 – Regresja Logistyczna

27.1. a) Dlaczego nie regresja liniowa?

- Predykcje mogą wykraczać poza przedział $[0, 1]$.
- Zależność rzadko jest liniowa (często przyjmuje kształt litery S).
- Niespełnione założenie o stałej wariancji reszt (heteroskedastyczność).

27.2. b) Obliczenie szans (Odds)

Dane: $p = 0.75$.

$$\text{Odds} = \frac{p}{1-p} = \frac{0.75}{1-0.75} = \frac{0.75}{0.25} = 3 \quad (27.82)$$

Szanse wynoszą 3 do 1.

27.3. c) Dowód równoważności z Log-Odds

Model:

$$\Pr(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (27.83)$$

Oznaczmy $z = \beta_0 + \beta_1 X$. Wtedy $p = \frac{e^z}{1+e^z}$.

1. Obliczamy $1 - p$:

$$1 - p = 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z - e^z}{1 + e^z} = \frac{1}{1 + e^z} \quad (27.84)$$

2. Dzielimy p przez $1 - p$:

$$\frac{p}{1-p} = \frac{\frac{e^z}{1+e^z}}{\frac{1}{1+e^z}} = \left(\frac{e^z}{1+e^z} \right) \cdot \left(\frac{1+e^z}{1} \right) = e^z \quad (27.85)$$

3. Logarytmujemy obustronnie:

$$\ln\left(\frac{p}{1-p}\right) = \ln(e^z) = z \quad (27.86)$$

Podstawiając z :

$$\ln\left(\frac{\Pr(X)}{1 - \Pr(X)}\right) = \beta_0 + \beta_1 X \quad (27.87)$$

27.4. d) Zależność sigma a logit

Funkcja logistyczna $\sigma(x)$ i funkcja logit $l(p)$ są **funkcjami odwrotnymi**.

$$\sigma(x) = \frac{e^x}{1 + e^x} \quad (\text{odwzorowuje } \mathbb{R} \rightarrow (0, 1)) \quad (27.88)$$

$$l(p) = \ln\left(\frac{p}{1-p}\right) \quad (\text{odwzorowuje } (0, 1) \rightarrow \mathbb{R}) \quad (27.89)$$

Zachodzi:

$$l(\sigma(x)) = x \quad (27.90)$$

oraz

$$\sigma(l(p)) = p \quad (27.91)$$

.

Algorytmiczna Analiza Danych

Ćwiczenia 8

28 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

28. Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych

Aby uzyskać model dla K klas, wykorzystując $K - 1$ modeli binarnej regresji logistycznej, stosujemy podejście oparte na **klasie referencyjnej** (bazowej). Załóżmy, że klasa K jest naszą klasą bazową.

Budujemy $K - 1$ klasyfikatorów binarnych, gdzie k -ty model (dla $k = 1, \dots, K - 1$) uczy się przewidywać logarytm szansy (log-odds) bycia w klasie k względem klasy K :

$$\ln\left(\frac{\Pr(Y = k)}{\Pr(Y = K)}\right) = \beta_k^T x \quad (28.92)$$

Gdzie β_k to wektor wag dla klasy k . Przekształcając to równanie, otrzymujemy:

$$P(Y = k) = P(Y = K) \cdot e^{\beta_k^T x} \quad (28.93)$$

Ponieważ suma prawdopodobieństw wszystkich klas musi wynosić 1 ($\sum_{j=1}^K \Pr(Y = j) = 1$), możemy wyznaczyć $\Pr(Y = K)$:

$$\begin{aligned} \Pr(Y = K) + \sum_{k=1}^{K-1} \Pr(Y = K) \cdot e^{\beta_k^T x} &= 1 \\ \Pr(Y = K) \left(1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}\right) &= 1 \\ \Pr(Y = K) &= \frac{1}{1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}} \end{aligned} \quad (28.94)$$

Dla dowolnego $k < K$ prawdopodobieństwo wynosi zatem:

$$\Pr(Y = k) = \frac{e^{\beta_k^T x}}{1 + \sum_{j=1}^{K-1} e^{\beta_j^T x}} \quad (28.95)$$

Jest to równoważne funkcji Softmax, gdzie dla klasy referencyjnej przyjmujemy wektor wag $\beta_K = 0$ (wektor zerowy).

29. Ćwiczenie 29 – Funkcja Softmax

29.1. Wzór i intuicja

Wzór funkcji Softmax dla j -tego elementu wektora z :

$$p_j(z) = \frac{e^{z_j}}{\sum_{k=1}^n e^{z_k}} \quad (29.96)$$

29.1.1. Intuicja

Funkcja ta realizuje dwa cele:

1. **Exponentiation** (e^x) - Przekształca logity (które mogą być ujemne) na wartości dodatnie oraz wzmacnia różnice między wartościami (duże wartości stają się znacznie większe od małych).
2. **Normalizacja** - Dzielenie przez sumę sprawia, że wszystkie wartości sumują się do 1, tworząc poprawny rozkład prawdopodobieństwa.

29.1.2. Dlaczego „ciągły argmax”?

Zwykła funkcja `argmax` zwraca indeks największej wartości (np. wektor one-hot). Jest ona jednak nieciągła i nieróżniczkowalna. Softmax jest jej gładkim przybliżeniem. Jeśli wprowadzimy parametr temperatury T ($\frac{z_j}{T}$) i $T \rightarrow 0$, rozkład softmax dąży do rozkładu punktowego (1 dla maksimum, 0 dla reszty), zachowując jednak różniczkowalność, co jest kluczowe dla uczenia sieci metodą spadku gradientu.

29.2. Klasyfikacja wieloetykietowa (Multi-label)

Gdy obserwacja może należeć do kilku klas jednocześnie, Softmax nie jest odpowiedni, ponieważ wymusza sumowanie się prawdopodobieństw do 1 (konkurencja między klasami).

Rozwiązanie: Stosuje się funkcję **Sigmoid** ($\sigma(z) = \frac{1}{1+e^{-z}}$) niezależnie dla każdego wyjścia (dla każdej klasy). Traktujemy to jako n niezależnych problemów klasyfikacji binarnej („czy należy do klasy A?”, „czy należy do klasy B?” itd.). Funkcją kosztu jest wtedy suma binarnych entropii krzyżowych.

30. Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax

Mamy wektor $p(z)$ o składowych $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$.

30.1. Macierz Jacobiego

Macierz Jacobiego J ma wymiary $n \times n$, a jej element na pozycji (j, k) to pochodna cząstkowa j -tego wyjścia po k -tym wejściu:

$$J_{jk} = \frac{\partial p_j}{\partial z_k} \quad (30.97)$$

Wzór ogólny (z wykorzystaniem delty Kroneckera δ_{jk}):

$$\frac{\partial p_j}{\partial z_k} = p_j(\delta_{jk} - p_k) \quad (30.98)$$

Co w rozwinięciu daje:

- Na przekątnej ($j = k$): $p_j(1 - p_j)$
- Poza przekątną ($j \neq k$): $-p_j p_k$

30.2. Analiza znaków pochodnych

- **Gdy $j = k$:** $\frac{\partial p_j}{\partial z_k} = p_j(1 - p_j)$. Ponieważ p_j jest prawdopodobieństwem z funkcji Softmax (dla skończonych z), to $0 < p_j < 1$. Zatem iloczyn dwóch liczb dodatnich jest **dodatni**.
- **Gdy $j \neq k$:** $\frac{\partial p_j}{\partial z_k} = -p_j p_k$. Ponieważ $p_j > 0$ i $p_k > 0$, to ich iloczyn ze znakiem minus jest **ujemny**.

Konsekwencje: Zwiększenie wartości logitu z_k (sygnału dla klasy k) powoduje wzrost prawdopodobieństwa tej klasy (p_k), ale jednocześnie **obniżenie** prawdopodobieństw wszystkich pozostałych klas (p_j). Potwierdza to konkurencyjną naturę Softmaxu - klasy „walczą” o zasoby (sumę równą 1).

31. Ćwiczenie 31 – Gradient Entropii Krzyżowej

Chcemy policzyć $\frac{\partial L}{\partial z_i}$, gdzie $L = -\sum_k y_k \log(p_{k(z)})$.

Korzystając z reguły łańcuchowej (dla wielu zmiennych):

$$\frac{\partial L}{\partial z_i} = \sum_{k=1}^n \frac{\partial L}{\partial p_k} \cdot \frac{\partial p_k}{\partial z_i} \quad (31.99)$$

1. Pochodna L po p_k :

$$\frac{\partial}{\partial p_k} \left(-\sum_j y_j \log(p_j) \right) = -\frac{y_k}{p_k} \quad (31.100)$$

2. Pochodna Softmaxu (z Ćwiczenia 30):

$$\frac{\partial p_k}{\partial z_i} = p_k(\delta_{ki} - p_i) \quad (31.101)$$

Podstawiając:

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= \sum_k \left(-\frac{y_k}{p_k} \right) \cdot p_k(\delta_{ki} - p_i) \\ &= -\sum_k y_k(\delta_{ki} - p_i) \\ &= -\left(y_i(1 - p_i) + \sum_{k \neq i} y_k(-p_i) \right) \\ &= -\left(y_i - y_i p_i - \sum_{k \neq i} y_k p_i \right) \\ &= -\left(y_i - p_i \underbrace{\sum_k y_k}_{=1} \right) \\ &= p_i - y_i \end{aligned} \quad (31.102)$$

Wynik:

$$\frac{\partial L}{\partial z_i} = p_i - y_i \quad (31.103)$$

Wykorzystanie: Wzór $p_i - y_i$ reprezentuje **błąd predykcji** (różnicę między przewidywanym prawdopodobieństwem a rzeczywistą etykietą). Jest to sygnał błędu przekazywany wstecz (backpropagation) do aktualizacji wag modelu.

- Jeśli $y_i = 1$, a model dał $p_i = 0.8$, gradient wynosi -0.2 (dążymy do zwiększenia z_i).
- Jego prostota obliczeniowa sprawia, że połączenie Softmax + Cross-Entropy jest standardem w sieciach neuronowych.

32. Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)

Wykres pudełkowy służy do wizualizacji rozkładu cechy statystycznej i składa się z następujących elementów:

1. Pudełko (Box):

- Dolna krawędź pudełka wyznacza *pierwszy kwartył* ($Q1$) (25. centyl).
- Górna krawędź wyznacza *trzeci kwartył* ($Q3$) (75. centyl).
- Wysokość pudełka to *rozstęp międzykwartyłowy* ($IQR = Q3 - Q1$), w którym znajduje się 50% środkowych obserwacji.

2. Linia wewnątrz pudełka:

- Oznacza *medianę* ($Q2$), czyli wartość środkową. Jej położenie wskazuje na skośność rozkładu (np. jeśli jest bliżej dołu, rozkład może być prawoskośny).

3. Wąsy (Whiskers):

- Linie wychodzące z pudełka w górę i w dół.
- Zazwyczaj sięgają do ostatniego punktu danych mieszczącego się w przedziale $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$.

4. Punkty poza wąsami (Outliers):

- Obserwacje odstające, które wykraczają poza zasięg wąsów. Są zaznaczane jako pojedyncze kropki lub gwiazdki.

Algorytmiczna Analiza Danych

Ćwiczenia 9

5 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

33. Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa

W problemie klasyfikacji wieloklasowej (gdzie mamy K klas), zmienną celu dla i -tej obserwacji możemy zapisać jako wektor one-hot $\mathbf{y}^{(i)} = [y_1^{(i)}, \dots, y_K^{(i)}]$, gdzie $y_k^{(i)} = 1$ jeśli obserwacja należy do klasy k , a 0 w przeciwnym razie. Model przewiduje prawdopodobieństwa $\hat{y}_k^{(i)}$ (np. za pomocą funkcji Softmax).

Funkcja wiarygodności (Likelihood) dla N niezależnych obserwacji ma postać:

$$L(\theta) = \prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \quad (33.104)$$

Aby ułatwić optymalizację, stosujemy logarytm naturalny wiarygodności (Log-Likelihood):

$$\ln L(\theta) = \ln \left(\prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \right) = \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.105)$$

Maksymalizacja funkcji wiarygodności jest równoważna minimalizacji jej odwrotności ze znakiem minus (negative log-likelihood):

$$\text{NLL} = - \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (33.106)$$

Powyższy wzór to nic innego jak suma **entropii krzyżowych** pomiędzy rozkładem rzeczywistym y a przewidywanym $\hat{y}$. Zatem maksymalizacja wiarygodności w klasyfikacji wieloklasowej jest tożsama z minimalizacją entropii krzyżowej.

34. Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL

Niech P będzie prawdziwym rozkładem prawdopodobieństwa, a Q rozkładem aproksymującym (modelowanym). Zdefiniujmy miary dla zmiennych dyskretnych:

1. **Entropia Shannona ($H(P)$)** - Miara niepewności lub ilości informacji zawartej w rozkładzie P .

$$H(P) = - \sum_x P(x) \log P(x) \quad (34.107)$$

2. **Entropia krzyżowa ($H(P, Q)$)** - Średnia liczba bitów potrzebna do zakodowania zdarzeń z rozkładu P przy użyciu kodowania optymalnego dla rozkładu Q .

$$H(P, Q) = - \sum_x P(x) \log Q(x) \quad (34.108)$$

3. **Dywergencja Kullbacka-Leiblera ($D_{\text{KL}(P \parallel Q)}$)** - Miara „odległości” (straty informacji) przy zastąpieniu prawdziwego rozkładu P rozkładem Q .

$$D_{\text{KL}(P \parallel Q)} = \sum_x P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (34.109)$$

34.1. Związek między miarami

Rozpisując wzór na dywergencję KL:

$$\begin{aligned} D_{\text{KL}(P \parallel Q)} &= \sum_x P(x) (\log P(x) - \log Q(x)) \\ &= \sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned} \quad (34.110)$$

Stąd otrzymujemy kluczową zależność:

$$H(P, Q) = H(P) + D_{\text{KL}(P \parallel Q)} \quad (34.111)$$

Interpretacja: Entropia krzyżowa to entropia własna danych plus „kara” (dywergencja KL) za niedopasowanie modelu Q do rzeczywistości P .

35. Ćwiczenie 35 – Entropia różniczkowa

35.1. Definicja

Dla zmiennej losowej ciągłej X o gęstości prawdopodobieństwa $f(x)$, entropia różniczkowa wynosi:

$$h(X) = - \int_{-\infty}^{\infty} f(x) \log f(x) dx \quad (35.112)$$

35.2. Ujemna wartość entropii różniczkowej

W przeciwieństwie do przypadku dyskretnego, $h(X)$ może być ujemna, ponieważ $f(x)$ może przyjmować wartości > 1 . **Przykład:** Rozkład jednostajny na przedziale $[0, a]$, gdzie $a < 1$ (np. $a = 0.5$).

$$f(x) = \begin{cases} \frac{1}{a} & \text{dla } x \in [0, a] \\ 0 & \text{w p.p.} \end{cases} \quad (35.113)$$

$$h(X) = - \int_0^a \frac{1}{a} \log \left(\frac{1}{a} \right) dx = -\frac{1}{a} \log \left(\frac{1}{a} \right) \cdot a = -\log \left(\frac{1}{a} \right) = \log(a) \quad (35.114)$$

Dla $a = 0.5$, $h(X) = \log(0.5) < 0$.

35.3. Skalowanie zmiennej ($H(aX)$)

Niech $Y = aX$ dla $a > 0$. Gęstość prawdopodobieństwa Y to $f_{Y(y)} = \frac{1}{a}f_{X(\frac{y}{a})}$.

$$\begin{aligned} h(Y) &= - \int f_{Y(y)} \log f_{Y(y)} dy \\ &= - \int \frac{1}{a} f_{X(\frac{y}{a})} \log \left(\frac{1}{a} f_{X(\frac{y}{a})} \right) dy \end{aligned} \quad (35.115)$$

Podstawiając $x = \frac{y}{a}$ (więc $dy = a dx$):

$$\begin{aligned} &= - \int \frac{1}{a} f_{X(x)} (\log f_{X(x)} - \log a) a dx \\ &= - \int f_{X(x)} \log f_{X(x)} dx + \log a \int f_{X(x)} dx \\ &= h(X) + \log a \end{aligned} \quad (35.116)$$

35.4. Maksymalna entropia rozkładu normalnego

Wiemy, że $D_{\text{KL}}(f \parallel g) \geq 0$ (Nierówność Gibbsa). Niech $f(x)$ będzie dowolnym rozkładem o średniej μ i wariancji σ^2 , a $g(x)$ będzie rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

$$D_{\text{KL}}(f \parallel g) = \int f(x) \log \left(\frac{f(x)}{g(x)} \right) dx = -h(f) - \int f(x) \log g(x) dx \geq 0 \quad (35.117)$$

Stąd: $h(f) \leq - \int f(x) \log g(x) dx$.

Obliczmy prawą stronę dla $g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$:

$$\begin{aligned} &- \int f(x) \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2} \right] dx \\ &= \frac{1}{2} \log(2\pi\sigma^2) \int f(x) dx + \frac{1}{2\sigma^2} \int f(x)(x-\mu)^2 dx \end{aligned} \quad (35.118)$$

Ponieważ f ma wariancję σ^2 , całka $\int f(x)(x-\mu)^2 dx = \sigma^2$. Oraz $\int f(x) dx = 1$.

$$= \frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2} = \frac{1}{2} \log(2\pi e\sigma^2) \quad (35.119)$$

Wartość ta jest dokładnie entropią rozkładu normalnego $h(g)$. Zatem $h(f) \leq h(g)$, co dowodzi, że rozkład normalny ma największą entropię przy ustalonej wariancji.

36. Ćwiczenie 36 – Miary odległości między rozkładami

Oto zestawienie popularnych miar dla rozkładów P i Q (gęstości $p(x)$ i $q(x)$):

Miara	Opis i Własności
-------	------------------

Dywergencja Kullbacka-Leiblera (KL) $D_{\text{KL}(P \parallel Q)} = \int p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$	• Intuicja: Strata informacji przy aproksymacji P przez Q. • Własności: Nieujemna (≥ 0), równa 0 wtw gdy $P = Q$. • Uwaga: Nie jest metryką (nie jest symetryczna: $D_{\text{KL}(P \parallel Q)} \neq D_{\text{KL}(Q \parallel P)}$ i nie spełnia nierówności trójkąta).
Odległość Hellingera $H^2(P, Q) = \frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx$	• Intuicja: Euklidesowa odległość między pierwiastkami z gęstości. • Własności: Jest to metryka. Przyjmuje wartości w zakresie $[0, 1]$. Jest symetryczna. • Przydatna w teorii estymacji i statystyce asymptotycznej.
Total Variation Distance (TV) $\begin{aligned} TV(P, Q) &= \sup_A P(A) - Q(A) \\ &= \frac{1}{2} \int p(x) - q(x) dx \end{aligned}$	• Intuicja: Największa możliwa różnica w prawdopodobieństwie przypisanym temu samemu zdarzeniu przez dwa rozkłady. • Własności: Jest metryką (L_1 norm). Ograniczona $0 \leq TV \leq 1$. • Bardzo restrykcyjna miara zbieżności.
Odległość Wassersteina (Earth Mover's) $W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\ x - y\]$	• Intuicja: Minimalny „koszt” (masa $\times$ droga) przesunięcia masy prawdopodobieństwa z rozkładu P, by uformować Q. • Własności: Jest metryką. Działa świetnie nawet gdy rozkłady mają rozłączne nośniki (gdzie KL byłoby nieskończone). Kluczowa w GAN-ach (WGAN).