

# Algorytmiczna Analiza Danych

## Ćwiczenia 4

2025-10-24

Adrian Herda  
Politechnika Wrocławska

### 1. Zadanie 13 - Prawdopodobieństwo prawdziwej wartości w przedziale

Jako że  $e_i \sim \mathcal{N}(0, \sigma^2)$  oraz są niezależne, to zgodnie z własnościami rozkładu normalnego, estymator  $\hat{\beta}_1$  również ma rozkład normalny z wartością oczekiwaną równą  $\beta_1$  oraz wariancją  $\text{Var}(\hat{\beta}_1)$ .

#### 1.1. Reguła trzech sigm

Reguła trzech sigm mówi, że w rozkładzie normalnym ok. 99.7% masy leży w przedziale  $\mathbb{E}[X] \pm 3\sigma_X$  dla każdej zmiennej losowej  $X \sim \mathcal{N}(\mathbb{E}[X], \sigma_X)$ . Dla  $\mathbb{E}[X] \pm 2\sigma_X$  mamy ok. 95%.

To tylko krótkie heurystyczne odwołanie do „regułki 68 – 95 – 99.7” dla rozkładu normalnego ( $1\sigma \approx 68\%$ ,  $2\sigma \approx 95\%$ ,  $3\sigma \approx 99.7\%$ ).

#### 1.2. Ustandaryzowana zmienna

Niech

$$Z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim \mathcal{N}(0, 1) \quad (1)$$

Wtedy:

$$\Pr(|\hat{\beta}_1 - \beta_1| \leq 2\sqrt{\text{Var}(\hat{\beta}_1)}) = \Pr(|Z| \leq 2) \quad (2)$$

Ze wzoru na gęstość prawdopodobieństwa w standardowym rozkładzie normalnym mamy:

$$\begin{aligned} \Pr(|Z| \leq 2) &= \int_{-2}^2 \varphi(x) dx \\ &= \Phi(2) - \Phi(-2) \\ &= \Phi(2) - (1 - \Phi(2)) \\ &= 2\Phi(2) - 1 \\ &= 0.9545 \end{aligned} \quad (3)$$

## 2. Zadanie 14 - Wzór na estymatory parametrów w modelu regresji liniowej z $k + 1$ parametrami

### 2.1. Teza

Estymatory:

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} \in \mathbb{R}^{k+1} \quad (4)$$

Wzór:

$$\hat{\beta} = (X^T X)^{-1} X^T \vec{y} \quad (5)$$

gdzie  $X$  to macierz danych a  $\vec{y}$  to wektor odpowiedzi.

### 2.2. Dowód

$$y = f(x) + \varepsilon \quad (6)$$

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k \quad (7)$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (8)$$

$$\vec{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad (9)$$

$$\vec{y} = X\beta + \varepsilon$$

$\Downarrow$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \beta_0 + \beta_1 x_{11} + \dots + \beta_k x_{1k} + \varepsilon_1 \\ \beta_0 + \beta_1 x_{21} + \dots + \beta_k x_{2k} + \varepsilon_2 \\ \vdots \\ \beta_0 + \beta_1 x_{n1} + \dots + \beta_k x_{nk} + \varepsilon_n \end{pmatrix} \quad (10)$$

$$\varepsilon = \vec{y} - \hat{y} \wedge \text{RSS} = \sum_{i=1}^n \varepsilon_i^2 = \varepsilon^T \varepsilon \quad (11)$$

$\Downarrow$

$$\text{RSS} = (\vec{y} - \hat{y})^T (\vec{y} - \hat{y})$$

$$\begin{aligned} J(\hat{\beta}) &= (\vec{y} - X\hat{\beta})^T (\vec{y} - X\hat{\beta}) \\ &= (\vec{y}^T - \hat{\beta}^T X^T) (\vec{y} - X\hat{\beta}) \\ &= \vec{y}^T \vec{y} - \vec{y}^T X\hat{\beta} - \hat{\beta}^T X^T \vec{y} + X^T \hat{\beta}^T X\hat{\beta} \\ &= \vec{y}^T \vec{y} - 2\vec{y}^T X\hat{\beta} + \hat{\beta}^T X^T X\hat{\beta} \end{aligned} \quad (12)$$

Chcemy najmniejszą wartość RSS. Liczymy pochodną cząstkową po  $\hat{\beta}$  i przyrównujemy do zera:

$$\begin{aligned}\frac{\partial J}{\partial \hat{\beta}} &= 2X^T X \hat{\beta} - 2X^T \vec{y} = 0 \\ X^T X \hat{\beta} &= X^T \vec{y} \\ \hat{\beta} &= (X^T X)^{-1} X^T \vec{y}\end{aligned}\tag{13}$$