

Algorytmiczna Analiza Danych

Ćwiczenia 4

1980-01-01

Adrian Herda
Politechnika Wrocławska

1. Zadanie 15 - Korelacja

$$\begin{aligned} \text{TSS} &= \sum_{i=1}^n (Y_i - \bar{Y}_i)^2 = S_{yy} \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y}_i)^2 \\ &= \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{RSS}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}_{\text{ESS}} - 2 \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}_i)}_{\text{Własność ortogonalności reszt} \rightarrow 0} \\ &= \text{RSS} + \text{ESS} \end{aligned} \tag{1}$$

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y}_i - \hat{\beta}_1 \bar{X} \\ \hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\ &= (\bar{Y}_i - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 X_i \\ &= \bar{Y}_i + \hat{\beta}_1 (X_i - \bar{X}) \\ \hat{Y}_i - \bar{Y}_i &= \hat{\beta}_1 (X_i - \bar{X}) \end{aligned} \tag{2}$$

$$\text{ESS} = \hat{\beta}_1^2 S_{yy}$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$\begin{aligned} R^2 &= 1 - \frac{\text{RSS}}{\text{TSS}} \\ &= \frac{\text{RSS} + \text{ESS} - \text{RSS}}{\text{TSS}} \\ &= \frac{\text{ESS}}{\text{TSS}} \\ &= \left(\frac{S_{xy}}{S_{xx}} \right)^2 \frac{S_{xx}}{S_{yy}} \\ &= \frac{S_{xy}^2}{S_{xx} S_{yy}} \\ &= \text{Corr}(X, Y)^2 \end{aligned} \tag{3}$$

■

2. Zadanie 16 - t-statystyka i p-wartość

Wyjaśnij czym jest t-statystyka i w jaki sposób możemy jej użyć w kontekście regresji liniowej. Czym jest p-wartość?

2.1. t-statystyka

t-statystyka to miara używana w statystyce do oceny istotności współczynników regresji w modelu regresji liniowej. Określa, jak wiele standardowych błędów odchyła się estymowany współczynnik od wartości zerowej (hipoteza zerowa). Wzór na t-statystykę dla współczynnika regresji $\hat{\beta}_j$ jest następujący:

$$t_j = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \quad (4)$$

gdzie $\text{SE}(\hat{\beta}_j)$ to standardowy błąd estymatora współczynnika regresji $\hat{\beta}_j$.

2.2. p-wartość

p-wartość to prawdopodobieństwo uzyskania wyników co najmniej tak ekstremalnych jak obserwowane, zakładając, że hipoteza zerowa jest prawdziwa. W kontekście regresji liniowej, p-wartość jest używana do oceny istotności statystycznej współczynników regresji. Niska p-wartość (zazwyczaj poniżej 0.05) sugeruje odrzucenie hipotezy zerowej, co oznacza, że istnieje statystycznie istotny związek między zmienną niezależną a zmienną zależną.

3. Zadanie 17 - Odległość Mahalanobisa

Wyjaśnij czym jest odległość Mahalanobisa i jaki jest jej związek z leverage statistic.

3.1. odpowiedź

Odległość Mahalanobisa to miara odległości między punktem a rozkładem prawdopodobieństwa. W przeciwieństwie do standardowej odległości euklidesowej, odległość Mahalanobisa uwzględnia korelacje między zmiennymi i skalę danych. Jest definiowana jako:

$$D_{M(x)} = \sqrt{(x - \mu)^T S^{-1} (x - \mu)} \quad (5)$$

gdzie μ to wektor średnich zmiennych, a S to macierz kowariancji.

Odległość Mahalanobisa jest szczególnie użyteczna w kontekście analizy regresji, ponieważ pozwala na identyfikację obserwacji, które są nietypowe lub odstające w kontekście całego zbioru danych. Wartości odległości Mahalanobisa mogą być używane do obliczania statystyki leverage, która mierzy wpływ danej obserwacji na dopasowanie modelu regresji. Obserwacje o wysokiej odległości Mahalanobisa mogą mieć duży wpływ na estymację współczynników regresji i mogą być potencjalnymi punktami odstającymi.

4. Zadanie 18 - Double descent

Na podstawie materiału wideo i rozdziału 10.8 w książce ISL opisz zjawisko double descent

4.1. Odpowiedź

- W fazie podparametryzowanej („under-parameterized”) - model nie ma wystarczającej mocy, by dobrze dopasować dane $\rightarrow$ testowy błąd jest stosunkowo wysoki, ale spada wraz ze wzrostem złożoności.
- Następnie w okolicy punktu, kiedy liczba parametrów $\approx$ liczba próbek (lub model może dokładnie dopasować dane) - następuje wzrost błędu testowego (szczyt) z powodu dużej wariancji, niestabilności.
- Potem, w nadparametryzowanej („over-parameterized”) fazie - mimo że model może „przeuczyć” dane, okazuje się, że zwiększanie złożoności dalej prowadzi do spadku błędu testowego. Model bardzo duży generalizuje lepiej niż średni.