

Algorytmiczna Analiza Danych

Ćwiczenia 6

01.01.1980

Adrian Herda
Politechnika Wrocławska

1. Zadanie 19

Przypomnij, czym jest estymator największej wiarygodności. Przedstaw i wyjaśnij własności takiego estymatora (w szczególności asymptotyczną nieobciążoność i efektywność).

1.1. Odpowiedź

1.1.1. Definicja

Założmy, że mamy próbę losową $X_1, \dots, X_n$ pochodzącą z rozkładu o funkcji gęstości (lub masie prawdopodobieństwa) $f(x; \theta)$, gdzie θ to nieznaną parametr populacji (np. średnia, wariancja, parametr Bernoulliego itd.).

Funkcja wiarygodności (likelihood function) określa prawdopodobieństwo zaobserwowania danej próby przy danym parametrze θ :

$$L(\theta) = f(x_1; \theta) \cdot \dots \cdot f(x_n; \theta) \quad (1)$$

albo w postaci logarytmicznej (częściej stosowanej dla wygody obliczeń):

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta) \quad (2)$$

Estymator największej wiarygodności (ENW) to wartość $\hat{\theta}$, która maksymalizuje funkcję wiarygodności:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} L(\theta) \quad (3)$$

lub równoważnie:

$$\hat{\theta}_{\text{MLE}} = \max_{\theta} \ell(\theta) \quad (4)$$

1.1.2. Własności

Spójność - Gdy liczba obserwacji $n \rightarrow \infty$ to estymator największej wiarygodności zbliża się do prawdziwej wartości parametru θ

$$\hat{\theta}_{\text{MLE}} \xrightarrow{P} \theta \quad (5)$$

Efektywność - Przy pewnych warunkach estymator największej wiarygodności zbliża się, w dystrybucji, do rozkładu normalnego:

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \sim \mathcal{N}(0, \mathcal{I}^{-1}) \quad (6)$$

gdzie

$$\mathcal{J}_{jk} = \mathbb{E} \left[-\frac{\partial^2 f_{\theta_0}(X_t)}{\partial \theta_j \partial \theta_k} \right] \quad (7)$$

to macierz informacji Fishera.

2. Zadanie 20

Założmy, że mamy n obserwacji $x_1, \dots, x_n$ pochodzących z rozkładu normalnego zmiennej losowej $X \sim \mathcal{N}(\mu, \sigma^2)$. Wyprowadź estymator największej wiarygodności dla parametru μ

2.1. Rozwiązanie

$$f(x_i; \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \quad (8)$$

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(x_i; \mu) \\ \ell(\mu) &= \sum_{i=1}^n \ln f(x_i; \mu) \\ &= \sum_{i=1}^n \ln \left((2\pi\sigma^2)^{-\frac{1}{2}} \exp \left(-\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right) \\ &= \sum_{i=1}^n -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (9)$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\mu} = 0$:

$$\begin{aligned}
\frac{d\ell}{d\mu} &= \frac{d}{d\mu} \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right) \\
&= -\frac{1}{2\sigma^2} \frac{d}{d\mu} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n \frac{d}{d\mu} (x_i^2 - 2x_i\mu + \mu^2) \\
&= -\frac{1}{2\sigma^2} \sum_{i=1}^n (-2x_i + 2\mu) \\
&= -\frac{1}{\sigma^2} \sum_{i=1}^n (-x_i + \mu) \\
0 &= \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) \\
&= \sum_{i=1}^n (\mu - x_i) \\
&= n\mu - \sum_{i=1}^n x_i \\
n\mu &= \sum_{i=1}^n x_i \\
\hat{\mu}_{\text{MLE}} &= \frac{1}{n} \sum_{i=1}^n x_i
\end{aligned} \tag{10}$$

3. Zadanie 21

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu wykładniczego z nieznanym parametrem λ . Wyprowadź estymator największej wiarygodności dla parametru λ . Wskaż intuicyjnie, dlaczego ten estymator ma sens.

3.1. Rozwiązanie

$$f(x; \lambda) = \lambda e^{-\lambda x} \tag{11}$$

$$\begin{aligned}
L(\lambda) &= \prod_{i=1}^n f(x_i; \lambda) \\
&= \lambda^n \exp(-\lambda n x_i) \\
&= \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right) \\
\ell(\lambda) &= n \ln \lambda - \lambda \sum_{i=1}^n x_i
\end{aligned} \tag{12}$$

Szukamy wartości maksymalnej ℓ więc liczymy chcemy policzyć $\frac{d\ell}{d\lambda} = 0$:

$$\begin{aligned}
 \frac{d\ell}{d\lambda} &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
 0 &= \frac{n}{\lambda} - \sum_{i=1}^n x_i \\
 \frac{n}{\lambda} &= \sum_{i=1}^n x_i \\
 \hat{\lambda}_{\text{MLE}} &= \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}
 \end{aligned}
 \tag{13}$$

4. Zadanie 22

Rozważmy n niezależnych obserwacji $x_1, \dots, x_n$, które pochodzą z rozkładu jednostajnego na przedziale $[0, \theta]$, gdzie θ jest nieznanym parametrem. Wyprowadź estymator największej wiarygodności dla parametru θ . Wskaż intuicyjnie, dlaczego ten estymator ma sens. Czy ten estymator jest nieobciążony?

4.1. Rozwiązanie

$$f(x; \theta) = \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x) \tag{14}$$

$$\begin{aligned}
 L(\theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) \\
 &= \theta^{-n} \mathbf{1}_{\{\forall_i, x_i \leq \theta\}} \\
 &= \theta^{-n} \mathbf{1}_{\{\max_i x_i \leq \theta\}} \\
 &= \begin{cases} 0, & \max_i x_i > \theta \\ \theta^{-n}, & \max_i x_i \leq \theta, \text{ funkcja malejąca} \end{cases}
 \end{aligned}
 \tag{15}$$

Chcąc osiągnąć największe możliwe $L(\theta)$ musimy zminimalizować θ tak aby nadal $\forall_i x_i \leq \theta \Rightarrow \max_i x_i \leq \theta$. Więc największa wartość $L(\theta)$ jest osiągana dla:

$$\hat{\theta}_{\text{MLE}} = \max_i x_i = x_{(n)} \tag{16}$$

4.2. Czy estymator nieobciążony?

Nie, estymator jest obciążony.

Proof. Rozkład $x_{(n)}$ (maksimum) dla $x \in [0, \theta]$:

$$F_{x_{(n)}}(x) = P(x_{(n)} < x) = \left(\frac{x}{\theta}\right)^n \tag{17}$$

$$\begin{aligned}
\mathbb{E}[\hat{\theta}_{\text{MLE}}] &= \mathbb{E}[x_{(n)}] = \int_0^\theta x dF_{x_{(n)}}(x) \\
&= \int_0^\theta x \cdot n \frac{x^{n-1}}{\theta^n} dx \\
&= \frac{n}{\theta^n} \int_0^\theta x^n dx \\
&= \frac{n}{\theta^n} \left(\frac{x^{n+1}}{n+1} \right) \Big|_0^\theta \\
&= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \\
&= \frac{n}{n+1} \theta \neq \theta
\end{aligned} \tag{18}$$

$$\begin{aligned}
\text{Bias}(\hat{\theta}_{\text{MLE}}) &= \mathbb{E}[\hat{\theta}_{\text{MLE}}] - \theta \\
&= \frac{n}{n+1} \theta - \theta \\
&= -\frac{1}{n+1} \theta
\end{aligned} \tag{19}$$

■

5. Zadanie 23

5.1. a) $p = 1$

Ułamek próby który użyjemy $\frac{0.10}{1} = 0.1$

5.2. b) $p = 2$

Teraz chcemy wykorzystać kwadrat o długości $X_1 = 0.1$ oraz szerokości $X_2 = 0.1$

Ułamek próby który użyjemy: $\frac{0.1 \cdot 0.1}{1} = 0.01$

5.3. c) $p = 100$

Teraz chcemy wykorzystać hiperkostkę o długości boku 0.1

Ułamek próby który użyjemy: $\frac{0.1^{100}}{1} = 10^{-100} \approx 0$

5.4. d)

Im większe p tym mniej punktów leży w odległości 0.1 od testowego, więc metody oparte na lokalności się trochę psują, mając mało danych do porządnego przewidywania. Rośnie wariancja a żeby ją kontrolować musimy zwiększać K lub zwiększać okno szukania co psuje założenie lokalności.

5.5. e)**5.5.1. Wzór**

Niech w to długość krawędzi hiperkostki wewnętrznej, zawierającej $\approx 10\%$ obserwacji treningowych

$$\begin{aligned} 0.1 &= w^p \\ w &= \sqrt[p]{0.1} \end{aligned} \tag{20}$$

5.5.2. Wyniki

p	w
1	0.1
2	$\sqrt{0.1} \approx 0.31$
100	$\sqrt[100]{0.1} \approx 0.977$

Prawie cała objętość hiperkostki leży w jej brzegach. Nie da się być lokalnym i mieć wystarczająco dużo sąsiadów $\rightarrow$ Klątwa wielowymiarowości