

Algorytmiczna Analiza Danych

Ćwiczenia 7

21 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Zadanie 24 – Ocena modelu w problemie klasyfikacji

1.1. Oznaczenia

Stosujemy następujące oznaczenia w macierzy pomyłek:

- **TP (True Positive)** - Prawdziwie pozytywne.
- **TN (True Negative)** - Prawdziwie negatywne.
- **FP (False Positive)** - Fałszywie pozytywne (błąd I rodzaju).
- **FN (False Negative)** - Fałszywie negatywne (błąd II rodzaju).

1.2. a) Metryki: Accuracy, Precision, Recall oraz F1

1.2.1. Definicje metryk

1. **Accuracy (Dokładność)** - Określa, jak często model ma rację.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.1)$$

2. **Precision (Precyzja)** - Określa wiarygodność pozytywnej predykcji (ile z przewidzianych „jedynek” to faktycznie „jedynek”).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1.2)$$

3. **Recall (Czułość)** - Określa zdolność modelu do wykrywania klasy pozytywnej (ile faktycznych „jedynek” udało się znaleźć).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.3)$$

4. **F1-Score** - Średnia harmoniczna precyzji i czułości. Jest lepszą miarą niż Accuracy przy niebalansowanych danych.

$$F1 = 2 \cdot \left(\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \right) \quad (1.4)$$

1.2.2. Przykład

Testujemy wykrywacz choroby (10 chorych, 90 zdrowych). Model wykrył 8 chorych, ale też błędnie wskazał 10 zdrowych jako chorych.

- $\text{Accuracy} = \frac{8+80}{100} = 0.88$
- $\text{Precision} = \frac{8}{8+10} \approx 0.44$

- $\text{Recall} = \frac{8}{8+2} = 0.80$

1.3. b) Różnica wersji *micro* od *macro*

- **Macro Average** - Liczymy metrykę (np. F1) dla każdej klasy osobno, a potem wyciągamy z nich średnią. Traktuje każdą klasę równoważnie (dobre do wykrywania błędów w rzadkich klasach).
- **Micro Average** - Sumujemy wszystkie TP, FP, FN globalnie i liczymy metrykę raz. W klasyfikacji wieloklasowej (single-label) Micro-F1 jest równoważne Accuracy. Faworyzuje klasy większościowe.

Przykład: Klasa A (100 próbek, model idealny), Klasa B (10 próbek, model tragiczny).

- **Micro** będzie wysokie (zdominowane przez A).
- **Macro** będzie niskie (uwidoczni błąd na B).

1.4. c) Potoczne rozumienie a definicja

- **Accuracy** - Potocznie „jakość”. W *ML* może być mylące - model przewidujący zawsze brak rzadkiego zdarzenia (np. wygrana w lotto) ma 99.9% accuracy, a jest bezużyteczny.
- **Precision** - Potocznie kojarzy się z „dokładnością pomiaru”. W *ML* to „brak fałszywych alarmów”.

2. Zadanie 25 – Naiwny Klasyfikator Bayesa

2.1. Definicja

Naiwny klasyfikator Bayesa - model probabilistyczny oparty na twierdzeniu Bayesa, który zakłada **warunkową niezależność** cech (x_i) od siebie przy znanej klasie (C_k).

Warto go stosować, gdy mamy mało danych (szybka zbieżność), bardzo wysoki wymiar danych (np. tekst) lub potrzebujemy szybkiego modelu bazowego.

2.2. Dowód wzoru

Theorem 2.1.

$$\Pr(C_k \mid x_1, \dots, x_n) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (2.5)$$

Proof. Wychodzimy z twierdzenia Bayesa:

$$\Pr(C_k \mid x) = \frac{\Pr(x \mid C_k) \Pr(C_k)}{\Pr(x)} \quad (2.6)$$

Gdzie $x = (x_1, \dots, x_n)$. W liczniku mamy prawdopodobieństwo łączne $\Pr(x_1, \dots, x_n \mid C_k)$. Stosujemy „naiwne” założenie o niezależności cech:

$$\Pr(x_1, \dots, x_n \mid C_k) \approx \prod_{i=1}^n \Pr(x_i \mid C_k) \quad (2.7)$$

Podstawiając do licznika:

$$\Pr(C_k | x) = \frac{\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k)}{\Pr(x)} \quad (2.8)$$

$$\Pr(C_k | x) = \frac{1}{\Pr(x)} \Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \quad (2.9)$$

Mianownik $\Pr(x)$ jest sumą po wszystkich klasach (z prawa całkowitego prawdopodobieństwa):

$$\Pr(x) = \sum_k \Pr(x | C_k) \Pr(C_k) = \sum_k \left(\Pr(C_k) \prod_{i=1}^n \Pr(x_i | C_k) \right) \quad (2.10)$$

■

3. Zadanie 26 – Klasyfikacja Spam vs Nie-spam

Dane:

- $N = 1000$ e-maili.
- Klasa C_1 (Spam): 100 e-maili (wszystkie $x_1 = 1, x_2 = 1$).
- Klasa C_2 (Nie-spam): 900 e-maili (450: $x_1 = 1, x_2 = 0$ oraz 450: $x_1 = 0, x_2 = 1$).

Szukamy predykcji dla nowego e-maila $x = (x_1 = 1, x_2 = 1)$.

1. Prawdopodobieństwa a priori (Priors):

$$\Pr(C_1) = \frac{100}{1000} = 0.1 \quad (3.11)$$

$$\Pr(C_2) = \frac{900}{1000} = 0.9 \quad (3.12)$$

2. Prawdopodobieństwa warunkowe (Likelihoods):

- Dla C_1 (Spam):
 - $\Pr(x_1 = 1 | C_1) = \frac{100}{100} = 1$
 - $\Pr(x_2 = 1 | C_1) = \frac{100}{100} = 1$
- Dla C_2 (Nie-spam):
 - $\Pr(x_1 = 1 | C_2) = \frac{450}{900} = 0.5$
 - $\Pr(x_2 = 1 | C_2) = \frac{450}{900} = 0.5$

3. Obliczenia dla nowego e-maila (licznik wzoru Bayesa):

- Dla Spam:

$$L(C_1) = \Pr(C_1) \cdot \Pr(x_1 = 1 | C_1) \cdot \Pr(x_2 = 1 | C_1) = 0.1 \cdot 1 \cdot 1 = 0.1 \quad (3.13)$$

- Dla Nie-spam:

$$L(C_2) = \Pr(C_2) \cdot \Pr(x_1 = 1 | C_2) \cdot \Pr(x_2 = 1 | C_2) = 0.9 \cdot 0.5 \cdot 0.5 = 0.225 \quad (3.14)$$

4. Normalizacja i wynik:

$$\text{Evidence } \Pr(x) = 1 \cdot 1 \cdot 0.1 + 0.5 \cdot 0.5 \cdot 0.9 = 0.1 + 0.225 = 0.325.$$

$$\Pr(C_1 | x) = \frac{0.1}{0.325} \approx 0.308 \quad (3.15)$$

$$\Pr(C_2 | x) = \frac{0.225}{0.325} \approx 0.692 \quad (3.16)$$

Odp: Prawdopodobieństwo, że to Spam wynosi ok. 30.8%, a że Nie-spam ok. 69.2%.

4. Zadanie 27 – Regresja Logistyczna

4.1. a) Dlaczego nie regresja liniowa?

- Predykcje mogą wykraczać poza przedział $[0, 1]$.
- Zależność rzadko jest liniowa (często przyjmuje kształt litery S).
- Niespełnione założenie o stałej wariancji reszt (heteroskedastyczność).

4.2. b) Obliczenie szans (Odds)

Dane: $p = 0.75$.

$$\text{Odds} = \frac{p}{1-p} = \frac{0.75}{1-0.75} = \frac{0.75}{0.25} = 3 \quad (4.17)$$

Szanse wynoszą 3 do 1.

4.3. c) Dowód równoważności z Log-Odds

Model:

$$\Pr(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (4.18)$$

Oznaczmy $z = \beta_0 + \beta_1 X$. Wtedy $p = \frac{e^z}{1+e^z}$.

1. Obliczamy $1 - p$:

$$1 - p = 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z - e^z}{1 + e^z} = \frac{1}{1 + e^z} \quad (4.19)$$

2. Dzielimy p przez $1 - p$:

$$\frac{p}{1-p} = \frac{\frac{e^z}{1+e^z}}{\frac{1}{1+e^z}} = \left(\frac{e^z}{1+e^z} \right) \cdot \left(\frac{1+e^z}{1} \right) = e^z \quad (4.20)$$

3. Logarytmujemy obustronnie:

$$\ln\left(\frac{p}{1-p}\right) = \ln(e^z) = z \quad (4.21)$$

Podstawiając z :

$$\ln\left(\frac{\Pr(X)}{1 - \Pr(X)}\right) = \beta_0 + \beta_1 X \quad (4.22)$$

4.4. d) Zależność sigma a logit

Funkcja logistyczna $\sigma(x)$ i funkcja logit $l(p)$ są **funkcjami odwrotnymi**.

$$\sigma(x) = \frac{e^x}{1 + e^x} \quad (\text{odwzorowuje } \mathbb{R} \rightarrow (0, 1)) \quad (4.23)$$

$$l(p) = \ln\left(\frac{p}{1-p}\right) \quad (\text{odwzorowuje } (0, 1) \rightarrow \mathbb{R}) \quad (4.24)$$

Zachodzi:

$$l(\sigma(x)) = x \quad (4.25)$$

oraz

$$\sigma(l(p)) = p \quad (4.26)$$

.