

Algorytmiczna Analiza Danych

Ćwiczenia 8

28 listopada 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Ćwiczenie 28 – Wielomianowa regresja logistyczna z modeli binarnych

Aby uzyskać model dla K klas, wykorzystując $K - 1$ modeli binarnej regresji logistycznej, stosujemy podejście oparte na **klasie referencyjnej** (bazowej). Załóżmy, że klasa K jest naszą klasą bazową.

Budujemy $K - 1$ klasyfikatorów binarnych, gdzie k -ty model (dla $k = 1, \dots, K - 1$) uczy się przewidywać logarytm szansy (log-odds) bycia w klasie k względem klasy K :

$$\ln\left(\frac{\Pr(Y = k)}{\Pr(Y = K)}\right) = \beta_k^T x \quad (1.1)$$

Gdzie β_k to wektor wag dla klasy k . Przekształcając to równanie, otrzymujemy:

$$P(Y = k) = P(Y = K) \cdot e^{\beta_k^T x} \quad (1.2)$$

Ponieważ suma prawdopodobieństw wszystkich klas musi wynosić 1 ($\sum_{j=1}^K \Pr(Y = j) = 1$), możemy wyznaczyć $\Pr(Y = K)$:

$$\begin{aligned} \Pr(Y = K) + \sum_{k=1}^{K-1} \Pr(Y = K) \cdot e^{\beta_k^T x} &= 1 \\ \Pr(Y = K) \left(1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}\right) &= 1 \\ \Pr(Y = K) &= \frac{1}{1 + \sum_{k=1}^{K-1} e^{\beta_k^T x}} \end{aligned} \quad (1.3)$$

Dla dowolnego $k < K$ prawdopodobieństwo wynosi zatem:

$$\Pr(Y = k) = \frac{e^{\beta_k^T x}}{1 + \sum_{j=1}^{K-1} e^{\beta_j^T x}} \quad (1.4)$$

Jest to równoważne funkcji Softmax, gdzie dla klasy referencyjnej przyjmujemy wektor wag $\beta_K = 0$ (wektor zerowy).

2. Ćwiczenie 29 – Funkcja Softmax

2.1. Wzór i intuicja

Wzór funkcji Softmax dla j -tego elementu wektora z :

$$p_j(z) = \frac{e^{z_j}}{\sum_{k=1}^n e^{z_k}} \quad (2.5)$$

2.1.1. Intuicja

Funkcja ta realizuje dwa cele:

1. **Exponentiation** (e^x) - Przekształca logity (które mogą być ujemne) na wartości dodatnie oraz wzmacnia różnice między wartościami (duże wartości stają się znacznie większe od małych).
2. **Normalizacja** - Dzielenie przez sumę sprawia, że wszystkie wartości sumują się do 1, tworząc poprawny rozkład prawdopodobieństwa.

2.1.2. Dlaczego „ciągły argmax”?

Zwykła funkcja `argmax` zwraca indeks największej wartości (np. wektor one-hot). Jest ona jednak nieciągła i nieróżniczkowalna. Softmax jest jej gładkim przybliżeniem. Jeśli wprowadzimy parametr temperatury T ($\frac{z_j}{T}$) i $T \rightarrow 0$, rozkład softmax dąży do rozkładu punktowego (1 dla maksimum, 0 dla reszty), zachowując jednak różniczkowalność, co jest kluczowe dla uczenia sieci metodą spadku gradientu.

2.2. Klasyfikacja wieloetykietowa (Multi-label)

Gdy obserwacja może należeć do kilku klas jednocześnie, Softmax nie jest odpowiedni, ponieważ wymusza sumowanie się prawdopodobieństw do 1 (konkurencja między klasami).

Rozwiązanie: Stosuje się funkcję **Sigmoid** ($\sigma(z) = \frac{1}{1+e^{-z}}$) niezależnie dla każdego wyjścia (dla każdej klasy). Traktujemy to jako n niezależnych problemów klasyfikacji binarnej („czy należy do klasy A?”, „czy należy do klasy B?” itd.). Funkcją kosztu jest wtedy suma binarnych entropii krzyżowych.

3. Ćwiczenie 30 – Macierz Jacobiego funkcji Softmax

Mamy wektor $p(z)$ o składowych $p_j = \frac{e^{z_j}}{\sum_k e^{z_k}}$.

3.1. Macierz Jacobiego

Macierz Jacobiego J ma wymiary $n \times n$, a jej element na pozycji (j, k) to pochodna cząstkowa j -tego wyjścia po k -tym wejściu:

$$J_{jk} = \frac{\partial p_j}{\partial z_k} \quad (3.6)$$

Wzór ogólny (z wykorzystaniem delty Kroneckera δ_{jk}):

$$\frac{\partial p_j}{\partial z_k} = p_j(\delta_{jk} - p_k) \quad (3.7)$$

Co w rozwinięciu daje:

- Na przekątnej ($j = k$): $p_j(1 - p_j)$
- Poza przekątną ($j \neq k$): $-p_j p_k$

3.2. Analiza znaków pochodnych

- **Gdy $j = k$:** $\frac{\partial p_j}{\partial z_k} = p_j(1 - p_j)$. Ponieważ p_j jest prawdopodobieństwem z funkcji Softmax (dla skończonych z), to $0 < p_j < 1$. Zatem iloczyn dwóch liczb dodatnich jest **dodatni**.
- **Gdy $j \neq k$:** $\frac{\partial p_j}{\partial z_k} = -p_j p_k$. Ponieważ $p_j > 0$ i $p_k > 0$, to ich iloczyn ze znakiem minus jest **ujemny**.

Konsekwencje: Zwiększenie wartości logitu z_k (sygnału dla klasy k) powoduje wzrost prawdopodobieństwa tej klasy (p_k), ale jednocześnie **obniżenie** prawdopodobieństw wszystkich pozostałych klas (p_j). Potwierdza to konkurencyjną naturę Softmaxu - klasy „walczą” o zasoby (sumę równą 1).

4. Ćwiczenie 31 – Gradient Entropii Krzyżowej

Chcemy policzyć $\frac{\partial L}{\partial z_i}$, gdzie $L = -\sum_k y_k \log(p_{k(z)})$.

Korzystając z reguły łańcuchowej (dla wielu zmiennych):

$$\frac{\partial L}{\partial z_i} = \sum_{k=1}^n \frac{\partial L}{\partial p_k} \cdot \frac{\partial p_k}{\partial z_i} \quad (4.8)$$

1. Pochodna L po p_k :

$$\frac{\partial}{\partial p_k} \left(-\sum_j y_j \log(p_j) \right) = -\frac{y_k}{p_k} \quad (4.9)$$

2. Pochodna Softmaxu (z Ćwiczenia 30):

$$\frac{\partial p_k}{\partial z_i} = p_k(\delta_{ki} - p_i) \quad (4.10)$$

Podstawiając:

$$\begin{aligned} \frac{\partial L}{\partial z_i} &= \sum_k \left(-\frac{y_k}{p_k} \right) \cdot p_k(\delta_{ki} - p_i) \\ &= -\sum_k y_k(\delta_{ki} - p_i) \\ &= -\left(y_i(1 - p_i) + \sum_{k \neq i} y_k(-p_i) \right) \\ &= -\left(y_i - y_i p_i - \sum_{k \neq i} y_k p_i \right) \\ &= -\left(y_i - p_i \underbrace{\sum_k y_k}_{=1} \right) \\ &= p_i - y_i \end{aligned} \quad (4.11)$$

Wynik:

$$\frac{\partial L}{\partial z_i} = p_i - y_i \quad (4.12)$$

Wykorzystanie: Wzór $p_i - y_i$ reprezentuje **błąd predykcji** (różnicę między przewidywanym prawdopodobieństwem a rzeczywistą etykietą). Jest to sygnał błędu przekazywany wstecz (backpropagation) do aktualizacji wag modelu.

- Jeśli $y_i = 1$, a model dał $p_i = 0.8$, gradient wynosi -0.2 (dążymy do zwiększenia z_i).
- Jego prostota obliczeniowa sprawia, że połączenie Softmax + Cross-Entropy jest standardem w sieciach neuronowych.

5. Ćwiczenie 33 – Wykres Pudełkowy (Boxplot)

Wykres pudełkowy służy do wizualizacji rozkładu cechy statystycznej i składa się z następujących elementów:

1. Pudełko (Box):

- Dolna krawędź pudełka wyznacza *pierwszy kwartył* ($Q1$) (25. centyl).
- Górna krawędź wyznacza *trzeci kwartył* ($Q3$) (75. centyl).
- Wysokość pudełka to *rozstęp międzykwartyłowy* ($IQR = Q3 - Q1$), w którym znajduje się 50% środkowych obserwacji.

2. Linia wewnątrz pudełka:

- Oznacza *medianę* ($Q2$), czyli wartość środkową. Jej położenie wskazuje na skośność rozkładu (np. jeśli jest bliżej dołu, rozkład może być prawoskośny).

3. Wąsy (Whiskers):

- Linie wychodzące z pudełka w górę i w dół.
- Zazwyczaj sięgają do ostatniego punktu danych mieszczącego się w przedziale $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$.

4. Punkty poza wąsami (Outliers):

- Obserwacje odstające, które wykraczają poza zasięg wąsów. Są zaznaczane jako pojedyncze kropki lub gwiazdki.