

Algorytmiczna Analiza Danych

Ćwiczenia 9

5 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Ćwiczenie 32 – Klasyfikacja wieloklasowa a entropia krzyżowa

W problemie klasyfikacji wieloklasowej (gdzie mamy K klas), zmienną celu dla i -tej obserwacji możemy zapisać jako wektor one-hot $\mathbf{y}^{(i)} = [y_1^{(i)}, \dots, y_K^{(i)}]$, gdzie $y_k^{(i)} = 1$ jeśli obserwacja należy do klasy k , a 0 w przeciwnym razie. Model przewiduje prawdopodobieństwa $\hat{y}_k^{(i)}$ (np. za pomocą funkcji Softmax).

Funkcja wiarygodności (Likelihood) dla N niezależnych obserwacji ma postać:

$$L(\theta) = \prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \quad (1.1)$$

Aby ułatwić optymalizację, stosujemy logarytm naturalny wiarygodności (Log-Likelihood):

$$\ln L(\theta) = \ln \left(\prod_{i=1}^N \prod_{k=1}^K \left(\hat{y}_k^{(i)} \right)^{y_k^{(i)}} \right) = \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (1.2)$$

Maksymalizacja funkcji wiarygodności jest równoważna minimalizacji jej odwrotności ze znakiem minus (negative log-likelihood):

$$\text{NLL} = - \sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln \left(\hat{y}_k^{(i)} \right) \quad (1.3)$$

Powyższy wzór to nic innego jak suma **entropii krzyżowych** pomiędzy rozkładem rzeczywistym y a przewidywanym $\hat{y}$. Zatem maksymalizacja wiarygodności w klasyfikacji wieloklasowej jest tożsama z minimalizacją entropii krzyżowej.

2. Ćwiczenie 34 – Entropia, Entropia Krzyżowa i Dywergencja KL

Niech P będzie prawdziwym rozkładem prawdopodobieństwa, a Q rozkładem aproksymującym (modelowanym). Zdefiniujmy miary dla zmiennych dyskretnych:

1. **Entropia Shannona ($H(P)$)** - Miara niepewności lub ilości informacji zawartej w rozkładzie P .

$$H(P) = - \sum_x P(x) \log P(x) \quad (2.4)$$

2. **Entropia krzyżowa ($H(P, Q)$)** - Średnia liczba bitów potrzebna do zakodowania zdarzeń z rozkładu P przy użyciu kodowania optymalnego dla rozkładu Q .

$$H(P, Q) = - \sum_x P(x) \log Q(x) \quad (2.5)$$

3. **Dywergencja Kullbacka-Leiblera ($D_{\text{KL}(P \parallel Q)}$)** - Miara „odległości” (straty informacji) przy zastąpieniu prawdziwego rozkładu P rozkładem Q .

$$D_{\text{KL}(P \parallel Q)} = \sum_x P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (2.6)$$

2.1. Związek między miarami

Rozpisując wzór na dywergencję KL:

$$\begin{aligned} D_{\text{KL}(P \parallel Q)} &= \sum_x P(x) (\log P(x) - \log Q(x)) \\ &= \sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned} \quad (2.7)$$

Stąd otrzymujemy kluczową zależność:

$$H(P, Q) = H(P) + D_{\text{KL}(P \parallel Q)} \quad (2.8)$$

Interpretacja: Entropia krzyżowa to entropia własna danych plus „kara” (dywergencja KL) za niedopasowanie modelu Q do rzeczywistości P .

3. Ćwiczenie 35 – Entropia różniczkowa

3.1. Definicja

Dla zmiennej losowej ciągłej X o gęstości prawdopodobieństwa $f(x)$, entropia różniczkowa wynosi:

$$h(X) = - \int_{-\infty}^{\infty} f(x) \log f(x) dx \quad (3.9)$$

3.2. Ujemna wartość entropii różniczkowej

W przeciwieństwie do przypadku dyskretnego, $h(X)$ może być ujemna, ponieważ $f(x)$ może przyjmować wartości > 1 . **Przykład:** Rozkład jednostajny na przedziale $[0, a]$, gdzie $a < 1$ (np. $a = 0.5$).

$$f(x) = \begin{cases} \frac{1}{a} & \text{dla } x \in [0, a] \\ 0 & \text{w p.p.} \end{cases} \quad (3.10)$$

$$h(X) = - \int_0^a \frac{1}{a} \log \left(\frac{1}{a} \right) dx = -\frac{1}{a} \log \left(\frac{1}{a} \right) \cdot a = -\log \left(\frac{1}{a} \right) = \log(a) \quad (3.11)$$

Dla $a = 0.5$, $h(X) = \log(0.5) < 0$.

3.3. Skalowanie zmiennej ($H(aX)$)

Niech $Y = aX$ dla $a > 0$. Gęstość prawdopodobieństwa Y to $f_{Y(y)} = \frac{1}{a}f_{X(\frac{y}{a})}$.

$$\begin{aligned} h(Y) &= - \int f_{Y(y)} \log f_{Y(y)} dy \\ &= - \int \frac{1}{a} f_{X(\frac{y}{a})} \log \left(\frac{1}{a} f_{X(\frac{y}{a})} \right) dy \end{aligned} \quad (3.12)$$

Podstawiając $x = \frac{y}{a}$ (więc $dy = a dx$):

$$\begin{aligned} &= - \int \frac{1}{a} f_{X(x)} (\log f_{X(x)} - \log a) a dx \\ &= - \int f_{X(x)} \log f_{X(x)} dx + \log a \int f_{X(x)} dx \\ &= h(X) + \log a \end{aligned} \quad (3.13)$$

3.4. Maksymalna entropia rozkładu normalnego

Wiemy, że $D_{\text{KL}}(f \parallel g) \geq 0$ (Nierówność Gibbsa). Niech $f(x)$ będzie dowolnym rozkładem o średniej μ i wariancji σ^2 , a $g(x)$ będzie rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

$$D_{\text{KL}}(f \parallel g) = \int f(x) \log \left(\frac{f(x)}{g(x)} \right) dx = -h(f) - \int f(x) \log g(x) dx \geq 0 \quad (3.14)$$

Stąd: $h(f) \leq - \int f(x) \log g(x) dx$.

Obliczmy prawą stronę dla $g(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$:

$$\begin{aligned} &- \int f(x) \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2} \right] dx \\ &= \frac{1}{2} \log(2\pi\sigma^2) \int f(x) dx + \frac{1}{2\sigma^2} \int f(x)(x-\mu)^2 dx \end{aligned} \quad (3.15)$$

Ponieważ f ma wariancję σ^2 , całka $\int f(x)(x-\mu)^2 dx = \sigma^2$. Oraz $\int f(x) dx = 1$.

$$= \frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2} = \frac{1}{2} \log(2\pi e\sigma^2) \quad (3.16)$$

Wartość ta jest dokładnie entropią rozkładu normalnego $h(g)$. Zatem $h(f) \leq h(g)$, co dowodzi, że rozkład normalny ma największą entropię przy ustalonej wariancji.

4. Ćwiczenie 36 – Miary odległości między rozkładami

Oto zestawienie popularnych miar dla rozkładów P i Q (gęstości $p(x)$ i $q(x)$):

Miara	Opis i Własności
-------	------------------

Dywergencja Kullbacka-Leiblera (KL) $D_{\text{KL}(P \parallel Q)} = \int p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$	• Intuicja: Strata informacji przy aproksymacji P przez Q. • Własności: Nieujemna (≥ 0), równa 0 wtw gdy $P = Q$. • Uwaga: Nie jest metryką (nie jest symetryczna: $D_{\text{KL}(P \parallel Q)} \neq D_{\text{KL}(Q \parallel P)}$ i nie spełnia nierówności trójkąta).
Odległość Hellingera $H^2(P, Q) = \frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 dx$	• Intuicja: Euklidesowa odległość między pierwiastkami z gęstości. • Własności: Jest to metryka. Przyjmuje wartości w zakresie $[0, 1]$. Jest symetryczna. • Przydatna w teorii estymacji i statystyce asymptotycznej.
Total Variation Distance (TV) $TV(P, Q) = \sup_A P(A) - Q(A) $ $= \frac{1}{2} \int p(x) - q(x) dx$	• Intuicja: Największa możliwa różnica w prawdopodobieństwie przypisanym temu samemu zdarzeniu przez dwa rozkłady. • Własności: Jest metryką (L_1 norm). Ograniczona $0 \leq TV \leq 1$. • Bardzo restrykcyjna miara zbieżności.
Odległość Wassersteina (Earth Mover's) $W(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\ x - y\]$	• Intuicja: Minimalny „koszt” (masa $\times$ droga) przesunięcia masy prawdopodobieństwa z rozkładu P, by uformować Q. • Własności: Jest metryką. Działa świetnie nawet gdy rozkłady mają rozłączne nośniki (gdzie KL byłoby nieskończone). Kluczowa w GAN-ach (WGAN).