

Algorytmiczna Analiza Danych

Ćwiczenia 10

12 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Ćwiczenie 37– Własności próby bootstrapowej

Niech X oznacza liczbę unikalnych obserwacji w próbie bootstrapowej rozmiaru n .

1.1. Wartość oczekiwana X

Zdefiniujmy zmienną indykatorową I_j dla j -tej obserwacji z oryginalnej próby (gdzie $j = 1, \dots, n$):

$$I_j = \begin{cases} 1 & \text{jeśli obserwacja } j \text{ znalazła się w próbie bootstrapowej} \\ 0 & \text{w przeciwnym wypadku} \end{cases} \quad (1.1)$$

Liczba unikalnych obserwacji to suma indykatorów: $X = \sum_{j=1}^n I_j$.

Prawdopodobieństwo, że konkretna obserwacja j **nie** zostanie wylosowana w pojedynczym losowaniu wynosi $(1 - \frac{1}{n})$. Ponieważ próba bootstrapowa polega na n -krotnym losowaniu ze zwracaniem, prawdopodobieństwo, że obserwacja j nie znajdzie się w całej próbie wynosi:

$$P(I_j = 0) = \left(1 - \frac{1}{n}\right)^n \quad (1.2)$$

Zatem prawdopodobieństwo, że obserwacja j znajdzie się w próbie (jest unikalna) to:

$$\mathbb{E}[I_j] = P(I_j = 1) = 1 - \left(1 - \frac{1}{n}\right)^n \quad (1.3)$$

Korzystając z liniowości wartości oczekiwanej:

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{j=1}^n I_j\right] = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \quad (1.4)$$

Dla dużych n , korzystając z granicy $\lim_{n \rightarrow \infty} \left(1 - \frac{a}{n}\right)^n = e^{-a}$:

$$\mathbb{E}[X] \approx n(1 - e^{-1}) \approx 0.632n \quad (1.5)$$

1.2. Wariancja X

Wariancję sumy zmiennych zależnych wyrażamy wzorem:

$$\text{Var}(X) = \sum_{j=1}^n \text{Var}(I_j) + \sum_{j \neq k} \text{Cov}(I_j, I_k) \quad (1.6)$$

Wariancja pojedynczego indykatora:

$$\begin{aligned}
\text{Var}(I_j) &= \mathbb{E}[I_j^2] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] - \mathbb{E}[I_j]^2 \\
&= \mathbb{E}[I_j] (1 - \mathbb{E}[I_j]) \\
&= \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \left(1 - \frac{1}{n}\right)^n
\end{aligned} \tag{1.7}$$

Kowariancja:

$$\text{Cov}(I_j, I_k) = E[I_j I_k] - E[I_j] E[I_k] \tag{1.8}$$

$$\begin{aligned}
E[I_j I_k] &= 1 \cdot P(j \in S \wedge k \in S) + 0 \cdot P(j \in S \wedge k \notin S) \\
&= P(j \in S \wedge k \in S)
\end{aligned} \tag{1.9}$$

to prawdopodobieństwo, że **zarówno** j jak i k są w próbie. Łatwiej policzyć to przez dopełnienie:

$$P(j \in S \wedge k \in S) = 1 - P(j \notin S \vee k \notin S) \tag{1.10}$$

$$= 1 - [P(j \notin S) + P(k \notin S) - P(j \notin S \wedge k \notin S)] \tag{1.11}$$

Gdzie $P(j \notin S \wedge k \notin S) = \left(1 - \frac{2}{n}\right)^n$.

Po podstawieniu i uproszczeniu dla dużych n , otrzymujemy przybliżenie:

$$\text{Var}(X) \approx n[e^{-1}(1 - e^{-1}) - n(e^{-1} - e^{-2})] \tag{1.12}$$

W praktyce dla dużych n wariancja ta dąży do:

$$\text{Var}(X) \approx n \cdot e^{-1}(1 - e^{-1}) \approx n \cdot 0.233 \tag{1.13}$$

1.3. Odsetek unikalnych obserwacji i jego wariancja

Niech $\hat{p}$ będzie odsetkiem unikalnych obserwacji: $\hat{p} = \frac{X}{n}$.

1.3.1. Średnia

$$E[\hat{p}] = E\left[\frac{X}{n}\right] = \frac{1}{n} E[X] = 1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - e^{-1} \approx 0.632 \tag{1.14}$$

1.3.2. Wariancja

$$\text{Var}(\hat{p}) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) \tag{1.15}$$

Dla dużych n , wariancja odsetka maleje rzędu $\frac{1}{n}$.

1.4. Prawdopodobieństwo braku obserwacji w k próbkach

Prawdopodobieństwo, że dana obserwacja nie znajdzie się w jednej próbie bootstrapowej wynosi $\left(1 - \frac{1}{n}\right)^n \approx e^{-1}$. Ponieważ próbki są generowane niezależnie, prawdopodobieństwo, że obserwacja nie znajdzie się w żadnej z k próbek wynosi:

$$P(\text{brak w } k \text{ próbkach}) = \left[\left(1 - \frac{1}{n} \right)^n \right]^k \approx (e^{-1})^k = e^{-k} \quad (1.16)$$

2. Ćwiczenie 38 – Konstrukcja drzewa i predyktory kateryczne

2.1. Konstrukcja drzewa

Drzewa decyzyjne konstruowane są zazwyczaj za pomocą algorytmu zachłannego (np. CART, C4.5). Proces polega na rekurencyjnym podziale przestrzeni cech na prostokątne regiony. W każdym kroku wybierana jest zmienna oraz punkt podziału, które najlepiej rozdzielają dane względem zmiennej celu (minimalizując np. RSS dla regresji lub wskaźnik Giniego/entropię dla klasyfikacji).

2.2. Problem z predyktorem katerycznym

Dla predyktora katerycznego z q możliwymi nieuporządkowanymi wartościami, podział polega na przydzieleniu pewnego podzbioru wartości do lewego węzła, a reszty do prawego.

Liczba możliwych podziałów: Aby podzielić zbiór q wartości na dwie niepuste grupy, rozważamy wszystkie możliwe podzbiory. Zbiór q -elementowy ma 2^q podzbiorów.

1. Odejmujemy zbiór pusty i zbiór pełny (podział musi być na dwie grupy): $2^q - 2$.
2. Ponieważ podział $\{A, B\}$ vs $\{C\}$ jest tożsamy z $\{C\}$ vs $\{A, B\}$, wynik dzielimy przez 2.

Liczba podziałów wynosi:

$$\frac{2^q - 2}{2} = 2^{q-1} - 1 \quad (2.17)$$

Problem: Liczba ta rośnie wykładniczo wraz z q . Przeszukiwanie wszystkich podziałów jest obliczeniowo bardzo kosztowne dla dużego q . Dodatkowo, zmienne o dużej liczbie kategorii są faworyzowane przez algorytm doboru zmiennych (tzw. bias doboru).

2.3. Rozwiązanie problemu

Dla binarnej klasyfikacji (0/1) lub regresji istnieje efektywne rozwiązanie (Fisher, 1958):

1. Oblicz średnią wartość zmiennej celu dla każdej kategorii predyktora.
2. Uporządkuj kategorie według tych średnich rosnąco.
3. Potraktuj zmienną kateryczną jak zmienną ciągłą (uporządkowaną) i sprawdzaj podziały tylko wzdłuż tego porządku.

Redukuje to liczbę sprawdzanych podziałów z $2^{q-1} - 1$ do $q - 1$.

3. Ćwiczenie 39 – Miary jakości podziału

3.1. a) Interpretacja indeksu Giniego

Indeks Giniego dla węzła m zdefiniowany jest jako:

$$G = \sum_{k=1}^K p_{mk}(1 - p_{mk}) = 1 - \sum_{k=1}^K p_{mk}^2 \quad (3.18)$$

gdzie p_{mk} to frakcja obserwacji klasy k w węźle m .

Interpretacja: Indeks Giniego można interpretować jako miarę „nieczystości” węzła. Reprezentuje on oczekiwany poziom błędu, jeśli klasyfikowalibyśmy losowo obserwację z węzła, losując jej etykietę zgodnie z rozkładem klas w tym węźle. Im mniejszy indeks Giniego, tym bardziej „czysty” węzeł (zdominowany przez jedną klasę).

3.2. b) Porównanie podziałów

Mamy problem dwuklasowy (klasy A i B). W korzeniu mamy (400, 400). Całkowita liczba obserwacji $N = 800$.

- **Analiza Podziału 1:**

Tworzy węzły: $N_1(300, 100)$ oraz $N_2(100, 300)$.

- ▶ N_1 (400 obs): Dominująca klasa A. Błędne: 100 (klasa B).
- ▶ N_2 (400 obs): Dominująca klasa B. Błędne: 100 (klasa A).
- ▶ Całkowita liczba błędów: $100 + 100 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

- **Analiza Podziału 2:**

Tworzy węzły: $N_3(200, 400)$ oraz $N_4(200, 0)$.

- ▶ N_3 (600 obs): Dominująca klasa B. Błędne: 200 (klasa A).
- ▶ N_4 (200 obs): Dominująca klasa A. Błędne: 0 (czysty węzeł).
- ▶ Całkowita liczba błędów: $200 + 0 = 200$.
- ▶ **Odsetek błędnych klasyfikacji:** $\frac{200}{800} = 25$.

Oba podziały mają ten sam Misclassification Rate (0.25).

3.3. Obliczenie Indeksu Giniego

Wzór dla dwóch klas: $2p(1 - p)$.

- **Dla Podziału 1:**

- ▶ Węzeł N_1 ($p = 0.75$): $G_1 = 1 - (0.75^2 + 0.25^2) = 1 - (0.5625 + 0.0625) = 375$.
- ▶ Węzeł N_2 ($p = 0.25$): $G_2 = 1 - (0.25^2 + 0.75^2) = 375$.
- ▶ Średni ważony Gini:

$$G_{\text{split 1}} = \frac{400}{800} \cdot 0.375 + \frac{400}{800} \cdot 0.375 = 375 \quad (3.19)$$

- **Dla Podziału 2:**

- ▶ Węzeł N_3 (200, 400), $p_A = \frac{1}{3}$, $p_B = \frac{2}{3}$:

$$G_3 = 1 - \left(\left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right) = 1 - \left(\frac{1}{9} + \frac{4}{9} \right) = \frac{4}{9} \approx 0.444 \quad (3.20)$$

- ▶ Węzeł N_4 (200, 0), $p_A = 1$:

$$G_4 = 1 - (1^2 + 0^2) = 0 \quad (3.21)$$

(węzeł czysty)

- Średni ważony Gini (wagi: $\frac{600}{800} = \frac{3}{4}$ i $\frac{200}{800} = \frac{1}{4}$):

$$G_{\text{split } 2} = \frac{3}{4} \cdot \frac{4}{9} + \frac{1}{4} \cdot 0 = \frac{3}{9} = \frac{1}{3} \approx 0.333 \quad (3.22)$$

3.3.1. Wniosek

$$G_{\text{split } 2}(0.333) < G_{\text{split } 1}(0.375) \quad (3.23)$$

Indeks Giniego jest niższy dla drugiego podziału, co oznacza, że preferuje on podział, który wydziela czysty węzeł („pure node”), nawet jeśli globalny błąd klasyfikacji jest taki sam.