

Algorytmiczna Analiza Danych

Ćwiczenia 11

19 grudnia 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Zadanie 40 – Współczynnik Giniego

Współczynnik Giniego - to statystyczna miara koncentracji (nierówności) rozkładu dochodów lub bogactwa w danym społeczeństwie. Przyjmuje wartości od 0 do 1 (lub od 0% do 100%).

- **0 (Idealna równość)** - Każdy obywatel ma dokładnie taki sam dochód.
- **1 (Idealna nierówność)** - Jedna osoba posiada cały dochód kraju, a reszta nie posiada nic.

1.1. Intuicja geometryczna (Krzywa Lorenza)

Współczynnik Giniego oblicza się na podstawie wykresu, gdzie na osi X mamy skumulowany odsetek populacji, a na osi Y skumulowany odsetek dochodu.

1. **Linia 45 stopni** - To linia idealnej równości.
2. **Krzywa Lorenza** - Rzeczywisty rozkład dochodów w populacji.
3. **Obliczanie** - Jeśli oznaczymy pole między linią 45 stopni a Krzywą Lorenza jako A , a pole pod Krzywą Lorenza jako B , współczynnik Giniego (G) wyraża się wzorem:

$$G = \frac{A}{A + B} \quad (1.1)$$

1.2. Pozycja Polski w OECD

Polska na tle krajów OECD prezentuje się jako kraj o **średnio-niskich** nierównościach, szczególnie po uwzględnieniu transferów społecznych:

- **Przed transferami i podatkami:** Współczynnik Giniego w Polsce jest relatywnie wysoki (podobnie jak w większości krajów rozwiniętych), co wynika z rynkowego zróżnicowania płac.
- **Po transferach i podatkach:** Polska odnotowuje jeden z większych spadków współczynnika w OECD. Obecnie wartość ta oscyluje wokół **0.27 – 0.28**, co plasuje Polskę poniżej średniej OECD (czyli jesteśmy krajem o mniejszych nierównościach niż np. USA, Wielka Brytania czy kraje bałtyckie).

1.3. Poziom graniczny napięcie społecznych

W literaturze ekonomicznej i socjologicznej (m.in. ONZ) przyjmuje się często, że wartości współczynnika Giniego powyżej **0.40** stanowią „czerwoną linię”. Przekroczenie tego poziomu sugeruje głębokie nierówności, które mogą prowadzić do destabilizacji politycznej, protestów i wzrostu przestępczości.

2. Zadanie 41 – Algorytm Random Forest

Random Forest to metoda zespołowa (ensemble learning) oparta na budowie wielu drzew decyzyjnych i agregacji ich wyników.

2.1. Pseudokod

- Dla $b = 1$ do B (liczba drzew):
 - Wylosuj próbkę bootstrapową Z^* z danych treningowych (losowanie ze zwracaniem).
 - Wyhoduj drzewo T_b na podstawie próbki Z^* :
 - Powtarzaj, aż osiągniesz minimalny rozmiar liścia:
 - Wybierz losowo m zmiennych spośród wszystkich p predyktorów.
 - Wybierz najlepszą zmienną i punkt podziału spośród m zmiennych.
 - Podziel węzeł na dwa węzły potomne.
- Zwróć zespół drzew $\{T_b\}_1^B$.

2.2. Predykcja

- Klasyfikacja** - Głosowanie większościowe (Majority Vote) - klasa najczęściej wskazywana przez drzewa.
- Regresja** - Średnia arytmetyczna z przewidywań wszystkich B drzew.

3. Ćwiczenie 42 – Algorytm Boosting (Regresja)

W przeciwieństwie do Random Forest, Boosting buduje drzewa sekwencyjnie. Każde kolejne drzewo uczy się na błędach (resztach) swoich poprzedników.

3.1. Pseudokod (na podstawie ISL)

- Ustaw $\hat{f}(x) = 0$ oraz reszty $r_i = y_i$ dla wszystkich obserwacji w zbiorze treningowym.
- Dla $b = 1, 2, \dots, B$:
 - Dopasuj drzewo $\hat{f}^b$ z d podziałami (liczba liści = $d + 1$) do danych treningowych (X, r) .
 - Zaktualizuj model główny, dodając nową wersję drzewa z parametrem uczenia (shrinkage) λ :

$$\hat{f}(x) \leftarrow \hat{f}(x) + \lambda \hat{f}^b(x) \quad (3.2)$$

- Zaktualizuj reszty:

$$r_i \leftarrow r_i - \lambda \hat{f}^b(x_i) \quad (3.3)$$

- Zwróć model końcowy: $\hat{f}(x) = \sum_{b=1}^B \lambda \hat{f}^b(x)$.

3.2. Wyjaśnienie kluczowych parametrów

- B (Liczba drzew)** - Zbyt duża może prowadzić do overfittingu (inaczej niż w RF).
- λ (Shrinkage)** - Mała wartość (np. 0.01) spowalnia naukę, wymagając więcej drzew, ale zazwyczaj poprawia generalizację.
- d (Liczba podziałów)** - Kontroluje złożoność każdego drzewa (często wystarczają bardzo proste drzewa, tzw. stumps, gdzie $d = 1$).