

Algorytmiczna Analiza Danych

Ćwiczenia 13

16 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Ćwiczenie 46 – Idea algorytmu Apriori

Algorytm Apriori - klasyczny algorytm służący do znajdowania częstych zbiorów elementów (frequent itemsets) w transakcyjnych bazach danych.

1.1. Właściwość Apriori (Anti-monotonicity)

Kluczowa dla działania algorytmu jest zasada:

Jeśli zbiór elementów jest częsty, to każdy jego podzbiór musi być częsty. I odwrotnie: jeśli zbiór jest rzadki, to każdy jego nadzbiór również jest rzadki.

Dzięki tej właściwości możemy drastycznie ograniczyć przestrzeń poszukiwań (tzw. *pruning*). Jeśli zbiór A, B jest rzadki, nie musimy sprawdzać A, B, C, ponieważ on również musi być rzadki.

1.2. Proces generowania kandydatów

Algorytm działa iteracyjnie (poziomami $k = 1, 2, \dots$):

1. **Łączenie (Join)** - Kandydaci o rozmiarze k (C_k) są generowani poprzez łączenie częstych zbiorów o rozmiarze $k - 1$ (L_{k-1}). Łączymy dwa zbiory $X, Y \in L_{k-1}$ tylko wtedy, gdy ich pierwsze $k - 2$ elementy są identyczne (zakładając porządek leksykograficzny).
2. **Przycinanie (Prune)** - Dla każdego wygenerowanego kandydata sprawdzamy, czy **wszystkie** jego podzbiory o rozmiarze $k - 1$ znajdują się w L_{k-1} . Jeśli którykolwiek podzbiór nie jest częsty, kandydat jest usuwany zgodnie z właściwością Apriori.

2. Ćwiczenie 47 – Oznaczenie węzłów kraty (M, D, C, R)

Dane:

- Liczba transakcji (N): 10
- Próg wsparcia: 30% $\rightarrow$ 3 transakcje.

Analiza licznosci zbiorów (Support count):

Zbiór	Liczność	Status
{a}	5	D
{b}	7	D
{c}	5	D

Zbiór	Liczność	Status
{d}	9	D
{e}	6	C
{ab}	3	M
{ac}	2	R
{ad}	4	C
{ae}	4	C
{bc}	3	M
{bd}	6	D
{be}	4	C
{cd}	4	M
{ce}	2	R
{de}	6	D
{abc}	1	R
{abd}	2	R
{abe}	2	R
{acd}	1	R
{ace}	1	R
{ade}	4	M
{bcd}	2	R
{bce}	1	R
{bde}	4	M
{cde}	2	R
{abcd}	0	R
{abce}	0	R
{abde}	2	R
{acde}	1	R
{bcde}	1	R
{abcde}	0	R

Oznaczenia:

- **M (Maksymalny)** - Częsty, brak częstych nadzbiorów.
- **D (Domknięty)** - Częsty, brak nadzbiorów o *tym samym* wsparciu (Maksymalne też są domknięte, ale tutaj rozróżniamy je dla precyzji, przypisując M do tych na granicy „częstości”).
- **C** - Częsty, nie M i nie D.
- **R (Rzadki)** - Poniżej progu.

Wynikowa klasyfikacja węzłów:

- **M:** ab, bc, cd, ade, bde
- **D:** a, b, c, d, bd, de
- **C:** e, ad, ae, be
- **R:** ac, ce oraz wszystkie zbiory 3-elementowe inne niż ade, bde i wszystkie 4-elementowe.

3. Ćwiczenie 48 – Intuicje: Maksymalne vs Domknięte

3.1. Maksymalny zbiór częsty:

- **Intuicja:** Jest to „granica” zbiorów częstych. Najdłuższe możliwe kombinacje, które są jeszcze częste.
- **Cel:** Kompaktowa reprezentacja wszystkich częstych zbiorów. Jeśli znamy zbiory maksymalne, wiemy, że każdy ich podzbiór też jest częsty.
- **Wada:** Tracimy informację o dokładnej liczności podzbiorów (kompresja stratna).

3.2. Domknięty zbiór częsty:

- **Intuicja:** Zbiór, który „maksymalizuje” przedmioty dla danej grupy transakcji. Dodanie czegokolwiek do tego zbioru spowodowałoby spadek wsparcia (występowanie w mniejszej liczbie transakcji).
- **Cel:** Pozwala na odtworzenie dokładnego wsparcia wszystkich częstych podzbiorów bez skanowania bazy (kompresja bezstratna). Wsparcie dowolnego zbioru X jest równe wsparciu jego najmniejszego domkniętego nadzbioru.

Relacja:

$$\text{Maksymalne} \subseteq \text{Domknięte} \subseteq \text{Częste} \quad (3.1)$$

Każdy maksymalny zbiór jest domknięty, ale nie każdy domknięty jest maksymalny.

4. Ćwiczenie 49 – Złożoność Algorytmu Apriori

Niech d to liczba unikalnych przedmiotów, N to liczba transakcji, a w to maksymalna szerokość transakcji.

1. **Złożoność czasowa:** Głównym kosztem jest zliczanie wsparcia dla kandydatów C_k . W najgorszym przypadku algorytm generuje $O(2^d)$ kandydatów. Koszt zliczania to:

$$O\left(\sum_k |C_k| \cdot N \cdot w\right) \quad (4.2)$$

W praktyce często upraszcza się to do $O(2^d)$, co wskazuje na wykładniczą złożoność względem liczby produktów.

2. **Złożoność pamięciowa:** Wymaga przechowywania kandydatów na danym poziomie oraz liczników.

$$O\left(\max_k |C_k|\right) \quad (4.3)$$

W najgorszym przypadku (gdy $k \approx \frac{d}{2}$) pamięć rośnie wykładniczo.

Wpływ progu wsparcia ($\text{Support}_{\min}$): Tak, próg ma krytyczny wpływ.

- **Zmniejszanie $\text{Support}_{\min}$:** Powoduje gwałtowny wzrost liczby częstych zbiorów i kandydatów.
- **Negatywne konsekwencje:** Wykładniczy wzrost czasu obliczeń i zapotrzebowania na pamięć. Może dojść do wygenerowania tak dużej liczby kandydatów na poziomie 2 (pary), że algorytm nie zmieści się w pamięci RAM.

5. Ćwiczenie 50 – Liczba reguł asocjacyjnych

Mamy d zmiennych. Reguła ma postać $X \rightarrow Y$, gdzie $X, Y \subseteq I$, $X \cap Y = \emptyset$, $X \neq \emptyset$, $Y \neq \emptyset$.

Dla każdego z d elementów mamy 3 możliwości:

1. Element jest w antecedenencie (X).
2. Element jest w następniku (Y).
3. Element nie występuje w regule (nie jest ani w X , ani w Y).

Daje to 3^d kombinacji. Należy jednak odjąć przypadki niepoprawne:

- **Zbiór X jest pusty:** Elementy mogą być tylko w Y lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- **Zbiór Y jest pusty:** Elementy mogą być tylko w X lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- Odejmując $2^d + 2^d$, dwukrotnie odjęliśmy przypadek, gdzie zarówno X jak i Y są puste (wszystkie elementy są „nigdzie”). Należy go dodać (+1).

Zatem liczba reguł:

$$|R| = 3^d - (2^d + 2^d - 1) = 3^d - 2 \cdot 2^d + 1 = 3^d - 2^{d+1} + 1 \quad (5.4)$$

■

6. Ćwiczenie 51 – Przechodność reguł

Pytanie: Czy jeśli $\text{Conf}(A \rightarrow B) > \text{próg}$ i $\text{Conf}(B \rightarrow C) > \text{próg}$, to $\text{Conf}(A \rightarrow C)$ musi być wysokie?

Odpowiedź: Nie. Reguły asocjacyjne nie są przechodnie.

Przykład: Rozważmy 100 transakcji.

- A występuje w 10 transakcjach.
- B występuje w 10 transakcjach.
- C występuje w 10 transakcjach.
- A i B współwystępują w 9 transakcjach ($A \rightarrow B$, $\text{conf} = 0.9$).
- B i C współwystępują w 9 transakcjach ($B \rightarrow C$, $\text{conf} = 0.9$).
- Jednak zbiory A , B oraz B , C mogą „wymijać się” wewnątrz B tak bardzo, jak to możliwe. W skrajnym przypadku część wspólna A i C może być za mała.

A	A	A	A	A	A	A	A	A	A		
	B	B	B	B	B	B	B	B	B	B	
		C	C	C	C	C	C	C	C	C	C

W powyższym przykładzie $\text{Conf}(A \rightarrow B) = 0.9$ oraz $\text{Conf}(B \rightarrow C) = 0.9$, ale $\text{Conf}(A \rightarrow C) = 0.8$. Dla $\text{Conf}_{\min} \in (0.8, 0.9)$ reguła przechodnia $A \rightarrow C$ ma mniejszą ufność.

7. Ćwiczenie 52 – Dowód nierówności

Założenie: Ufność reguły $A \rightarrow B$ jest mniejsza niż wsparcie B , co zapisujemy jako:

$$\text{Conf}(A \rightarrow B) < \text{Supp}(B) \quad (7.5)$$

W języku prawdopodobieństwa warunkowego oznacza to:

$$P(B|A) < P(B) \quad (7.6)$$

(Obecność A zmniejsza prawdopodobieństwo wystąpienia B — korelacja ujemna).

Chcemy udowodnić, że dla $\bar{A}$ („brak A”):

- a) $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$
- b) $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Kolejność dowodzenia: Najpierw udowodnimy podpunkt **b)**, ponieważ podpunkt **a)** wynika z niego bezpośrednio.

7.1. Podpunkt b)

Theorem 7.1. $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Proof. Skorzystajmy z Prawa Prawdopodobieństwa Całkowitego dla zdarzenia B . Prawdopodobieństwo $P(B)$ jest średnią ważoną prawdopodobieństw warunkowych:

$$\begin{aligned} P(B) &= P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) \\ P(B) &= P(B|A)P(A) + P(B|\bar{A})(1 - P(A)) \\ P(B) - P(B|A)P(A) &= P(B|\bar{A})(1 - P(A)) \end{aligned} \quad (7.7)$$

$$\begin{aligned} P(B|A) &< P(B) \\ \Downarrow \\ P(B|A) &= P(B) - \varepsilon, \quad 0 < \varepsilon < 1 \end{aligned} \quad (7.8)$$

Podstawiając do lewej strony równania:

$$\begin{aligned} P(B) - (P(B) - \varepsilon)P(A) &= P(B) - P(B)P(A) + \varepsilon P(A) \\ &= P(B)(1 - P(A)) + \varepsilon P(A) \end{aligned} \quad (7.9)$$

$$P(B)(1 - P(A)) + \varepsilon P(A) = P(B|\bar{A})(1 - P(A)) \quad (7.10)$$

Dzielimy obie strony przez $(1 - P(A))$ (zakładając, że $P(A) \neq 1$):

$$P(B) + \frac{\varepsilon P(A)}{1 - P(A)} = P(B|\bar{A}) \quad (7.11)$$

Ponieważ $\varepsilon > 0$ oraz $P(A) \geq 0$, ułamek $\frac{\varepsilon P(A)}{1 - P(A)}$ jest liczbą dodatnią. Zatem:

$$P(B|\bar{A}) > P(B) \quad (7.12)$$

Co w notacji reguł asocjacyjnych oznacza:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (7.13)$$

■

7.2. Podpunkt a)

Theorem 7.2. $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$

Proof. Korzystamy z własności przechodniości nierówności.

1. Z udowodnionego przed chwilą punktu **b)** wiemy, że:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (7.14)$$

2. Z **założenia** w treści zadania wiemy, że:

$$\text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (7.15)$$

Łącząc te dwa fakty otrzymujemy ciąg nierówności:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (7.16)$$

Z czego wynika bezpośrednio:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B) \quad (7.17)$$

■

8. Ćwiczenie 53 – Miary oceny reguł

Poniższa tabela przedstawia definicje miar (gdzie $P(X)$ oznacza $\text{Supp}(X)$) wraz z ich intuicyjnym znaczeniem.

Miara	Definicja / Wzór	Intuicja / Interpretacja
Lift (Uniesienie)	$\frac{P(A \cap B)}{P(A)P(B)} = \frac{\text{Conf}(A \rightarrow B)}{\text{Supp}(B)}$	O ile razy częściej A i B występują razem, niż gdyby były niezależne? 1 = brak związku (losowość). > 1 = A przyciąga B (promocja łączona ma sens).
Leverage	$P(A \cap B) - P(A)P(B)$	Mierzy „nadwyżkę” transakcji. Ile dokładnie transakcji więcej (lub mniej) obserwujemy w porównaniu do oczekiwań losowych? W przeciwieństwie do Lift, jest to różnica bezwzględna.
Conviction (Przekonanie)	$\frac{1 - \text{Supp}(B)}{1 - \text{Conf}(A \rightarrow B)} = \frac{P(A)P(\neq B)}{P(A \cap \neq B)}$	Mierzy siłę implikacji. Jak bardzo reguła myliłaby się, gdyby A i B były niezależne? Wartość ∞ oznacza, że reguła $A \rightarrow B$ jest zawsze prawdziwa (pełna implikacja logiczna).

Jaccard	$\frac{P(A \cap B)}{P(A \cup B)} = \frac{P(A \cap B)}{P(A) + P(B) - P(A \cap B)}$	Podobieństwo zbiorów. Jaki procent transakcji zawierających przynajmniej jeden z tych produktów, zawiera oba ? Ignoruje transakcje, w których nie ma ani A, ani B.
Cosine	$\frac{P(A \cap B)}{\sqrt{P(A)P(B)}}$	Podobieństwo geometryczne. Wartość między 0 a 1. Jest to średnia geometryczna z ufności w obie strony ($A \rightarrow B$ i $B \rightarrow A$). Dobra miara, gdy licznosci A i B są podobne.
Kulczyński	$\frac{1}{2}(P(B A) + P(A B))$	Średnia arytmetyczna z ufności w obu kierunkach. Neutralizuje problem, gdy jeden produkt jest bardzo popularny, a drugi niszowy (nie faworyzuje żadnej strony).
Zhang	$\frac{P(A \cap B) - P(A)P(B)}{\max(P(A \cap B)(1 - P(A)), P(A)(P(B) - P(A \cap B)))}$	Kompleksowa miara (od -1 do $+1$). $+1$: Idealna pozytywna asocjacja. -1 : Idealna negatywna asocjacja (rozłączność). 0 : Brak związku.