

Algorytmiczna Analiza Danych

Ćwiczenia 14

23 stycznia 2025 r.

Adrian Herda
Politechnika Wrocławska

1. Ćwiczenie 50 – Liczba reguł asocjacyjnych

Mamy d zmiennych. Reguła ma postać $X \rightarrow Y$, gdzie $X, Y \subseteq I$, $X \cap Y = \emptyset$, $X \neq \emptyset$, $Y \neq \emptyset$.

Dla każdego z d elementów mamy 3 możliwości:

1. Element jest w antecedenencie (X).
2. Element jest w następniku (Y).
3. Element nie występuje w regule (nie jest ani w X , ani w Y).

Daje to 3^d kombinacji. Należy jednak odjąć przypadki niepoprawne:

- **Zbiór X jest pusty:** Elementy mogą być tylko w Y lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- **Zbiór Y jest pusty:** Elementy mogą być tylko w X lub „nigdzie” (2 opcje). Jest to 2^d przypadków.
- Odejmując $2^d + 2^d$, dwukrotnie odjęliśmy przypadek, gdzie zarówno X jak i Y są puste (wszystkie elementy są „nigdzie”). Należy go dodać (+1).

Zatem liczba reguł:

$$|R| = 3^d - (2^d + 2^d - 1) = 3^d - 2 \cdot 2^d + 1 = 3^d - 2^{d+1} + 1 \quad (1.1)$$

■

2. Ćwiczenie 51 – Przechodność reguł

Pytanie: Czy jeśli $\text{Conf}(A \rightarrow B) > \text{próg}$ i $\text{Conf}(B \rightarrow C) > \text{próg}$, to $\text{Conf}(A \rightarrow C)$ musi być wysokie?

Odpowiedź: Nie. Reguły asocjacyjne nie są przechodnie.

Przykład: Rozważmy 100 transakcji.

- A występuje w 10 transakcjach.
- B występuje w 10 transakcjach.
- C występuje w 10 transakcjach.
- A i B współwystępują w 9 transakcjach ($A \rightarrow B$, $\text{conf} = 0.9$).
- B i C współwystępują w 9 transakcjach ($B \rightarrow C$, $\text{conf} = 0.9$).
- Jednak zbiory A , B oraz B , C mogą „wymijać się” wewnątrz B tak bardzo, jak to możliwe. W skrajnym przypadku część wspólna A i C może być za mała.

A	A	A	A	A	A	A	A	A	A		
	B	B	B	B	B	B	B	B	B	B	
		C	C	C	C	C	C	C	C	C	C

W powyższym przykładzie $\text{Conf}(A \rightarrow B) = 0.9$ oraz $\text{Conf}(B \rightarrow C) = 0.9$, ale $\text{Conf}(A \rightarrow C) = 0.8$. Dla $\text{Conf}_{\min} \in (0.8, 0.9)$ reguła przechodnia $A \rightarrow C$ ma mniejszą ufność.

3. Ćwiczenie 52 – Dowód nierówności

Założenie: Ufność reguły $A \rightarrow B$ jest mniejsza niż wsparcie B , co zapisujemy jako:

$$\text{Conf}(A \rightarrow B) < \text{Supp}(B) \quad (3.2)$$

W języku prawdopodobieństwa warunkowego oznacza to:

$$P(B|A) < P(B) \quad (3.3)$$

(Obecność A zmniejsza prawdopodobieństwo wystąpienia B — korelacja ujemna).

Chcemy udowodnić, że dla $\bar{A}$ („brak A ”):

- a) $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$
- b) $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Kolejność dowodzenia: Najpierw udowodnimy podpunkt **b)**, ponieważ podpunkt **a)** wynika z niego bezpośrednio.

3.1. Podpunkt b)

Theorem 3.1. $\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B)$

Proof. Skorzystajmy z Prawa Prawdopodobieństwa Całkowitego dla zdarzenia B . Prawdopodobieństwo $P(B)$ jest średnią ważoną prawdopodobieństw warunkowych:

$$\begin{aligned} P(B) &= P(B|A)P(A) + P(B|\bar{A})P(\bar{A}) \\ P(B) &= P(B|A)P(A) + P(B|\bar{A})(1 - P(A)) \\ P(B) - P(B|A)P(A) &= P(B|\bar{A})(1 - P(A)) \end{aligned} \quad (3.4)$$

$$\begin{aligned} P(B|A) &< P(B) \\ \Downarrow \\ P(B|A) &= P(B) - \varepsilon, \quad 0 < \varepsilon < 1 \end{aligned} \quad (3.5)$$

Podstawiając do lewej strony równania:

$$\begin{aligned} P(B) - (P(B) - \varepsilon)P(A) &= P(B) - P(B)P(A) + \varepsilon P(A) \\ &= P(B)(1 - P(A)) + \varepsilon P(A) \end{aligned} \quad (3.6)$$

$$P(B)(1 - P(A)) + \varepsilon P(A) = P(B|\bar{A})(1 - P(A)) \quad (3.7)$$

Dzielimy obie strony przez $(1 - P(A))$ (zakładając, że $P(A) \neq 1$):

$$P(B) + \frac{\varepsilon P(A)}{1 - P(A)} = P(B|\bar{A}) \quad (3.8)$$

Ponieważ $\varepsilon > 0$ oraz $P(A) \geq 0$, ułamek $\frac{\varepsilon P(A)}{1 - P(A)}$ jest liczbą dodatnią. Zatem:

$$P(B|\bar{A}) > P(B) \quad (3.9)$$

Co w notacji reguł asocjacyjnych oznacza:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (3.10)$$

■

3.2. Podpunkt a)

Theorem 3.2. $\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B)$

Proof. Korzystamy z własności przechodniości nierówności.

1. Z udowodnionego przed chwilą punktu **b)** wiemy, że:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) \quad (3.11)$$

2. Z **założenia** w treści zadania wiemy, że:

$$\text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (3.12)$$

Łącząc te dwa fakty otrzymujemy ciąg nierówności:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Supp}(B) > \text{Conf}(A \rightarrow B) \quad (3.13)$$

Z czego wynika bezpośrednio:

$$\text{Conf}(\bar{A} \rightarrow B) > \text{Conf}(A \rightarrow B) \quad (3.14)$$

■

4. Ćwiczenie 53 – Miary oceny reguł

Poniższa tabela przedstawia definicje miar (gdzie $P(X)$ oznacza $\text{Supp}(X)$) wraz z ich intuicyjnym znaczeniem.

Miara	Definicja / Wzór	Intuicja / Interpretacja
Lift (Uniesienie)	$\frac{P(A \cap B)}{P(A)P(B)} = \frac{\text{Conf}(A \rightarrow B)}{\text{Supp}(B)}$	O ile razy częściej A i B występują razem, niż gdyby były niezależne? 1 = brak związku (losowość). > 1 = A przyciąga B (promocja łączona ma sens).
Leverage	$P(A \cap B) - P(A)P(B)$	Mierzy „nadwyżkę” transakcji. Ile dokładnie transakcji więcej (lub mniej) obserwujemy w porównaniu do oczekiwań losowych? W

		przeciwieństwie do Lift, jest to różnica bezwzględna.
Conviction (Przekonanie)	$\frac{1 - \text{Supp}(B)}{1 - \text{Conf}(A \rightarrow B)} = \frac{P(A)P(\neq B)}{P(A \cap \neq B)}$	Mierzy siłę implikacji. Jak bardzo reguła myliłaby się, gdyby A i B były niezależne? Wartość ∞ oznacza, że reguła $A \rightarrow B$ jest zawsze prawdziwa (pełna implikacja logiczna).
Jaccard	$\frac{P(A \cap B)}{P(A \cup B)} = \frac{P(A \cap B)}{P(A) + P(B) - P(A \cap B)}$	Podobieństwo zbiorów. Jaki procent transakcji zawierających przynajmniej jeden z tych produktów, zawiera oba ? Ignoruje transakcje, w których nie ma ani A, ani B.
Cosine	$\frac{P(A \cap B)}{\sqrt{P(A)P(B)}}$	Podobieństwo geometryczne. Wartość między 0 a 1. Jest to średnia geometryczna z ufności w obie strony ($A \rightarrow B$ i $B \rightarrow A$). Dobra miara, gdy licznosci A i B są podobne.
Kulczyński	$\frac{1}{2}(P(B A) + P(A B))$	Średnia arytmetyczna z ufności w obu kierunkach. Neutralizuje problem, gdy jeden produkt jest bardzo popularny, a drugi niszowy (nie faworyzuje żadnej strony).
Zhang	$\frac{P(A \cap B) - P(A)P(B)}{\max(P(A \cap B)(1 - P(A)), P(A)(P(B) - P(A \cap B)))}$	Kompleksowa miara (od -1 do $+1$). $+1$: Idealna pozytywna asocjacja. -1 : Idealna negatywna asocjacja (rozłączność). 0 : Brak związku.